

Wintersemester 2024/2025

Statistik

Studiengang Wirtschaftsingenierwesen

M. Wiedemann

Vorwort

Das vorliegende Skript ist Grundlage der Vorlesung „Statistik“ im Studiengang Wirtschaftsingenieurwesen an der Hochschule Esslingen im Wintersemester 2024/2025.

Da Irren und Fehler leider in der menschlichen Natur liegen, wird auch dieses Skript – trotz großer Sorgfalt bei der Erstellung – nicht frei davon sein. Falls Sie Fehler oder Missverständliches finden, bin ich Ihnen für einen Hinweis an marcel.wiedemann@hs-esslingen.de sehr dankbar!

Gegenüber der letzten Version zum Sommersemester 2024 gibt es folgende Änderungen:

- kleinere Korrekturen

im Juli 2024

Marcel Wiedemann

Inhaltsverzeichnis

I	Einführung	5
1	Was ist Statistik?	6
1.1	Ablauf einer statistischen Analyse	6
1.2	Grundbegriffe	7
1.3	Klassierte Daten	8
2	Tabellenkalkulation Excel	9
2.1	Grundfunktionen	10
2.2	Relative und absolute Zellbezüge	11
2.3	Matrixformeln	12
2.4	Erstellen und Formatieren von Diagrammen	13
2.5	Daten aus Text-Dateien einlesen	16
II	Beschreibende Statistik	19
1	Eindimensionale Häufigkeitsverteilungen	20
1.1	Häufigkeiten und ihre graphische Darstellung	20
1.2	Mit Graphiken lügen?! – Qualitätskriterien für gute Graphiken	25
1.3	Die empirische Verteilungsfunktion	27
1.4	Quantile	29
1.5	Lage- und Streuparameter	34
1.5.1	Lageparameter	34
1.5.2	Streuungsparameter	38
2	Zweidimensionale Häufigkeitsverteilungen	42
2.1	Kovarianz und Korrelationskoeffizient	44
2.2	Regressionsanalyse	49
3	Lineare Transformation von Daten	56
4	Regression - weiterführende Aspekte	60
III	Wahrscheinlichkeitsrechnung	64
1	Grundlagen	65
1.1	Kombinatorik	65
1.2	Mengenlehre	68
1.3	Axiome der Wahrscheinlichkeitsrechnung	70
2	Laplace-Experiment	74
3	Unabhängige Ereignisse	76

4	Bedingte Wahrscheinlichkeit	78
5	Zufallsvariablen	83
5.1	Diskrete Zufallsvariable	85
5.2	Stetige Zufallsvariable	87
5.3	Symmetrische Zufallsvariable	90
6	Erwartungswert einer Zufallsvariablen	91
7	Varianz einer Zufallsvariablen	94
8	Interpretation der Dichte von Zufallsvariablen	97
9	Arithmetisches Mittel bei Versuchswiederholungen	98
10	Standardisierung einer Zufallsvariable	99
11	Diskrete Verteilungen	100
11.1	Binomialverteilung	100
11.2	Poisson-Verteilung	106
11.3	Hypergeometrische Verteilung	111
12	Stetige Verteilungen	115
12.1	Gleichverteilung	115
12.2	Normalverteilung	116
12.3	Zentraler Grenzwertsatz	123
IV	Schliessende Statistik	128
1	Punktschätzer	129
1.1	Schätzer Erwartungswert	131
1.2	Schätzer Varianz	131
1.3	Schätzer Standardabweichung	132
1.4	Schätzer Wahrscheinlichkeit	133
2	Intervallschätzer	134
2.1	Intervallschätzer für Normalverteilungen	135
2.1.1	Intervallschätzer Erwartungswert bei bekannter Varianz	135
2.1.2	Intervallschätzer Erwartungswert bei unbekannter Varianz	138
2.1.3	Intervallschätzer Differenz zweier Erwartungswerte bei bekannter Varianz	141
2.1.4	Intervallschätzer Differenz zweier Erwartungswerte bei unbekannter gleicher Varianz	143
2.1.5	Intervallschätzer Varianz	144
2.2	Intervallschätzer Erwartungswert für beliebige Verteilungen	147
2.3	Intervallschätzer Wahrscheinlichkeit	148
3	Hypothesentests	150
3.1	Vorgehen bei statistischen Tests	153

3.1.1	Wahl der Hypothesen	154
3.1.2	Wahl des Signifikanzniveaus	155
3.2	Hypothesentests für Normalverteilungen	155
3.2.1	Hypothesentest Erwartungswert bei bekannter Varianz	155
3.2.2	Hypothesentest Erwartungswert bei unbekannter Varianz	157
3.2.3	Hypothesentest Vergleich Erwartungswerte bei unbekannter gleicher Va- rianz	158
3.3	Hypothesentests für Wahrscheinlichkeiten	160
3.4	Abschließende Bemerkungen	161
V	Statistische Qualitätskontrolle	162
1	Einführung	163
2	Prozessfähigkeit	163
3	Qualitätsregelkarten	165
3.1	$\bar{x}$ -Karte	166
3.2	s -Karte	167
4	Bestimmung von μ und σ	169
5	Ein Beispiel	170
5.1	Analyse des Fertigungsprozesses – Schätzung von μ und σ	170
5.2	Prozessanalyse – Ermittlung von c_p und c_{pk}	170
5.3	Prozesskontrolle – Vorbereitung der Qualitätsregelkarten	171
5.3.1	$\bar{x}$ -Karte	171
5.3.2	s -Karte	172
5.4	Prozesskontrolle – Durchführung	173
VI	Anhang	174
	Tabelle: Normalverteilung	175
	Tabelle: Normalverteilung - Quantile	176
	Tabelle: t -Verteilung	177
	Tabelle: χ^2 -Verteilung	178

Teil I

Einführung

1 Was ist Statistik?

„Statistical thinking will one day be as necessary for efficient citizenship as the ability to read and write.“ H.G. Wells

Statistik befasst sich mit der Erfassung, Analyse, Auswertung und Darstellung von Daten sowie Entscheidungsmethoden unter Unsicherheit. Mit Statistik kommen wir nahezu täglich in Berührung, z. B. bei Meinungsumfragen, Wahlprognosen, Sportanalysen, Wetterberichten, Versicherungen, Finanzanalysen, ...

Wir unterscheiden in der Statistik die folgenden Teilbereiche.

- (I) **Beschreibende Statistik:** Ziel der beschreibenden Statistik ist es, empirisch gewonnene Daten aufzubereiten und in eine „übersichtliche Form“ zu bringen. Hierzu dienen Tabellen, Graphiken, ... Dies ist Inhalt des Kapitels II: mit den hier vorgestellten Methoden, wollen wir die Daten zum „Sprechen“ bringen.
- (II) **Schließende Statistik:** Ziel der schließenden Statistik ist es, aus den erhobenen Daten Rückschlüsse auf die zugrundeliegende Grundgesamtheit zu ziehen. Da wir stets nur über Stichproben verfügen und es in den meisten Fällen kaum möglich ist, die Grundgesamtheit vollständig zu untersuchen, werden derartige Rückschlüsse immer mit Unsicherheiten behaftet sein. Schließende Statistik ist Inhalt der Kapitels IV. Hierzu werden wir die Ergebnisse der Wahrscheinlichkeitsrechnung/-theorie aus Kapitel III benötigen.
- (III) **Analytische/Explorative Statistik:** Die analytische Statistik befindet sich im Übergang zwischen den Teilbereichen beschreibende und schließende Statistik. Ziel ist das Suchen nach Zusammenhängen und Strukturen in den Daten. Die so gewonnenen Hypothesen lassen sich mittels der Methoden der schließenden Statistik überprüfen. Analytische Statistik ist nicht Teil der Vorlesung.

1.1 Ablauf einer statistischen Analyse

Eine statistische Analyse verläuft in folgenden Schritten:

1. Planung

- Festlegen des Untersuchungsziels
- Festlegung der Grundgesamtheit (Definition der zu untersuchenden statistischen Elemente, präzise Abgrenzung in räumlicher, zeitlicher und sachlicher Hinsicht)
- Festlegung der zu erhebenden Merkmale
- Festlegung der Art (Totalerhebung/Vollerhebung, Teilerhebung/Stichprobe) und Methode (Zufallsstichprobe, systematische Auswahl, Schichtenstichprobe, Klumpenstichprobe, Quotenverfahren, ...) der Datenerhebung

2. Erhebung

- Fragebögen, Beobachtung, Experimente, Datenbanken, ...

- Primärerhebung (Daten werden selbst erhoben), Sekundärerhebung (bereits erhobene Daten werden genutzt)
3. Datenbereinigung
 - Identifizieren von Ausreißern und fehlenden Werten
 - ggf. berichtigen, streichen, abändern oder beibehalten
 4. Aufbereitung/Darstellung
 5. Analyse/Interpretation

Auf einer auf diese Weise durchgeführten statistischen Analyse können schließlich Entscheidungen zu den untersuchten Sachverhalten getroffen werden.

Bemerkung 1.1

Die Schritte 1 - 3 werden auch unter dem Begriff Datengewinnung, die Schritte 4 - 5 unter dem Begriff Datenauswertung zusammengefasst.

Die Datengewinnung sollte stets mit größter Sorgfalt durchgeführt werden; haben die erhobenen Daten nicht die nötige Qualität, können sie u. U. für eine Weiterverwendung nutzlos sein.

Im Kapitel *Beschreibende Statistik* beschäftigen wir uns mit dem Thema Aufbereitung/Darstellung von Daten und im Kapitel *Schließende Statistik* mit dem Thema Analyse/Interpretation.

1.2 Grundbegriffe

Unter einer Grundgesamtheit verstehen wir eine Menge an Objekten, der unser Interesse gilt bzw. die untersucht werden sollen (z. B. Studierende, Autos, Häuser, Lagerbestand, ...). Statistische Elemente sind Elemente unserer Grundgesamtheit (z. B. ein Studierender, ein Auto, ein Haus, ...). Unter Merkmalen verstehen wir die Eigenschaften dieser statistischen Elemente; Merkmale bezeichnen wir mit Großbuchstaben $X, Y, \dots$. Ein statistisches Element kann eine Vielzahl von Merkmalen haben (z. B. Alter, Größe, Haarfarbe, ...). Merkmalsausprägungen schließlich sind die Werte, die ein Merkmal annehmen kann (z. B. natürliche Zahlen, reelle Zahlen, Farben, ...), diese bezeichnen wir mit Kleinbuchstaben $\tilde{x}_i$ (mit i aus einer geeigneten Indexmenge).

Wir unterscheiden die folgenden Merkmalstypen.

- (I) Quantitative Merkmale: Die Ausprägungen des Merkmals sind Zahlen bzw. Zahlen zuordenbar. Insbesondere besitzen die Reihenfolge aber auch die Differenzen der Merkmale eine Aussagekraft.
 - (i) Quantitativ-diskrete Merkmale: Die Ausprägungen bilden eine diskrete Zahlenmenge, d. h. es gibt nur endlich viele (oder abzählbar unendlich viele) Ausprägungen. Z. B. Ausprägungen in $\mathbb{N}$ oder $\mathbb{Z}$.

- (ii) Quantitativ-stetige Merkmale: Die Ausprägungen können beliebige Zahlenwerte innerhalb eines Intervalls (aus den reellen Zahlen) annehmen.
- (II) Qualitative Merkmale: Merkmale, die sich nicht durch Zahlen direkt erfassen lassen (bspw. durch Messen oder Zählen). Eine Codierung durch Zahlen kann zwar möglich sein, jedoch haben Differenzen keine direkte Bedeutung.
 - (i) Qualitativ-ordinale Merkmale: Die Ausprägungen lassen sich anordnen, ihre Unterschiede sind aber nicht quantitativ fassbar.
 - (ii) Qualitativ-nominale Merkmale: Die Ausprägungen können nicht sinnvoll in eine Reihenfolge gebracht werden, sondern nur an ihrer konkreten Ausprägung unterschieden werden.

Bemerkung 1.2

Ein Spezialfall qualitativer Merkmale sind sog. dichotome Merkmale, die nur zwei Ausprägungen annehmen können.

Beispiel 1.3

Im Folgenden einige Beispiele für die obigen Merkmalstypen.

- Quantitativ-diskret: Alter, Anzahl kaputter Bauteile, ...
- Quantitativ-stetig: Temperaturen, Längen, ...
- Qualitativ-ordinal: Noten, Dienstgrade, Studienjahr, ...
- Qualitativ-nominal: Beruf, Haarfarbe, Geburtsort, ...
- Dichotom: Geschlecht (m/w), verheiratet (ja/nein), schulpflichtig (ja/nein), ...

Unter dem Begriff Daten oder Stichprobe verstehen wir die beobachteten Werte eines oder mehrerer Merkmale. Wir bezeichnen diese mit x_i (mit i aus einer geeigneten Indexmenge) in Falle eines Merkmals bzw. als Tupel im Falle mehrerer Merkmale. Die Gesamtheit der erhobenen Daten nennt man auch Urliste.

Beispiel 1.4

	Beispiel 1	Beispiel 2
Grundgesamtheit	Studierende HS Esslingen	Autofahrer in Deutschland
Merkmal	Alter	Automarke
Merkmalsausprägung	1, 2, ..., 120	BMW, Audi, Mercedes, sonstige
Daten/Stichprobe	19, 20, 20, 23, 25, 18	Audi, BMW, sonst., sonst., Mercedes

1.3 Klassierte Daten

Häufig liegen die Daten nicht in Form einer Urliste x_i (mit i aus einer geeigneten Indexmenge) vor, sondern zusammengefasst nach Klassen. Beispielsweise ist bei sehr langen Datenreihen die

Betrachtung jedes einzelnen Punktes oft sinnlos, vielmehr macht dann eine Zusammenfassung quantitativer Merkmale in Klassen Sinn. Insbesondere bei quantitativ-stetigen Merkmalen ist dies sinnvoll.

Als Klassen wählen wir hierzu Intervalle der Form

$$A_1 := [a_1, b_1], A_2 := (a_2, b_2], \dots, A_k := (a_k, b_k],$$

wobei $b_1 = a_2, \dots, b_{k-1} = a_k$ gilt, d. h. die Intervalle grenzen „direkt aneinander“. Die Intervalle selbst können durchaus unterschiedlich lang sein. Darüber hinaus kann gelten $a_1 = -\infty$ (dann ist A_1 links offen) oder $b_k = \infty$ (dann ist A_k rechts offen).

Quantitative Merkmale der obigen Form nennen wir (stetig) klassierte Merkmale.

Beispiel 1.5

Von 50 Haushalten wurde das Nettoeinkommen in € erhoben und wie folgt klassiert:

Klassen A_i	$[0, 1000]$	$(1000, 1500]$	$(1500, 2000]$	$(2000, 3000]$	$(3000, 4000]$	$(4000, 8000]$
Anzahl	10	15	10	5	5	5

Bemerkung 1.6

Durch das Zusammenfassen von Daten in Klassen werden diese zwar übersichtlicher, allerdings verlieren wir auch Information! Darüber hinaus stellen sich die folgenden Fragen:

- Wie viele Klassen sollen gewählt werden?
Faustregel bei n Daten: Anzahl der Klassen sollte $\sqrt{n}$ nicht übersteigen.
- Sollen die Klassen gleich groß gewählt werden?
- Gibt es eine sinnvolle Beschränkung des untersten bzw. des obersten Intervalls?

2 Tabellenkalkulation Excel

Im Rahmen dieser Vorlesungen (als auch der zugehörigen Labor-Übungen) wird sich der Umgang mit Excel als sehr hilfreich bzw. nötig erweisen. Dieser Abschnitt soll daher als kurze Einführung in die Funktionalitäten von Excel dienen; ein Anspruch auf Vollständigkeit wird dabei natürlich nicht erhoben. Die hier diskutierten Inhalte sollen lediglich die Basis für die weitere Beschäftigung mit Excel schaffen. Wir werden zusätzlich weiterführende statistische Funktionen in den entsprechenden Kapiteln des Skriptes kurz anreißen und diskutieren. Darüber hinaus sei zur weiteren Vertiefung insbes. auf die Excel-Hilfe verwiesen.

Die Darstellung in den folgenden Abschnitten beruht auf Excel 2007. Unter anderen Excel-Versionen können einige Optionen eventuell anders betitelt oder angeordnet sein.

2.1 Grundfunktionen

Ein Excel-Arbeitsblatt ist wie folgt in Zeilen 1, 2, 3, ... bzw. Spalten A, B, C, ... aufgeteilt. Jede Zelle kann über ihren Zeilen- bzw. Spaltenindex eindeutig angesprochen werden.

	A	B	C	D	E
1					
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					

In die einzelnen Zellen können Texte, Zahlen als auch (komplexere) Rechenoperationen eingegeben werden. Bei der Eingabe von Rechenoperationen ist jedoch zu beachten, dass diese mit einem Gleichheitszeichen = beginnen müssen.

Zum Erstellen von Listen und Tabellen kann wie folgt vorgefahren werden. Wollen wir beispielsweise eine Liste der Wurzeln aus den Zahlen von 1 bis 10 erstellen (auf 3 Dezimalstellen), erstellen wir zuerst eine Liste mit Zahlen von 1 bis 10 und ziehen aus diesen dann jeweils die Wurzel.

1. Eingabe der ersten beiden Werte 1 und 2 in die Zellen A1 und A2.
2. Markieren der beiden Zahlen. Durch Klicken und Halten (mit der linken Maustaste) auf das kleine Viereck an der rechten unteren Seite des markierten Bereiches, kann die Liste nun beliebig durch Ziehen nach unten verlängert werden.

	A	B	C	D	E
1	1				
2	2				
3					
4					
5					
6					
7					
8					
9					
10					
11					


	A	B	C	D	E
1	1				
2	2				
3	3				
4	4				
5	5				
6	6				
7	7				
8	8				
9	9				
10	10				
11					

3. Eingabe der Berechnungsformel in die Zelle B1: `=WURZEL(A1)`. Nach Eingabe von `=WURZEL()` kann auch mittels Maus die gewünschte Zelle (Bezug der Formel) durch Anklicken bestimmt werden (hierzu vorher Cursor zwischen den Klammern positionieren).
4. Markieren der ersten Berechnungsformel (Zelle B1). Durch Klicken und Halten (mit der linken Maustaste) auf das kleine Viereck an der rechten unteren Seite des markierten Bereiches, kann die Berechnungsformel nun beliebig durch Ziehen nach unten fortgesetzt werden.

	A	B	C	D	E
1		=WURZEL(A1)			
2	2	WURZEL(Zahl)			
3	3				
4	4				
5	5				
6	6				
7	7				
8	8				
9	9				
10	10				
11					

	A	B	C	D	E
1	1	1			
2	2	1,41421356			
3	3	1,73205081			
4	4	2			
5	5	2,23606798			
6	6	2,44948974			
7	7	2,64575131			
8	8	2,82842712			
9	9	3			
10	10	3,16227766			
11					

5. Wir markieren die Liste der Wurzeln und rufen mittels Rechtsklick das Menü **Zellen formatieren** auf. Im Reiter **Zahlen** wählen wir unter **Zahl** 3 Dezimalstellen aus.



	A	B	C	D	E
1	1	1,000			
2	2	1,414			
3	3	1,732			
4	4	2,000			
5	5	2,236			
6	6	2,449			
7	7	2,646			
8	8	2,828			
9	9	3,000			
10	10	3,162			
11					

Bemerkung 2.1

1. Durch Doppelklicken in die einzelnen berechneten Zellen, wird jeweils die verwendete Formel inkl. ihrer Zellbezüge angezeigt.
2. Wir haben im obigen Beispiel eine erste Excel-Funktion, nämlich die Wurzel, kennengelernt; Excel bietet jedoch noch eine Vielzahl weiterer Funktionen an. Eine Übersicht über alle verfügbaren Funktionen erhält man mittels des Excel-Formelgenerators. Diesen findet man im Reiter **Formeln** unter **Funktion einfügen**.
3. Oftmals ist der Formelgenerator jedoch gar nicht nötig. Bei der Eingabe von Funktionen (bereits nach Eingabe von wenigen Buchstaben) zeigt Excel eine Auswahl möglicher Funktionen an. Durch Doppelklick kann eine Funktion gewählt werden; hiernach wird ersichtlich, welche Input-Parameter die Funktion benötigt und welches Format diese haben müssen.

2.2 Relative und absolute Zellbezüge

Den Bezug in der Formel im letzten Beispiel nennt man auch einen **relativen Bezug**: durch das Ziehen zum Fortsetzen der Formel wurden dann gemäß Zugrichtung alle Zellen entsprechend verändert. Dies ist jedoch nicht immer gewünscht: erweitern wir hierzu das obige Beispiel wie folgt. Wir möchten nun die Wurzeln der Zahlen 1 bis 10 jeweils mit 3 multiplizieren.

1. Wir belegen eine Zelle mit dem gewünschten Faktor 3 und multiplizieren den ersten Term $\sqrt{1}$ mit 3.

Wir können diese Formel nun nicht wie oben einfach durch markieren und ziehen nach unten fortsetzen, denn dann wird auch entsprechend der Zugrichtung die Zelle mit dem Faktor 3 verändert. Um dies zu verhindern, benötigen wir einen **absoluten Bezug**, d. h. Spalte und/oder Zeile einer Zelle sollen beim Ziehen (der Formel) festgehalten werden. Dies erreicht man durch Einfügen eines \$-Zeichens vor dem Zeilenindex (zum Festhalten der Zeile) bzw. dem Spaltenindex (zum Festhalten der Spalte) beim Ziehen.

Bemerkung 2.2

Absolute Zellbezüge können beim Eingeben der Formel auch mittels **F4-Taste** (für Windows) bzw. **CMD+T** (für Mac) eingegeben werden. Nachdem der gewünschte Zellbezug eingegeben wurde, können mittels der eben genannten Tastenkombinationen die gewünschten absoluten Bezüge gewählt werden (ggf. mehrfaches Drücken nötig).

In unserem Beispiel verfahren wir nun wie folgt.

2. Wir machen aus dem Zellbezug zur Multiplikation mit 3 einen absoluten Zellbezug. Dabei genügt es eigentlich – da wir die Formel nach unten ziehen – die Zeile der Zelle des Faktors festzuhalten.
3. Formel – entsprechend des letzten Beispiels – nach unten ziehen und die Ergebnisse auf 3 Dezimalstellen formatieren.

WURZEL				
	A	B	C	D
1	1	1,000	Faktor	=B1*\$C\$2
2	2	1,414		
3	3	1,732		
4	4	2,000		
5	5	2,236		
6	6	2,449		
7	7	2,646		
8	8	2,828		
9	9	3,000		
10	10	3,162		
11				

D1				
	A	B	C	D
1	1	1,000	Faktor	3,000
2	2	1,414	3	4,243
3	3	1,732		5,196
4	4	2,000		6,000
5	5	2,236		6,708
6	6	2,449		7,348
7	7	2,646		7,937
8	8	2,828		8,485
9	9	3,000		9,000
10	10	3,162		9,487
11				

Bemerkung 2.3

Ändern wir die Zahl 3 (in der Zelle für den neu eingefügten Faktor), so berechnen sich alle Zellen neu.

2.3 Matrixformeln

Spezielle Funktionen unter Excel sind sog. Matrixfunktionen, deren Ergebnis eine Matrix (also mehrere Zellen) ist und nicht nur eine Zelle. Als Beispiel wollen wir die beiden folgenden Matrizen mit Excel multiplizieren:

$$\underline{A} = \begin{pmatrix} 1 & 2 & 2 \\ 4 & 0 & 6 \end{pmatrix} \quad \underline{B} = \begin{pmatrix} -2 & 3 \\ 4 & 2 \\ 3 & 6 \end{pmatrix}$$

Hierzu sind folgende Schritte durchzuführen.

1. Eingeben der beiden Matrizen – in der obigen Gestalt – in Excel.
2. Markieren des Zielbereiches, der das Ergebnis enthalten soll: dieser ist eine 2×2 –Matrix.

	A	B	C	D	E	F	G	H
1								
2								
3		A				A*B		
4			1	2	2			
5			4	0	6			
6								
7		B						
8			-2	3				
9			4	2				
10			3	6				
11								

3. Eingabe der Funktion `=MMULT(A;B)` (dies ist die Excel-Funktion zur Multiplikation von Matrizen) wobei für die beiden Matrizen (getrennt durch ein Semikolon) die entsprechenden Bereiche zu markieren sind (hierzu jeweils vorher Cursor an der entsprechenden Stelle der Formel positionieren). An dieser Stelle NICHT **Enter** drücken!
4. Nach Eingabe der Formel die Tastenkombination **STRG+SHIFT+ENTER** drücken. Der markierte Bereich ist mit dem Ergebnis der Matrizenmultiplikation ausgefüllt.


	A	B	C	D	E	F	G	H
1								
2								
3		A				A*B		
4			1	2	2			
5			4	0	6			
6								
7		B						
8			-2	3				
9			4	2				
10			3	6				
11								

	A	B	C	D	E	F	G	H
1								
2								
3		A				A*B		
4			1	2	2	12	19	
5			4	0	6	10	48	
6								
7		B						
8			-2	3				
9			4	2				
10			3	6				
11								


2.4 Erstellen und Formatieren von Diagrammen

Wir wollen die Notenverteilung einer Statistik-Klausur mittels eines Diagrammes darstellen. Hierzu verfahren wir wie folgt.


1. Markieren der Zellen, die im Diagramm dargestellt werden sollen.
2. Im Reiter **Einfügen** können verschieden Diagrammtypen gewählt werden (im Teil **Diagramme**). Die Auswahl weiterer Typen ist durch Anklicken der Schaltfläche unten rechts möglich. Wir wählen ein **Säulendiagramm**: durch Anklicken können wir verschiedene Typen von Säulendiagrammen auswählen. Wir wählen den ersten Typ.



3. Wir ändern die Farbe der Balken auf rot: hierzu klicken wir einen Balken an (hiernach sind alle Balken markiert), nach Rechtsklick wählen wir das Menü **Datenreihe formatieren**. Unter **Füllung** > **Einfarbige Füllung** kann die Farbe rot gewählt werden.



4. Wir ändern die Bezeichnung der horizontalen Achse wie folgt: Anklicken des Diagramms, danach Rechtsklick. Wir wählen das Menü **Daten auswählen**. Hiernach Klick auf **Bearbeiten** der horizontalen Achsenbeschriftung. Schließlich mittels Maus den gewünschten Beschriftungsbereich markieren.



Bemerkung 2.4



1. Durch Rechtsklick auf das Diagramm können sowohl Diagrammtyp als auch die Daten

(im entsprechenden Menü) geändert werden.



2. Durch Klicken auf das Diagramm werden die Diagramm Daten mittels farbiger Rechtecke angezeigt. Durch Vergrößern/Verkleinern mittels Maus können die Diagramm Daten ebenfalls angepasst werden.
3. Durch Doppelklick auf die einzelnen Diagrammelemente (bspw. die Balken) können diese ebenfalls beliebig formatiert werden.

Das Diagramm kann nun wie gewünscht formatiert werden. Nach Anklicken des Diagramms kann im Reiter Layout (unter Diagrammtools) das Diagramm bearbeitet werden. Wir passen das Diagramm nun wie folgt an.



5. Wir fügen den Diagrammtitel „Notenverteilung“, durch Anklicken von Diagrammtitel (und Auswahl Über Diagramm) ein. Nach Anklicken des Titels im Diagramm kann der gewünschte Titel eingegeben werden. Zur weiteren Formatierung (Schriftart, Schriftgröße, ...) können die Excel-Standardbefehle genutzt werden.
6. Wir löschen die Bezeichnung Datenreihe1 durch Anklicken und Entfernen (siehe auch Bemerkung 2.5).




7. Wir fügen Achsenbezeichnungen (horizontal und vertikal) mittels Anklicken von Achsentitel ein. Wir bezeichnen die horizontale Achse mit „Noten“ und die vertikale Achse mit „Anzahl“.



8. Wir beschriften jeden Balken mit seinem Wert durch Anklicken von Datenbeschriftungen (wir wählen zentriert). Zur weiteren Formatierung der Datenbeschriftungen können die gewohnten Excel-Befehle genutzt werden: wir wählen Schriftgröße 14 (hierzu einfach die Beschriftung anklicken, danach Rechtsklick und die gewünschte Formatierung wählen).



Als Ergebnis erhalten wir schließlich:




Bemerkung 2.5

Die Bezeichnung Datenreihe1 kann im Menü Daten auswählen im Reiter Entwurf (Diagrammtools) geändert werden. Durch Bearbeiten der Reihe Datenreihe1 kann unter Reihenname der gewünschte Name eingegeben werden (auch hier kann ein Zellbezug gewählt werden).

2.5 Daten aus Text-Dateien einlesen



Wir wollen Daten aus der folgenden Textdatei (mit Dateiondung .txt) einlesen. Hierbei sollen die einzelnen Spalten in der Datei in jeweils einzelne Spalten in Excel übertragen werden, damit wir diese hiernach weiter bearbeiten können.





Hierzu verfahren wir wie folgt.

1. Auswahl der gewünschten Textdatei über Menü **Office > Öffnen**. Nach Auswahl der gewünschten Datei öffnet sich der Textkonvertierungs-Assistent.
2. Auswahl, wie die einzelnen Daten getrennt sind: Spalten fester Breite (Wahl **Feste Breite**) oder Trennzeichen (Wahl **Getrennt**). Darüber hinaus kann gewählt werden, ab welcher Zeile der Import beginnen soll.
 - (a) Bei Wahl **Feste Breite** können durch Klicken in den Vorschaubereich verschiedene Spaltenumbrüche eingefügt werden.
 - (b) Bei Wahl **Getrennt** können die verschiedenen Trennzeichen zwischen den Spalten ausgewählt werden. Der Vorschaubereich zeigt an, wie die Daten in Spalten eingeteilt werden.

Für das obige Beispiel wählen wir **Getrennt** (da die einzelnen Spalten durch Leerzeichen getrennt sind) sowie Import ab Zeile 1 und drücken **Weiter**. Als Trennzeichen wählen wir **Leerzeichen**.



3. Auswahl der Datenformate für jede Spalte. Hier wählen wir für unser Beispiel **Standard**.
4. Durch Klicken auf **Fertig stellen** werden die Daten in eine neue Excel-Arbeitsmappe mit der entsprechend gewählte Spalteneinteilung übernommen.



5. Die Daten können nun in eine beliebige andere Excel-Arbeitsmappe kopiert werden. Hierzu einfach die Daten markieren, kopieren (Button **Kopieren** im Reiter **Start** oder **STRG+C** unter Windows bzw. **CMD+C** unter Mac) sowie an der gewünschten Stelle einfügen (Button **Einfügen** im Reiter **Start** oder **STRG+V** unter Windows bzw. **CMD+V** unter Mac). Durch Klicken auf das Symbol des eingefügten Bereiches (unten rechts) kann ausgewählt werden, wie die Daten eingefügt werden sollen (bspw. bei Auswahl **Werte und Zahlenformate** werden sowohl die Werte als auch die Formate der kopierten Zahlen beibehalten).

32	32	89	1,7
33	33	64	3
34	34	82	2
35	35	72	2,7
36	36	76	2,7
37	37	95	1,3
38	38	87	2
39	39	84	2
40	40	110	1
41	41	80	2,3
42	42	74	2,7
43			
44			
45			

Teil II

Beschreibende Statistik

1 Eindimensionale Häufigkeitsverteilungen

1.1 Häufigkeiten und ihre graphische Darstellung

Aus einer gegebenen Datenmenge – insbesondere wenn diese sehr groß ist – ist es oft schwierig, sinnvolle Erkenntnisse zu ziehen, wenn diese nicht strukturiert aufbereitet ist. Ein erster sinnvoller Schritt ist das Untersuchen der Häufigkeiten der Merkmalsausprägungen.

Definition 1.1. (Absolute und relative Häufigkeiten – unklassierte Daten)

Gegeben sei eine n -elementige Menge unklassierter Daten des Merkmals X . Seien weiter $\tilde{x}_i$ die Ausprägung des Merkmals X . Wir definieren:

- die absolute Häufigkeit h_i von $\tilde{x}_i$ durch

$$h_i := \text{Anzahl der Daten mit Merkmalsausprägung } \tilde{x}_i$$

- die relative Häufigkeit f_i von $\tilde{x}_i$ durch

$$f_i := \frac{h_i}{n}$$

Ganz analog können wir absolute und relative Häufigkeiten für klassierte Daten definieren.

Definition 1.2. (Absolute und relative Häufigkeiten – klassierte Daten)

Gegeben sei eine n -elementige Menge klassierter Daten des Merkmals X . Seien weiter A_i die Klassen des Merkmals X . Wir definieren:

- die absolute Häufigkeit h_i von A_i durch

$$h_i := \text{Anzahl der Daten in der Klasse } A_i$$

- die relative Häufigkeit f_i von A_i durch

$$f_i := \frac{h_i}{n}$$

Die relativen Häufigkeiten werden auch gerne in Prozent angegeben. Für die oben definierten Größen gelten offensichtlich die folgenden Gleichungen:

$$\begin{aligned} \sum_{i=1}^n h_i &= n \\ \sum_{i=1}^n f_i &= 1 \end{aligned}$$

Mittels eines sog. Stabdiagramms können wir sowohl absoluten als auch die relativen Häufigkeiten von (klassierten) Merkmalen darstellen. Hierzu tragen wir die Merkmale entlang der x -Achse

(bei nominalen Merkmalen müssen wir hierzu u. U. eine willkürliche Reihenfolge festlegen) sowie ihre Häufigkeiten entlang der y -Achse auf. Bei klassierten quantitativen Merkmalen (insbes. bei stetigen Merkmalen) wird jedoch häufig lieber auf die Darstellung mittels eines Histogramms zurückgegriffen. Im Gegensatz zu Stabdiagrammen werden bei Histogrammen die Klassenbreiten mit berücksichtigt. Die Fläche über einer Klasse im Histogramm entspricht dabei der relativen Häufigkeiten der jeweiligen Merkmalsausprägung. Wir werden später sehen, dass das Histogramm das Pendant zur Dichte in der Wahrscheinlichkeitsrechnung ist.

Gegeben seien klassierte Daten eines quantitativen Merkmals X . Die Klassen seien gegeben durch Intervalle A_i mit $i = 1, \dots, k$. Seien weiter h_i mit $i = 1, \dots, k$ die absoluten Häufigkeiten pro Klasse. Das zugehörige Histogramm konstruieren wir, indem wir die relativen Häufigkeiten der Intervalle mit der Intervallgröße gewichten.


Klassen	$[a_1, b_1]$	$(a_2, b_2]$	$\dots$	$(a_k, b_k]$
absolute Häufigkeiten	h_1	h_2	$\dots$	h_k
relative Häufigkeiten	$f_1 = h_1/n$	$f_2 = h_2/n$	$\dots$	$f_k = h_k/n$
Histogramm-Höhe	$\frac{f_1}{b_1 - a_1}$	$\frac{f_2}{b_2 - a_2}$	$\dots$	$\frac{f_k}{b_k - a_k}$

Entlang der x -Achse tragen wir nun die Klassen (maßstabsgetreu) und entlang der y -Achse die Histogramm-Höhen auf. Auf diese Weise erhalten wir eine Treppenfunktion, wobei die Fläche unter der Funktion gleich 1 ist. Wie wir später sehen werden, ist dies völlig analog zu Wahrscheinlichkeitsdichten.

Beispiel 1.3. (Fortsetzung)

Von 50 Haushalten wurde das Nettoeinkommen in € erhoben und wie folgt klassiert.

A_i	$[0, 1000]$	$(1000, 1500]$	$(1500, 2000]$	$(2000, 3000]$	$(3000, 4000]$	$(4000, 8000]$
h_i	10	15	10	5	5	5
f_i	0.2	0.3	0.2	0.1	0.1	0.1
Höhe Hist.	0.0002	0.0006	0.0004	0.0001	0.0001	0.000025




Die Einheiten der x -Achsen sind jeweils in Tsd. angegeben.

Stabdiagramme als auch Histogramme sind natürlich nicht unabhängig von der Klasseneinteilung. Betrachten wir hierzu das letzte Beispiel mit folgender Klasseneinteilung (wenngleich


diese auch extremer Natur ist):

A_i	$[0, 1500]$	$(1500, 8000]$
h_i	25	25
f_i	0.5	0.5
Höhe Hist.	0.00033	$7,69 \cdot 10^{-5}$


abs. Häufigkeiten



rel. Häufigkeiten



Histogramm



Bemerkung 1.4

1. Das letzte Beispiel zeigt – wenn auch auf extreme Weise –, dass wir bei der Interpretation von Stabdiagrammen und Histogrammen die Klasseneinteilung mit im Blick haben müssen! Das Stabdiagramm der relativen Häufigkeiten lädt in obigem Falle zu Fehlinterpretationen gerade zu ein (wenn man nicht beachtet, dass die zweite Klasse wesentlich größer ist als die erste). Im Histogramm wird diese Information besser aufbereitet.
2. Sind die Klassen klein, wird das Histogramm eher sprunghaft und dem Stabdiagramm ähnlich. Sind die Klassen groß, weist es nur wenige Rechtecke auf (im Extremfall nur eines).
3. Sind alle Klassen gleich groß bzw. breit, so haben Stabdiagramm und Histogramm die gleiche Struktur.

Aufgabe 1.5

Es wurde untersucht, wie hoch der Promillespiegel bei Verkehrskontrollen ist. Ergänze die Daten der folgenden Tabelle und zeichne sowohl das Häufigkeitsdiagramm als auch das Histogramm.

A_i	$[0 - 0.3)$	$[0.3 - 0.5)$	$[0.5 - 0.8)$	$[0.8 - 1.3)$	$[1.3 - 2.0)$	$[2.0 - 3.5]$
h_i	5	20	25	10	5	5
f_i						
Höhe Hist.						

Bemerkung 1.6

In einem späteren Kapitel werden wir uns mit Dichten von Zufallsvariablen befassen. Haben wir klassierte Daten einer Zufallsvariablen gegeben, so können wir wie oben hergeleitet ein Histogramm der Daten zeichnen. Wollen wir nun prüfen, ob diese Zufallsvariable einem bestimmten Verteilungstyp genügt, können wir einfach die Dichte der Verteilung dem Histogramm der Daten gegenüberstellen und prüfen, inwieweit die beiden zueinander passen. Hierzu später mehr.

Excel 1.7. (Häufigkeitsdiagramme erstellen)

Wir wollen Häufigkeitsdiagramme zur Notenverteilung der in der Datei **Noten.txt** zur Verfügung gestellten Daten erstellen. Die Datei hat die folgende Gestalt: laufende Nummer, Punktzahl, Note (drei Spalten).

Zur Bestimmung der absoluten Häufigkeiten der Notenverteilung kann die Excel-Funktion **HÄUFIGKEIT(Daten; Klassen)** verwendet werden.

1. Einlesen der Daten in Excel (Details hierzu können dem Abschnitt *Tabellenkalkulation Excel* in Kapitel I entnommen werden).
2. Eingabe der Klassen (d. h. der Obergrenzen für jede Note). Diese seien wie folgt festgelegt:

The screenshot shows an Excel spreadsheet with two main data areas. The first area is a table of grades (Note) and their corresponding absolute frequencies (abs. Häufigkeit). The second area is a summary table showing the frequency distribution for each grade class.

Note	abs. Häufigkeit	rel. Häufigkeit
sehr gut	1	2,3
gut	3,3	
befriedigend	4	
ausreichend	5	
mangelhaft		

3. Bestimmung der absoluten Häufigkeit pro Klasse mittels **HÄUFIGKEIT(Daten; Klassen)**. Bei dieser Funktion handelt es sich um eine Matrixfunktion, d. h. ihr Ergebnis sind mehrere Zellen gleichzeitig. Die Eingabe geschieht wie folgt:
 - (a) Markieren des Zielbereiches für absoluten Häufigkeiten.
 - (b) Eingabe der Funktion **=HÄUFIGKEIT(Daten; Klassen)**, wobei für **Daten** die Daten der Noten zu markieren sind und für **Klassen** die definierten Klassengrenzen. **Nicht Enter drücken!**
 - (c) Drücken von **STRG+SHIFT+ENTER** gleichzeitig: hiernach befinden sich die absoluten Häufigkeiten im markierten Zielbereich.

Note	abs. Häufigkeit	rel. Häufigkeit
sehr gut	1,5	10
gut	2,3	20
befriedigend	3,3	9
ausreichend	4	2
mangelhaft	5	1

4. Einfügen der Summe der absoluten Häufigkeiten (diese wird zur Berechnung der relativen Häufigkeiten benötigt). Hierzu steht die Excel-Funktion SUMME(Zahl1; Zahl2; ...) zur Verfügung.

Eingabe von =SUMME(Zahl1; Zahl2; ...), wobei für Zahl1; Zahl2; ... der zu summierende Bereich mit der Maus zu markieren ist. Hiernach Enter drücken.


Note	abs. Häufigkeit	rel. Häufigkeit
sehr gut	1,5	10
gut	2,3	20
befriedigend	3,3	9
ausreichend	4	2
mangelhaft	5	1
Summe	=SUMME(H4:H8)	

5. Berechnung der relativen Häufigkeiten pro Klasse (Verwendung eines absoluten Bezugs für die Summenzeile beachten!)

Note	abs. Häufigkeit	rel. Häufigkeit
sehr gut	1,5	=H4/\$S\$10
gut	2,3	20
befriedigend	3,3	9
ausreichend	4	2
mangelhaft	5	1
Summe		


Note	abs. Häufigkeit	rel. Häufigkeit
sehr gut	1,5	0,38095238
gut	2,3	0,476190476
befriedigend	3,3	0,244761904
ausreichend	4	0,047619048
mangelhaft	5	0,023809524
Summe		

6. Formatierung der relativen Häufigkeiten als Prozentwerte wie folgt: Markieren, Rechtsklick, Wahl Zellen formatieren, Wahl Prozent sowie 2 Dezimalstellen im Reiter Zahlen. Alternativ können die beiden Buttons (siehe Graphik) benutzt werden: mit dem Prozent-Button (roter Kreis) werden die Zahlen als Prozentwerte formatiert, mit den Dezimalstellen-Buttons (blauer Kreis) können die Anzahl der Dezimalstellen erhöht bzw. verringert werden.



Neben der Darstellung von Merkmalsausprägungen mittels Stabdiagrammen oder Histogrammen, gibt es noch die Darstellung mittels sog. Kreis- bzw. Tortendiagramme. Diese ist besonders geeignet für qualitativ-nominale Daten, da die Festlegung einer Reihenfolge oder Anordnung dabei nicht nötig ist. Das Kreisdiagramm wird dabei proportional zu den relativen Häufigkeiten der Merkmalsausprägungen aufgeteilt.


Beispiel 1.8



1.2 Mit Graphiken lügen?! – Qualitätskriterien für gute Graphiken


Graphiken (wie bspw. die im letzten Abschnitt kennengelernten Diagramme) erlauben dem Benutzer oftmals sehr schnell wesentliche Informationen aus komplexem Datenmaterial zu erkennen bzw. Auffälligkeiten herauszuarbeiten, nach dem Motto „*Ein Bild sagt mehr als tausend Worte!*“. Hierzu bedarf es einer guten graphischen Aufbereitung des Datenmaterials. Sind Graphiken schlecht aufbereitet, kann genau das Gegenteil passieren und Missverständnisse sowie Fehlinterpretationen sind vorprogrammiert. Im Folgenden einige typische Fehler.

- 1. Zu komplexe Darstellungen:** Enthalten Graphiken zu viel Information, ist es oft kaum möglich, Aussagen aus ihnen zu gewinnen.





Quelle: *Wie man sich durch Graphiken täuschen lässt.* Wolfgang Walla (s.u.)

- 2. Unpassende Maßstäbe und Skalierungen:** Durch unpassende Maßstäbe bzw. Skalierungen, kann Zahlenmaterial wesentlich dramatischer dargestellt werden als es tatsächlich der Fall ist.



Jahr	Hausmüll pro Kopf	Veränderung zum Vorjahr	
	in kg	abs.	in %
1996	429	-	-
1997	443	14	3 %
1998	437	-6	-1 %
1999	431	-6	-1 %
2000	425	-6	-1 %

- 3. Fehlende Bezugsgrößen:** Fehlen Bezugsgrößen (absolute Werte), ist eine sinnvolle Interpretation oftmals nicht möglich.



Quelle: *Wie man sich durch Graphiken täuschen lässt.* Wolfgang Walla (s.u.)

Eine sehr schöne Aufbereitung weiterer Missverständnisse und Fehlinterpretationen, die bei falscher Aufbereitung von Graphiken entstehen können, findet man in folgender Quelle:

Wie man sich durch Graphiken täuschen lässt. Wolfgang Walla. Statistisches Landesamt Baden-Württemberg. 2. Auflage.

Bemerkung 1.9

Auf folgende Aspekte sollte bei Graphiken geachtet werden:

- Bezeichnende Titel
- Achsenbeschriftungen mit Einheiten
- (Möglichst) unverzerrte Skalierungen
- Beschränkung auf die wesentlichen Informationen

Motto: Die einfachste Graphik ist oft auch die Beste!

1.3 Die empirische Verteilungsfunktion

Definition 1.10. (Empirische Verteilungsfunktion – unklassierte Daten)

Gegeben sei eine n -elementige Menge an Daten eines quantitativen Merkmals X mit Merkmalsausprägungen $\tilde{x}_1, \dots, \tilde{x}_k$. Seien f_i die relativen Häufigkeiten der Merkmalsausprägungen $\tilde{x}_i$. Wir definieren die empirischen Verteilungsfunktion F des Merkmals X wie folgt

$$F(x) = \frac{\text{Anzahl der Stichprobenelemente } \leq x}{n} = \sum_{i: \tilde{x}_i \leq x} f_i$$


für $x \in \mathbb{R}$.

Die empirische Verteilungsfunktion summiert also die relativen Häufigkeiten aller Ausprägungen $\tilde{x}_i$ die kleiner gleich x sind. Dies ergibt eine rechtsseitig stetige Treppenfunktion, wie das folgende Beispiel zeigt.

Beispiel 1.11

Im Folgenden sei eine Stichprobe von Mathematiknoten von 20 Schülern gegeben :

$\tilde{x}_i$	1	2	3	4	5	6
h_i	3	7	4	3	2	1
f_i	0.15	0.35	0.2	0.15	0.1	0.05
kum. f_i	0.15	0.5	0.7	0.85	0.95	1



Wir können die Merkmalsausprägungen des quantitativen Merkmals X natürlich anordnen. Seien die Ausprägungen wie folgt geordnet $\tilde{x}_1 \leq \dots \leq \tilde{x}_k$, so gilt für die empirische Verteilungsfunktion:

$$F(x) = \begin{cases} 0 & , \text{ für } x < \tilde{x}_1 \\ \sum_{j=1}^i f_j & , \text{ für } \tilde{x}_i \leq x < \tilde{x}_{i+1} \\ 1 & , \text{ für } \tilde{x}_k \leq x \end{cases}$$

wobei f_i die relative Häufigkeit der Merkmalsausprägung $\tilde{x}_i$ ist.

Definition 1.12. (Empirische Verteilungsfunktion – klassierte Daten)

Gegeben seien klassierte Daten eines quantitativen Merkmals X mit Klassen $A_i = (a_i, b_i]$ für $i = 1, \dots, k$. Seien weiter f_i die relativen Häufigkeiten der Klassen A_i . Wir definieren die empirischen Verteilungsfunktion F des klassierten Merkmals X wie folgt

$$F(x) := \begin{cases} 0 & , \text{ für } x < a_1 \\ \sum_{j=1}^{i-1} f_j + \frac{x-a_i}{b_i-a_i} f_i & , \text{ für } a_i \leq x < b_i \\ 1 & , \text{ für } b_k \leq x \end{cases}$$

für $x \in \mathbb{R}$.


Die Verteilungsfunktion eines klassierten quantitativ Merkmals bzw. klassierter Daten ist eine stetige Funktion. Sie ergibt sich durch Integration des Histogramms und damit gewissermaßen als dessen Stammfunktion. An den Klassenober- bzw. Klassenuntergrenzen stimmt die Definition für klassierte Daten mit der für unklassierte Daten überein. Innerhalb einer Klasse wird der Wert der Verteilungsfunktion einfach linear zwischen den Klassengrenzen interpoliert. Dies setzt gewissermaßen die Annahme voraus, dass die Werte innerhalb der Klassen gleichverteilt sind.

Beispiel 1.13. (Fortsetzung)


Von 50 Haushalten wurde das Nettoeinkommen in € erhoben und wie folgt klassiert.

A_i	$[0, 1000]$	$(1000, 1500]$	$(1500, 2000]$	$(2000, 3000]$	$(3000, 4000]$	$(4000, 8000]$
h_i	10	15	10	5	5	5
f_i	0.2	0.3	0.2	0.1	0.1	0.1
kum. f_i	0.2	0.5	0.7	0.8	0.9	1.0

Histogramm



Verteilungsfunktion



Wenn wir uns das letzte Beispiel genau anschauen, fällt Folgendes auf. Die Steigungen der Verteilungsfunktion innerhalb einer gegebenen Klasse entspricht genau der Höhe des Histogrammes der entsprechenden Klasse. D. h. die Ableitung der Verteilungsfunktion innerhalb einer Klasse (nur hier ist die Ableitung auch definiert) gibt die Histogrammhöhe. Das Histogramm kann damit als Ableitung der Verteilungsfunktion aufgefasst werden (beachte jedoch, dass die Ableitung an den Klassengrenzen i. d. R. nicht definiert ist). Umgekehrt ergibt sich der Verteilungsfunktion einfach durch Integration des Histogramms: am obigen Beispiel kann dies leicht nachvollzogen werden.

1.4 Quantile

Definition 1.14. (Empirisches Quantil)

Sei X ein quantitatives Merkmal, F die Verteilungsfunktion und $p \in (0, 1)$. Das empirische p -Quantil – bezeichnet mit x_p – ist derjenige Wert, für den gilt:

$$\begin{aligned} x_p &= \min\{x \in \mathbb{R} : F(x) \geq p\} \\ &= \text{kleinstes } x \text{ mit } F(x) \geq p \end{aligned}$$


Folgende Quantile haben spezielle Namen:

- $x_{0.5}$ nennt man Median
- $x_{0.25}, x_{0.5}$ und $x_{0.75}$ nennt man erstes, zweites und drittes Quartil
- $x_{0.01}, x_{0.02}, x_{0.03}, \dots$ nennt man erstes, zweites, drittes, ... Perzentil

Beispiel 1.15. (Fortsetzung)

Unsere Stichprobe von Mathematiknoten von 20 Schülern war wie folgt gegeben:

$\tilde{x}_i$	1	2	3	4	5	6
h_i	3	7	4	3	2	1
f_i	0.15	0.35	0.2	0.15	0.1	0.05
kum. f_i	0.15	0.5	0.7	0.85	0.95	1



Beispiele für Quantile

$$\begin{aligned} x_{0.1} &= 1 \\ x_{0.25} &= 2 \\ x_{0.5} &= 2 \\ x_{0.75} &= 4 \end{aligned}$$

Bemerkung 1.16

Für eine unklassierte Menge an Daten ist das p -Quantil x_p also der kleinste Wert $x \in \mathbb{R}$, sodass

- mindestens $p \cdot 100\%$ der Daten sind kleiner oder gleich x_p bzw.
- mehr als $(1 - p) \cdot 100\%$ der Daten sind größer oder gleich x_p .

Aufgabe 1.17

Übersetze die folgenden Aussagen in die Sprache der Statistik mittels Quantilen.

1. „25 % der Frauen sind kleiner als 162.3 cm.“
2. „50 % der Bundestagsabgeordneten sind älter als 52.2 Jahre.“

3. „30 % aller Schrauben einer Produktion sind länger als 5.3 cm.“

4. „99.5 % aller Hagelereignisse kosten den Versicherer weniger als 1.25 Mio. €.“

Übersetze die folgenden Aussagen zurück in eine „normale“ Sprache.

1. „Die Kriminalitätsrate der Stadt X entspricht dem 85 % Quantil.“

2. „Das Ergebnis des IQ-Tests entspricht dem 99 % Quantil.“

3. „Die Stärke des Sturms entspricht dem 99.5 % Quantil.“

Wir wollen uns nun der Frage nähern, wie wir Quantile bestimmen können. Für Quantile nicht klassierter Daten gilt der folgende Satz.

Satz 1.18. (Quantile nicht klassierter Daten)

Gegeben sei eine n -elementige Menge an Daten eines Merkmals X und $p \in (0, 1)$. Zuerst ordnen wir die Daten der Größe nach wie folgt $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. Das p -Quantil ist gegeben durch

$$x_p = \begin{cases} x_{(n \cdot p)} & , \text{ falls } n \cdot p \text{ ganzzahlig ist} \\ x_{(\lfloor n \cdot p \rfloor + 1)} & , \text{ sonst} \end{cases}$$

wobei $\lfloor n \cdot p \rfloor$ den ganzzahligen Anteil von $n \cdot p$ bezeichnet.

Beispiel 1.19. (Fortsetzung)

Unsere Stichprobe von Mathematiknoten von 20 Schülern war wie folgt gegeben:

$\tilde{x}_i$	1	2	3	4	5	6
h_i	3	7	4	3	2	1

Geordnet hat unsere Stichprobe die folgende Form:

1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 4, 4, 4, 5, 5, 6

Wir berechnen die folgenden Quantile:

$$\begin{aligned} p = 0.1 &\implies 20 \cdot 0.1 = 2 \implies x_{0.1} = x_{(2)} = 1 \\ p = 0.25 &\implies 20 \cdot 0.25 = 5 \implies x_{0.25} = x_{(5)} = 2 \\ p = 0.5 &\implies 20 \cdot 0.5 = 10 \implies x_{0.5} = x_{(10)} = 2 \\ p = 0.75 &\implies 20 \cdot 0.75 = 15 \implies x_{0.75} = x_{(15)} = 4 \\ p = 0.775 &\implies 20 \cdot 0.775 = 15.5 \implies x_{0.775} = x_{(16)} = 4 \end{aligned}$$

Diese Ergebnisse haben wir teilweise bereits weiter oben graphisch anhand der Verteilungsfunktion hergeleitet.

Bemerkung 1.20

Oftmals definiert man das p -Quantil für eine n -elementige Menge an Daten (wie oben geordnet) allerdings wie folgt:

$$x_p = \begin{cases} \frac{1}{2} (x_{(n \cdot p)} + x_{(n \cdot p) + 1}) & , \text{ falls } n \cdot p \text{ ganzzahlig ist} \\ x_{(\lfloor n \cdot p \rfloor + 1)} & , \text{ sonst} \end{cases}$$

Falls $n \cdot p$ ganzzahlig ist, weicht dies von unserer Definition ab (nach Satz 1.18). Der Vorteil dieser Definition ist, dass im Falle einer symmetrischen Verteilung das 0.5-Quantil (auch Median genannt) mit dem Mittelwert übereinstimmt. Unsere Definition hat den Vorteil, dass die Quantile Elemente der Stichprobe sind.

Excel 1.21. (Quantile und Quartile)

Zur Bestimmung von Quantilen nicht klassierter Daten bietet Excel (ab Version 2011) folgende Funktionen an (inkl. der zugehörigen Quantilsdefinition):

- `QUANTIL.INKL(Matrix; Alpha)`

$$x_p = (1 - g) \cdot x_{(j+1)} + g \cdot x_{(j+2)} \quad \text{mit} \quad (n - 1) \cdot p = j + g \text{ und } x_{(0)} = x_{(1)}$$

- `QUANTIL.EXKL(Matrix; Alpha)`

$$x_p = (1 - g) \cdot x_{(j+1)} + g \cdot x_{(j+2)} \quad \text{mit} \quad (n + 1) \cdot p = j + g \text{ und } x_{(n)} = x_{(n+1)}$$

wobei jeweils `Matrix` die Daten und `Alpha` ($=p$) das gewünschte Quantil bezeichnet. Insbesondere approximieren beide Formeln linear, falls $(n - 1) \cdot p$ bzw. $(n + 1) \cdot p$ keine ganze Zahl ist. Dies ist ein Unterschied zu unserer Definition: die Excel-Formeln liefern damit andere Ergebnisse! Dies ist kein Fehler, sondern lediglich eine anderen Definition des Begriffes Quantil geschuldet.

Mittels der Excel-Funktionen `QUARTILE.INKL(Matrix; Quartile)` bzw. `QUARTILE.EXKL(Matrix; Quartile)` können die Quartile bestimmt werden. Der Parameter `Quartile` gibt das Quartil an: 0 (liefert den niedrigsten Wert), 1 (25 % Quantil), 2 (50 % Quantil), 3 (75 % Quantil), 4 (liefert den höchsten Wert).

In Versionen vor Excel 2011 wird die Funktion `QUANTIL(Matrix; Alpha)` angeboten, diese entspricht der Funktion `QUANTIL.INKL(Matrix; Alpha)`.

Wir wenden nun unseren Fokus auf die Bestimmung von Quantilen klassierter Daten. In diesem Falle ist die empirische Verteilungsfunktion stetig. Wenn es keine Klasse bzw. kein Intervall mit Häufigkeit 0 gibt, so ist F sogar streng monoton wachsend. Die folgende Gleichung hat dann eine eindeutige Lösung x_p :

$$F(x_p) = p.$$

Mit Hilfe des folgenden Satzes können wir einfach das Quantil x_p bestimmen.

Satz 1.22. (Quantile klassierter Daten)

Sei F die Verteilungsfunktion klassierter Daten und sei $p \in (0, 1)$. Das p -Quantil bestimmt man wie folgt.

1. Bestimme die Klasse $(a_i, b_i]$ derart, dass $p \in (F(a_i), F(b_i)]$ gilt.
2. Dann gilt:

$$x_p = a_i + \frac{p - F(a_i)}{F(b_i) - F(a_i)}(b_i - a_i)$$


Der letzte Satz gibt uns ein einfaches Rezept zur Bestimmung der Quantile: Zuerst suchen wir die Klasse $(a_i, b_i]$ mit $F(a_i) < p \leq F(b_i)$. Das Quantil x_p bestimmen wir dann, indem wir zwischen a_i und b_i linear interpolieren. Dieses Vorgehen funktioniert auch, wenn es Klassen mit Häufigkeit 0 gibt.

Beispiel 1.23. (Fortsetzung)

Von 50 Haushalten wurde das Nettoeinkommen in € erhoben und wie folgt klassiert.

A_i	$[0, 1000]$	$(1000, 1500]$	$(1500, 2000]$	$(2000, 3000]$	$(3000, 4000]$	$(4000, 8000]$
h_i	10	15	10	5	5	5
f_i	0.2	0.3	0.2	0.1	0.1	0.1
kum. f_i	0.2	0.5	0.7	0.8	0.9	1.0

Verteilungsfunktion



Frage: 40% der Haushalte haben ein Nettoeinkommen kleiner als $x_{0.4}$. Wie groß ist $x_{0.4}$?

Antwort: Es gilt also das 0.4-Quantil der Verteilung zu bestimmen. Wir gehen gemäß Satz 1.22 vor. Für die Klasse $(1000, 1500]$ gilt (siehe Verteilungsfunktion), dass

$$F(1000) = 0.2 < 0.4 \leq 0.5 = F(1500)$$

und damit

$$\begin{aligned} x_{0.4} &= 1000 + \frac{0.4 - 0.2}{0.5 - 0.2} \cdot (1500 - 1000) \\ &= 1333.33 \end{aligned}$$

Aufgabe 1.24

Berechne für das obige Beispiel die folgenden Quantile:

$$x_{0.1}, x_{0.5}, x_{0.82}$$

1.5 Lage- und Streuparameter

Wir möchten in den folgenden Abschnitten Kennzahlen zum Beschreiben von Stichproben entwickeln. Insbesondere Kennzahlen zur Lage der Daten sowie zu ihrer Streuung sind dabei von Interesse. Die hier entwickelten Kennzahlen werden auch als empirische Kennzahlen bezeichnet, da sie auf Basis empirischer Stichproben ermittelt werden.

1.5.1 Lageparameter

Definition 1.25. (Arithmetisches Mittel)

Gegeben sei eine n -elementige Menge $x_1, \dots, x_n$ an Daten eines quantitativen Merkmals. Das arithmetische Mittel bzw. der Mittelwert $\bar{x}$ der Daten ist definiert als:

$$\bar{x} := \frac{x_1 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Liegen klassierte Daten vor, so berechnet man $\bar{x}$, indem man den Mittelwert aus den Klassenmitten bildet.

Alternativ können wir den Mittelwert unter Verwendung der absoluten Häufigkeiten h_i der Merkmalsausprägungen $\tilde{x}_i$ wie folgt schreiben:

$$\bar{x} = \frac{h_1 \tilde{x}_1 + \dots + h_k \tilde{x}_k}{n}$$

Bemerkung 1.26

1. $\min_i x_i \leq \bar{x} \leq \max_i x_i$, d. h. $\bar{x}$ liegt zwischen dem kleinsten und größten Datenelement
2. $\bar{x}$ hat die folgende Schwerpunkteigenschaft

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0$$

d. h. die Summe der Abstände zum Mittelwert ist Null

3. $\bar{x}$ minimiert die quadratischen Abstände zu den Daten wie folgt:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \min_{c \in \mathbb{R}} \left\{ \sum_{i=1}^n (x_i - c)^2 \right\}$$

4. Der Mittelwert wird (insbes. bei kleinen Stichproben) sehr stark von Ausreißern beeinflusst.
5. Im Falle einer n -elementigen Menge klassierter Daten mit Klassen A_i ($i = 1, \dots, k$)

berechnet sich der Mittelwert wie folgt

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k h_i \cdot m_i$$

wobei m_i die Mitte der Klasse A_i und h_i ihre absolute Häufigkeit bezeichnet.

Excel 1.27. (Mittelwert)

Mittels der Funktion MITTELWERT(Zahl1; Zahl2; ...) kann in Excel der Mittelwert aus gegebenen Daten bestimmt werden.

Definition 1.28. (Median = Zentralwert)

Gegeben seien Daten eines quantitativen Merkmals. Wir definieren den Median als 0.5-Quantil, d. h.

$$x_{\text{med}} := x_{0.5}.$$

Der Median x_{med} ist also der Wert, für den mindestens 50 % der Daten darunter und mindestens 50 % der Daten darüber liegen. Der Median ist damit relativ unempfindlich gegenüber Ausreißern.

Bemerkung 1.29

Gegeben sei eine n -elementige Menge $x_1, \dots, x_n$ an Daten eines quantitativen Merkmals X . Wir nehmen an, die Daten seien bereits der Größe nach geordnet, d. h. $x_1 \leq \dots \leq x_n$. Für den Median gilt dann nach Satz 1.18:

$$x_{\text{med}} = \begin{cases} x_{(n+1)/2} & , \text{ für } n \text{ ungerade} \\ x_{n/2} & , \text{ für } n \text{ gerade} \end{cases}$$

Zur Berechnung des Medians für klassierte Daten verweisen wir auf Satz 1.22.

Excel 1.30. (Median)

Mittels der Funktion MEDIAN(Zahl1; Zahl2; ...) kann in Excel der Median aus gegebenen Daten bestimmt werden. **Excel nutzt dabei jedoch nicht die Formel gemäß der letzten Bemerkung, sondern gemäß Bemerkung 1.20!**

Definition 1.31. (Modalwert = häufigster Wert)

Gegeben seien unklassierte Daten eines Merkmals X . Der häufigste Wert oder Modalwert x_{mod} ist diejenige Merkmalsausprägung $\tilde{x}_i$ mit der größten (absoluten oder relativen) Häufigkeit.

Für klassierte Daten definieren wir den Modalwert als die Klasse mit der größten Dichte, d. h. der höchsten Höhe im Histogramm.

Bei klassierten Merkmalen ist der Modalwert nicht unbedingt die Klasse mit der größten Anzahl an Daten, da im Histogramm die Klassenhäufigkeiten noch mit den Klassengrößen gewichtet werden.

Excel 1.32. (Modalwert)


Mittels der Funktion `MODALWERT(Zahl1; Zahl2; ...)` kann in Excel der Modalwert aus gegebenen Daten bestimmt werden.

Beispiel 1.33. (Fortsetzung)

Die Stichprobe von Mathematiknoten von 20 Schülern war gegeben durch:

$\tilde{x}_i$	1	2	3	4	5	6
h_i	3	7	4	3	2	1
f_i	0.15	0.35	0.2	0.15	0.1	0.05
kum. f_i	0.15	0.5	0.7	0.85	0.95	1

Stabdiagramm



Dann gilt

$$\begin{aligned}\bar{x} &= \frac{3 \cdot 1 + 7 \cdot 2 + 4 \cdot 3 + 3 \cdot 4 + 2 \cdot 5 + 1 \cdot 6}{20} \\ &= 2.85\end{aligned}$$

$$x_{\text{med}} = 2$$

$$x_{\text{mod}} = 2$$

Das im Folgenden dargestellte geometrische Mittel ist bei (multiplikativen) Wachstumsprozessen (wie z. B. der Zinsrechnung) wichtig.

Definition 1.34. (Geometrisches Mittel)

Gegeben sei eine n -elementige Menge $x_1, \dots, x_n$ an Daten eines quantitativen Merkmals X .

Sei weiter $x_i > 0$ für $i = 1, \dots, n$. Das geometrische Mittel $\bar{x}_G$ ist definiert als

$$\bar{x}_G := \sqrt[n]{x_1 \cdot \dots \cdot x_n} = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}}$$

Bemerkung 1.35

1. Im Gegensatz zum arithmetischen Mittel, ist das geometrische Mittel nur für Werte $x_i > 0$ definiert.
2. Das geometrische Mittel ist stets kleiner oder gleich dem arithmetischen Mittel, d. h. $\bar{x}_G \leq \bar{x}$.
3. Geometrische Veranschaulichung: Das geometrische Mittel zweier Zahlen a, b liefert die Seitenlänge eines Quadrates, welchen den gleichen Flächeninhalt hat wie das Rechteck mit den Seitenlängen a und b .

Beispiel 1.36

Gegeben sei eine Geldanlage mit folgenden Renditen:

- 1. Jahr = 12 %
- 2. Jahr = -8 %
- 3. Jahr = 5 %

Wie groß ist die durchschnittliche Rendite r über 3 Jahre? Schauen wir uns hierzu die Wertentwicklung der Anlage an. Wir nehmen an, wir hätten zu Beginn des ersten Jahres einen Betrag K_0 investiert, dann ergibt sich folgende Entwicklung:

$$\text{Wert nach 1. Jahr} = K_0(1 + 12\%) = K_0(1 + 0.12) =: K_1$$

$$\text{Wert nach 2. Jahr} = K_1(1 - 8\%) = K_0(1 + 0.12)(1 - 0.08) =: K_2$$

$$\text{Wert nach 3. Jahr} = K_2(1 + 5\%) = K_0(1 + 0.12)(1 - 0.08)(1 + 0.05) =: K_3$$

Für die durchschnittliche Rendite über 3 Jahre gilt $K_3 = K_0(1 + r)^3$, d. h.

$$\begin{aligned} K_0(1 + r)^3 &= K_3 = K_0(1 + 0.12)(1 - 0.08)(1 + 0.05) \quad \text{und damit} \\ (1 + r)^3 &= (1 + 0.12)(1 - 0.08)(1 + 0.05) \end{aligned}$$

Wir erhalten damit $1 + r = 1.0266$, also $r = 2.66$ %. Das ist genau das gerade definierte geometrische Mittel der drei Zinsfaktoren. Der Mittelwert über die drei Renditen liefert hingegen 3 % und ist damit größer.

Das letzte Beispiel zeigt, dass es bei der Zins- und Zinseszinsrechnung durchaus einen Unterschied macht, wenn man statt des richtigen geometrischen Mittels das arithmetische Mittel der Renditen benutzt. Die Diskrepanz wird umso größer, je stärker die einzelnen Renditen voneinander abweichen.

1.5.2 Streuungsparameter

Definition 1.37. (Mittlere Abweichung)

Seien $x_1, \dots, x_n$ Daten eines quantitativen Merkmals X . Die mittlere Abweichung ist definiert als:

$$\frac{\text{Summe der Beträge der Abstände zum Mittelwert}}{\text{Anzahl der Stichprobenwerte}} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Für klassierte Daten berechnen wir die mittlere Abweichung, indem wir jede Klassen durch ihre Mitte ersetzen.

Die mittlere Abweichung ist zwar intuitiv sehr naheliegend, hat aber einige Nachteile. Zum Einen ist das Rechnen mit Beträgen u. U. recht mühsam, zum Anderen ist die Betragsfunktion nicht differenzierbar (an der Stelle 0). Aus diesem Grund nutzt man als Streuungsmaß eher die Standardabweichung (siehe später).

Definition 1.38

Seien $x_1, \dots, x_n$ Daten eines quantitativen Merkmals. Die Spannweite ist definiert als die Differenz des größten und kleinsten Wertes, d. h.

$$\text{Spannweite} := x_{\max} - x_{\min}.$$

wobei $x_{\max} := \max\{x_1, \dots, x_n\}$ und $x_{\min} := \min\{x_1, \dots, x_n\}$. Der Quartilsabstand ist definiert als die Differenz zwischen dem 0.75-Quantil (drittes Quartil) und dem 0.25-Quantil (erstes Quartil), d. h.

$$\text{Quartilsabstand} = x_{0.75} - x_{0.25}$$

Bemerkung 1.39

1. Die Spannweite ist sehr sensitiv gegenüber Ausreißern!
2. Der Quartilsabstand gibt die Länge des Intervalles an, in dem (mind.) 50 % der Daten liegen. Er ist robust gegenüber Ausreißern.

Excel 1.40. (Maximum, Minimum, Spannweite)


Mittels der Funktionen `MAX(Zahl1; Zahl2; ...)` bzw. `MIN(Zahl1; Zahl2; ...)` können in Excel die maximalen bzw. minimalen Elemente aus gegebenen Daten bestimmt werden. Die Spannweite kann einfach als Differenz `MAX(Zahl1; Zahl2; ...) - MIN(Zahl1; Zahl2; ...)` bestimmt werden.

Mittels eines sog. Box-Plots werden die Informationen wie Spannweite, Quartilsabstand und Median graphisch dargestellt. Man zeichnet dabei den minimalen und maximalen Wert als auch den Median sowie eine Box um das erste und dritte Quartil (die Länge der Box ist der Quartilsabstand).

Beispiel 1.41. (Fortsetzung)

Die Stichprobe von Mathematiknoten von 20 Schülern war gegeben durch:


$\tilde{x}_i$	1	2	3	4	5	6
h_i	3	7	4	3	2	1
f_i	0.15	0.35	0.2	0.15	0.1	0.05
kum. f_i	0.15	0.5	0.7	0.85	0.95	1



Es gilt

$$\begin{aligned} \text{Spannweite} &= 6 - 1 \\ \text{Quartilsabstand} &= x_{0.75} - x_{0.25} = 2 \\ \text{Median} = x_{\text{med}} &= 2 \end{aligned}$$

Der Boxplot sieht wie folgt aus (der Median ist rot gekennzeichnet):



In unserem Beispiel fallen Median und erstes Quartil zusammen, dies ist i. A. natürlich nicht der Fall.

Definition 1.42. (Varianz und Standardabweichung)

Seien $x_1, \dots, x_n$ Daten eines quantitativen Merkmals. Die empirische Varianz s_x^2 ist definiert als die durchschnittliche quadratische Abweichung der Daten zum Mittelwert, d. h.

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Die empirische Standardabweichung s_x ist definiert als die Wurzel der empirischen Varianz, d. h.

$$s_x = \sqrt{s_x^2}.$$

Für klassierte Daten berechnen wir Standardabweichung und Varianz, indem wir jede Klasse durch ihre Mitte ersetzen.

Für die Varianz gilt die folgende Formel:

$$\begin{aligned} s_x^2 &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\ &= \frac{1}{n-1} \left(\left(\sum_{i=1}^n x_i^2 \right) - \left(2\bar{x} \sum_{i=1}^n x_i \right) + n\bar{x}^2 \right) \\ &= \frac{1}{n-1} \left(\left(\sum_{i=1}^n x_i^2 \right) - 2\bar{x}n\bar{x} + n\bar{x}^2 \right) \\ &= \frac{1}{n-1} \left(\left(\sum_{i=1}^n x_i^2 \right) - n\bar{x}^2 \right) \end{aligned}$$

Alternativ können wir die Varianz unter Verwendung der absoluten Häufigkeiten h_i der Merkmalsausprägungen $\tilde{x}_i$ wie folgt schreiben:

$$\begin{aligned} s_x^2 &= \frac{1}{n-1} (h_1(\tilde{x}_1 - \bar{x})^2 + \dots + h_k(\tilde{x}_k - \bar{x})^2) \\ &= \frac{1}{n-1} \left(\left(\sum_{i=1}^k h_i \tilde{x}_i^2 \right) - n\bar{x}^2 \right) \end{aligned}$$

Bemerkung 1.43

1. Die Standardabweichung hat die gleiche „Einheit“ oder Dimension wie die Daten $x_1, \dots, x_n$.
2. Es gilt stets $s_x^2 \geq 0$ und $s_x \geq 0$. Des Weiteren ist die mittlere Abweichung stets kleiner gleich der Standardabweichung.
3. Es gilt stets

$$s_x = 0 \iff s_x^2 = 0 \iff x_1 = \dots = x_n$$

Die Varianz bzw. Standardabweichung ist also genau dann Null, wenn alle Daten gleich sind (und damit nicht streuen).

4. Warum teilen wir durch $n-1$ und nicht durch n ? Die Antwort werden wir später kennenlernen. Der Grund ist, dass diese Definition einen erwartungstreuen Schätzer der Varianz liefert.

5. Im Falle einer n -elementigen Menge klassierter Daten mit Klassen A_i ($i = 1, \dots, k$) berechnet sich die empirische Varianz wie folgt

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^k h_i \cdot (m_i - \bar{x})^2 = \frac{1}{n-1} \left(\left(\sum_{i=1}^k h_i \cdot m_i^2 \right) - n \cdot \bar{x}^2 \right)$$

wobei m_i die Mitte der Klasse A_i und h_i ihre absolute Häufigkeit bezeichnet.

6. Die Formel zur Berechnung von s_x^2 ist anfällig für Rundungsfehler (des Mittelwerts $\bar{x}$).

Excel 1.44. (Varianz und Standardabweichung)

Mittels der Funktionen `VARIANZ(Zahl1; Zahl2; ...)` bzw. `STABW(Zahl1; Zahl2; ...)` können in Excel die Varianz bzw. die Standardabweichung aus gegebenen Daten bestimmt werden. Die Standardabweichung kann natürlich ebenfalls als Wurzel der Varianz berechnet werden. Beide Funktionen wurden jedoch in neueren Excel-Versionen ersetzt und nur noch zur Rückwärtskompatibilität beibehalten.

Ab Excel Version 2011 werden die Funktionen `VAR.S(Zahl1; Zahl2; ...)` bzw. `STABW.S(Zahl1; Zahl2; ...)` angeboten: diese stimmen mit unseren Definitionen überein. Zusätzlich werden die Funktionen `VAR.P(Zahl1; Zahl2; ...)` bzw. `STABW.N(Zahl1; Zahl2; ...)` angeboten. **Bei den letzteren beiden Funktionen wird jeweils durch n und nicht durch $n - 1$ geteilt: sie entsprechen damit nicht unseren Definitionen.**

Beispiel 1.45

Die Stichprobe von Mathematiknoten von 20 Schülern war gegeben durch:

$\tilde{x}_i$	1	2	3	4	5	6
h_i	3	7	4	3	2	1

Wir haben bereits weiter oben den Mittelwert berechnet: $\bar{x} = 2.85$. Wir berechnen nun Varianz und Standardabweichung. Es gilt:

$$\begin{aligned} s_x^2 &= \frac{1}{20-1} \left(\left(\sum_{i=1}^6 h_i \tilde{x}_i^2 \right) - n \bar{x}^2 \right) \\ &= \frac{1}{19} (3 \cdot 1^2 + 7 \cdot 2^2 + 4 \cdot 3^2 + 3 \cdot 4^2 + 2 \cdot 5^2 + 1 \cdot 6^2 - 20 \cdot 2.85^2) \\ &= 2.0289 \\ s_x &= \sqrt{2.0289} = 1.4244 \end{aligned}$$

Aufgabe 1.46

Gegeben seien die Preisgelder in Pfund der letzten 24 Monate der TOP 16 Snooker-Spieler.

Name	Preisgeld
Mark Selby	796866
Neil Robertson	758512
Ding Junhui	709077
Ronnie O'Sullivan	507533
Barry Hawkins	461989
Judd Trump	428331
Shaun Murphy	359810
Mark Allen	353760
Marco Fu	332679
Stuart Bingham	325253
Ricky Walden	230893
John Higgins	223322
Stephen Maguire	212630
Joe Perry	208476
Allister Carter	203114
Graeme Dott	176305

Berechne Mittelwert, Standardabweichung und zeichne den Box-Plot.

2 Zweidimensionale Häufigkeitsverteilungen

Im ersten Abschnitt haben wir Daten zu einem einzigen Merkmal untersucht und hierzu einige statistische Werkzeuge entwickelt. Die zugrundeliegenden Häufigkeitsverteilungen waren – da wir nur ein einziges Merkmal untersucht haben – sog. eindimensionale Häufigkeitsverteilungen.

In diesem Abschnitt wollen wir unseren Blick auf zwei Merkmale weiten und sog. zweidimensionale Häufigkeitsverteilungen untersuchen. Wir betrachten von nun an nur noch quantitative Merkmale.

Ein sehr einfaches aber auch sehr schönes Werkzeug zur Untersuchung zweier Merkmale ist das sog. Streudiagramm. Durch das Muster der Punkte können u. U. Zusammenhänge und Abhängigkeiten der Merkmale abgeleitet werden. Dabei ist allerdings Vorsicht geboten, wie wir später sehen werden.


Definition 2.1

Gegeben seien Daten $x_1, \dots, x_n$ und $y_1, \dots, y_n$ zweier Merkmale X und Y . Ein Streudiagramm ist die Darstellung der Punkte (x_i, y_i) für $i = 1, \dots, n$ in der x - y -Ebene.

Beispiel 2.2

Gegeben sei die folgende Stichprobe zweier Merkmale Körpergröße X und Gewicht Y :

Körpergröße in cm	181	185	165	175	174	183
Gewicht in kg	78	94	63	81	71	90



Das Streudiagramm zeigt einen Zusammenhang zwischen den beiden Merkmalen. Die Werkzeuge der folgenden Abschnitte werden uns helfen, diesen mathematisch zu beschreiben.


Excel 2.3. (Streudiagramm)

Zur Erstellung von Streudiagrammen mit Excel verfahren wir wie folgt.

1. Einlesen/Eingabe der Daten. Wir verwenden hier die Daten des letzten Beispiels 2.2.

	A	B	C	D	E	F	G	H	I	J	K
1											
2											
3			Gewicht	Körpergröße							
4			181	78							
5			185	94							
6			165	63							
7			175	81							
8			174	71							
9			183	90							
10											
11											
12											
13											
14											
15											
16											
17											
18											
19											
20											

2. Markieren der Daten und Auswahl von Punkt im Teil Diagramme des Reiters Einfügen.



2.1 Kovarianz und Korrelationskoeffizient

Zur Untersuchung des statistischen Zusammenhangs zwischen zwei Merkmalen ist die Kovarianz ein wesentliches Werkzeug.

Definition 2.4. (Kovarianz)

Gegeben seien Daten $x_1, \dots, x_n$ und $y_1, \dots, y_n$ zweier Merkmale X und Y . Die empirische Kovarianz ist definiert als:

$$s_{xy} := \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Ganz analog zur Formel für die Varianz können wir die Kovarianz auch schreiben als:

$$s_{xy} = \frac{1}{n-1} \left(\left(\sum_{i=1}^n x_i y_i \right) - n \bar{x} \bar{y} \right)$$

Bemerkung 2.5

1. Die Kovarianz ist symmetrisch, d. h. $s_{xy} = s_{yx}$.
2. Natürlich können wir für gegebene Daten $x_1, \dots, x_n$ eines Merkmals X auch die Kova-

rianz s_{xx} mit sich selbst bilden. Dies ergibt aber gerade die Varianz, d. h. $s_{xx} = s_x^2$.

3. Die Formel zur Berechnung von s_{xy} ist anfällig für Rundungsfehler (der Mittelwerte $\bar{x}, \bar{y}$).

Excel 2.6. (Kovarianz)

Ab Excel Version 2011 wird die Funktion `KOVARIANZ.S(Matrix1; Matrix2)` zur Bestimmung der Kovarianz angeboten: diese entspricht unserer Definition. Darüber hinaus wird die Funktion `KOVARIANZ.P(Matrix1; Matrix2)` angeboten: **bei dieser wird jedoch durch n und nicht durch $n - 1$ geteilt; sie entspricht damit nicht unserer Definition.**

Bei älteren Excel-Versionen kann mittels der Funktion `KOVAR(Matrix1; Matrix2)` die Kovarianz aus gegebenen Daten bestimmt werden. **Es ist jedoch zu beachten, dass Excel dabei durch n und nicht durch $n - 1$ teilt! Damit stimmt diese Excel-Funktion nicht mit unserer Definition überein.**

Um die Kovarianz gemäß unserer Definition zu berechnen, muss die Excel-Funktion wie folgt angepasst werden: $n/(n-1) \cdot \text{KOVAR}(\text{Matrix1}; \text{Matrix2})$.

Definition 2.7. (Korrelationskoeffizient)

Der empirische Korrelationskoeffizient von Daten zweier Merkmale X und Y ist definiert als

$$r_{xy} := \frac{s_{xy}}{s_x \cdot s_y}$$

falls $s_x, s_y \neq 0$ gilt.

Bemerkung 2.8

1. Der Korrelationskoeffizient ist symmetrisch, d. h. $r_{xy} = r_{yx}$.

2. Ganz offensichtlich gilt:

$$r_{xx} = \frac{s_{xx}}{s_x \cdot s_x} = \frac{s_x^2}{s_x^2} = 1$$

D. h. der Korrelationskoeffizient von Daten eines Merkmals mit sich selbst ist 1.

3. Wenn $r_{xy} = 0$ gilt, so sagt man, die Merkmale X und Y sind unkorreliert.
4. Sind zwei Merkmale X und Y „unabhängig“ (für eine genaue Definition siehe später), so gilt $r_{xy} = 0$.
5. Die Umkehrung der letzten Bemerkung gilt im Allgemeinen nicht! D. h. aus $r_{xy} = 0$ folgt nicht, dass die Merkmale X und Y unabhängig sind.
6. Ist $r_{xy} = \pm 1$, so sagt man die Merkmale X und Y sind perfekt korreliert.
7. Die Formel zur Berechnung von r_{xy} ist anfällig für Rundungsfehler (der Mittelwerte $\bar{x}, \bar{y}$).

Excel 2.9. (Korrelationskoeffizient)

Mittels der Funktion `KORREL(Matrix1; Matrix2)` kann in Excel der Korrelationskoeffizient aus gegebenen Daten bestimmt werden.

Der Korrelationskoeffizient ist ein Maß für den linearen Zusammenhang zwischen X und Y , wie der folgende wichtige Satz zeigt. Dabei ist es wichtig zu beachten, dass dies nichts über einen ursächlichen Zusammenhang aussagt (wir werden diesen Punkt später noch vertiefen).

Satz 2.10

Der Korrelationskoeffizient r_{xy} von Daten zweier Merkmale X und Y kann Werte zwischen -1 und 1 annehmen. Darüber hinaus gilt:

$$r_{xy} = +1 \iff y_i = a + bx_i \text{ für zwei } a, b \in \mathbb{R} \text{ mit } b > 0$$

$$r_{xy} = -1 \iff y_i = a + bx_i \text{ für zwei } a, b \in \mathbb{R} \text{ mit } b < 0$$

Bemerkung 2.11

1. Im Falle $r_{xy} = \pm 1$ liegen also alle Punkte im Streudiagramm exakt auf einer Geraden.
2. Ist $-1 < r_{xy} < 1$, so liegen die Punkte nicht alle auf einer Geraden.
3. Je stärker r_{xy} an ± 1 liegt, desto stärker ist der lineare Zusammenhang zwischen X und Y .
4. Besteht ein linearer Zusammenhang zwischen zwei Merkmalen X und Y bedeutet dies nicht, dass diese auch kausal verknüpft sind!
5. Ist $r_{xy} = 0$ (bzw. $r_{xy} \approx 0$) bedeutet dies nur, dass kein (bzw. nur ein schwacher) linearer Zusammenhang besteht. Es können aber trotzdem andere (nicht lineare) Zusammenhänge bestehen!
6. Der Wert r_{xy} hat nichts mit der Steigung der Geraden zu tun!

Bemerkung 2.12

Zur Interpretation des Korrelationskoeffizienten r_{xy} , kann folgende Einteilung verwendet werden. Diese ist jedoch eher als Anhaltspunkt und weniger als feste Grenze zu verstehen. Vielmehr kommt es immer auf eine individuelle Einschätzung der Stichprobe an.

$r_{xy} = 0$	kein Zusammenhang
$0 < r_{xy} \leq 0.3$	schwacher Zusammenhang
$0.3 < r_{xy} \leq 0.7$	mittlerer Zusammenhang
$0.7 < r_{xy} < 1$	starker Zusammenhang
$ r_{xy} = 1$	linearer Zusammenhang

Beispiel 2.13. (Fortsetzung)

Gegeben war die folgende Stichprobe zweier Merkmale Körpergröße X und Gewicht Y :

Körpergröße in cm	181	185	165	175	174	183
Gewicht in kg	78	94	63	81	71	90

Es gilt

$$\begin{aligned}
 \bar{x} &= \frac{1063}{6} \approx 177.17 \\
 s_x &= 7.3869 \\
 \bar{y} &= 79.5 \\
 s_y &= 11.5715 \\
 s_{xy} &= \frac{1}{6-1} (181 \cdot 78 + 185 \cdot 94 + 165 \cdot 63 + 175 \cdot 81 + 174 \cdot 71 + 183 \cdot 90 - 6 \cdot \frac{1063}{6} \cdot 79.5) \\
 &= 78.7 \\
 r_{xy} &= \frac{s_{xy}}{s_x \cdot s_y} = 0.9207
 \end{aligned}$$


Wie bereits oben angemerkt, bedeutet eine vorhandene hohe Korrelation zwischen zwei Merkmalen **nicht**, dass diese auch kausal verknüpft sind. Man spricht in solchen Fällen auch von Scheinkorrelationen (oder besser: Scheinkausalität). Diese sind entweder zufällig (Koinzidenz) oder werden durch zusätzliche Variablen (die bekannt oder unbekannt sein können) verursacht, die die Merkmale beeinflussen. Betrachten wir hierzu das folgende Beispiel.

Beispiel 2.14. (Scheinkorrelation)

In der Tabelle ist die Entwicklung der Anzahl der McDonalds-Standorte sowie der Anzahl der Patientenzahlen in deutschen Krankenhäusern von 2005 bis 2012 dargestellt.

Jahr	McDonalds-Standorte	Anzahl Patienten
2005	1.264	16.539.398
2006	1.276	16.832.883
2007	1.302	17.178.573
2008	1.333	17.519.579
2009	1.361	17.817.180
2010	1.386	18.032.903
2011	1.415	18.344.156
2012	1.440	18.620.442

Das zugehörige Streudiagramm hat die folgende Gestalt:



Die Punkte sind nahezu linear verteilt. Dies wird auch durch den Korrelationskoeffizient von $r_{xy} = 0.9954$ sehr deutlich. Trotzdem besteht zwischen diesen beiden Zeitreihen kein inhaltlich kausaler Zusammenhang: Es handelt sich um eine Scheinkorrelation zwischen zwei wachsenden Zeitreihen.


Umgekehrt bedeutet eine nicht vorhandene Korrelation nicht, dass zwischen den Merkmalen kein Zusammenhang besteht, wie das folgende Beispiel zeigt.

Beispiel 2.15

Gegeben seien die folgenden Daten:

Merkmal X	-2	-1	0	1	2
Merkmal Y	4	1	0	1	4

Streudiagramm



Es gilt

$$\begin{aligned}\bar{x} &= 0 \\ \bar{y} &= 2 \\ s_{xy} &= 0\end{aligned}$$

Da $s_{xy} = 0$ folgt, dass $r_{xy} = 0$. Damit sind X und Y also weit davon entfernt, linear zusammenzuhängen. Nichtsdestotrotz besteht ein Zusammenhang zwischen X und Y , nämlich $Y = X^2$.

2.2 Regressionsanalyse

Ziel der Regressionsanalyse ist es, Zusammenhänge zwischen Merkmalen zu untersuchen. Wir beschränken uns in diesem Abschnitt auf den einfachsten Fall eines linearen Zusammenhangs zwischen zwei Merkmalen, man spricht dann auch von linearer Regression.


In Satz 2.10 haben wir gesehen, dass im Falle $r_{xy} = \pm 1$ für zwei Merkmale, diese linear zusammenhängen. Liegt der Korrelationskoeffizient nahe bei ± 1 , so ist der Zusammenhang „fast“ linear. Es stellt sich nun die Frage, wie wir die zugehörige Gerade bestimmen, die bestmöglich zu unseren Daten passt?

Beispiel 2.16. (Fortsetzung)

Gegeben war die folgende Stichprobe zweier Merkmale Körpergröße X und Gewicht Y :

Körpergröße in cm	181	185	165	175	174	183
Gewicht in kg	78	94	63	81	71	90

Ist der Zusammenhang linear? Welche Gerade (grün bzw. grau) beschreibt die Daten am besten?



Seien also $x_1, \dots, x_n$ und $y_1, \dots, y_n$ Daten zweier Merkmale X und Y . Wir suchen eine Ausgleichsgerade durch die Punkte (x_i, y_i) des Streudiagramms. Gemeint ist damit eine Gerade, die am besten durch die Daten „passt“. Sei hierzu $y(x) = a + bx$ eine beliebige Gerade. Wann passt diese Gerade nun zu den Punkten des Streudiagramms? Sie passt „am besten“ zu den Punkten in unserem Streudiagramm, wenn die Abstände zwischen den Punkten und der Gerade minimal sind! Wir wollen also, dass die folgende Summe minimal wird:

$$\sum_{i=1}^n (y(x_i) - y_i)^2 = \sum_{i=1}^n (a + bx_i - y_i)^2 \quad (*)$$

Wir nutzen hier wieder die quadratischen Abweichungen, da die Betragsfunktion nicht differenzierbar und damit weniger schön zum Arbeiten ist.

Wir suchen also das Minimum der folgenden Funktion

$$D(a, b) := \sum_{i=1}^n (y(x_i) - y_i)^2 = \sum_{i=1}^n (a + bx_i - y_i)^2$$

welches mit den aus der Vorlesung *Mathematik 2* bekannten Methoden bestimmt werden kann. Die kritischen Stellen ergeben sich aus den Nullstellen der partiellen Ableitungen:

$$\frac{\partial D}{\partial a} = \sum_{i=1}^n 2(a + bx_i - y_i) \stackrel{!}{=} 0 \quad (1)$$

$$\frac{\partial D}{\partial b} = \sum_{i=1}^n 2(a + bx_i - y_i)x_i \stackrel{!}{=} 0 \quad (2)$$

Als Lösung erhält man schließlich:

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2}$$

$$a = \bar{y} - b\bar{x}$$

Alternativ lässt sich die Ausgleichsgrade $y(x) = a + bx$ auch schreiben als

$$y(x) = \bar{y} + b(x - \bar{x})$$

indem wir a wie oben hergeleitet einsetzen. Die Ausgleichsgerade geht damit durch den Schwerpunkt $(\bar{x}, \bar{y})$.

Satz 2.17. (Regressionsgerade)

Seien $x_1, \dots, x_n$ und $y_1, \dots, y_n$ Daten zweier Merkmale X und Y mit $s_x \neq 0$. Die Parameter $a, b \in \mathbb{R}$ der Ausgleichsgeraden $y = a + bx$ durch die Punkte (x_i, y_i) sind bestimmt durch:

$$\begin{aligned} b &= \frac{s_{xy}}{s_x^2} \\ a &= \bar{y} - b\bar{x} \end{aligned}$$

Bemerkung 2.18

1. Die obige Regressionsgerade wird auch Ausgleichsgerade genannt.
2. Die Formeln zur Berechnung von a und b sind anfällig für Rundungsfehler.
3. Die Abweichungen $\hat{\epsilon}_i = y_i - \hat{y}_i$ (mit $\hat{y}_i = y(x_i) = a + bx_i$) werden als Residuen bezeichnet. Sie sollten bei einer „guten“ Regression „zufällig“ und „gleichartig“ um die Null schwanken und es sollten keine Muster erkennbar sein.
4. Hintergrund der Herleitung der Regressionsgeraden war die Minimierung der Summe der Quadrate der Residuen.
5. Aus (1) folgt, dass die Summe der Residuen $\hat{\epsilon}_i$ gleich Null ist und damit auch ihr Mittelwert. Sprichwörtlich: *„In den Residuen steckt (im Mittel) keine Information mehr.“*
6. Aus (2) folgt, dass der Vektor der Residuen senkrecht auf dem Vektor des Merkmals x steht. Sprichwörtlich: *„Die Residuen und das Merkmal x sind unkorreliert. Die Residuen enthalten nur Information, die nicht von x erklärt werden kann.“*

Wir möchten uns nun noch mit der Güte der linearen Approximation beschäftigen. Man kann die Varianz von y wie folgt zerlegen

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{Variation d. Residuen}} + \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{Variation d. Regressionsmodells}}$$

unter Verwendung von (1) und (2). D. h. die Variation von y setzt sich zusammen aus der Variation der Residuen und die Variation der Regressionswerte. Wir definieren das Bestimmtheitsmaß daher wie folgt.

Definition 2.19. (Bestimmtheitsmaß)

Das Bestimmtheitsmaß eines Regressionsmodells ist definiert als:

$$R^2 := \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Im Falle einer linearen Regression mit nur einem Merkmal vereinfacht sich die Formel des Bestimmtheitsmaßes wie im folgenden Satz dargelegt.

Satz 2.20

Im Falle einer linearen Regression gilt:

$$R^2 = r_{xy}^2$$

Bemerkung 2.21

1. Es gilt $0 \leq R^2 \leq 1$, wobei für $R^2 \approx 1$ die Punkte alle nahezu auf der Regressionsgeraden liegen.
2. R^2 beschreibt den Anteil der Variation der y -Werte, der durch die Regression erklärt werden kann.
3. Ein Bestimmtheitsmaß R^2 nahe 1 bedeutet aber weiterhin nicht, dass ein kausaler Zusammenhang zwischen den Merkmalen besteht bzw. das Prognosemodell qualitativ hochwertig ist (hier ist zusätzliche Experteneinschätzung gefragt). Ebenso bedeutet ein Bestimmtheitsmaß R^2 nahe 0 nicht, dass die Merkmale nicht zusammenhängen.

Schließlich möchten wir uns noch einer wesentlichen Anwendung der Regressionsanalyse zuwenden. Die Regressionsgerade kann nämlich als Prognosemodell genutzt werden, denn sie „beschreibt“ einen Zusammenhang zwischen X und Y (der aber – wie bereits gesehen – keinesfalls kausal begründet sein muss). Für ein gegebenes x kann durch Einsetzen in die Regressionsgerade der zugehörige Wert y ermittelt werden. Derartige Prognosen machen natürlich nur Sinn, wenn der Wert x „in der Nähe“ der gegebenen Daten (auf Basis derer die Regressionsgerade geschätzt wurde) liegt, denn nur dann kann das Modell auch als repräsentativ angesehen werden. Weiter ist es stets wichtig, dass Regressionsmodelle niemals unreflektiert genutzt werden, da – auch bei hohen Korrelationen – die Modelle nicht inhaltlich sinnvoll sein müssen.

Beispiel 2.22. (Fortsetzung)

Gegeben war die folgende Stichprobe zweier Merkmale Körpergröße X und Gewicht Y :

Körpergröße in cm	181	185	165	175	174	183
Gewicht in kg	78	94	63	81	71	90


Weiter oben hatten wir bereits die folgenden Größen berechnet: $\bar{x} = 177.17$, $\bar{y} = 79.5$, $s_x =$

7.3869, $s_{xy} = 78.7$. Nach Satz 2.17 gilt nun für Ausgleichsgerade:

$$b = \frac{s_{xy}}{s_x^2} = 1.4423$$

$$a = \bar{y} - b\bar{x} = -176.0226$$

Die Ausgleichsgerade (grün) ist damit gegeben durch $y = -176.0226 + 1.4423x$.



Prognosemodell


Frage: Welches Gewicht entspricht einer Körpergröße von 170 cm?

Antwort: Einsetzen in die Ausgleichsgerade liefert $y = -176.0226 + 1.4423 \cdot 170 = 69.16$, d. h. rund 69 kg (roter Punkt).



Excel 2.23. (Ausgleichsgerade)

Zur Bestimmung der Ausgleichsgeraden mittels Excel verfahren wir wie folgt (Fortsetzung von Beispiel 2.2).


1. Zuerst erzeugen wir das Streudiagramm.



2. Nach Rechtsklick auf die Datenpunkte wählen wir das Menü **Trendlinie** hinzufügen. Hiernach öffnet sich das Menüfenster **Trendlinie formatieren**.



3. Wir wählen als Trend-/Regressionstyp **Linear** (zu den anderen Typen später mehr). Des Weiteren wählen wir **Formel** im Diagramm anzeigen sowie **Bestimmtheitsmaß** im Diagramm darstellen (quadrierter Korrelationskoeffizient). Hiernach klicken auf **Schließen**.



4. Durch Rechtsklick auf die Formel und Auswahl des Menüpunktes **Trendlinienbeschriftung formatieren** kann diese wie gewünscht formatiert werden (z. B. Anzeige von zusätzlichen Nachkommastellen).

Aufgabe 2.24

Berechne für die folgenden Wertepaare die Ausgleichsgerade sowie den quadrierten Korrelati-

onskoeffizienten. Zeichne die Ausgleichsgerade in das Streudiagramm.

x_i	11	12	13	14	15
y_i	12	14	12	18	24

Wie lautet die Prognose für $x = 11.5$?


Aufgabe 2.25


Für ein Unternehmen wurden folgende Daten für Werbungskosten x_i und Absatz y_i (jeweils in 1000 € je Kunde) erhoben.

x_i	1.0	1.1	1.2	1.5	2.0	2.2	2.5	3.2	4.0	5.0
y_i	200	200	210	260	300	360	400	460	510	620

Wie hoch wäre der Absatz, wenn keinerlei Werbung betrieben wird? Um wie viel steigt der Absatz durchschnittlich, wenn die Werbungskosten um 1000 € steigen?

Im Folgenden noch einige graphische Beispiele zur Korrelation von Merkmalen (inkl. der Ausgleichsgeraden in grün).





3 Lineare Transformation von Daten

Definition 3.1. (Lineare Transformation von Daten)

Gegeben seien Daten $x_1, \dots, x_n$ eines quantitativen Merkmals X . Durch Anwendung einer linearen Funktion $y(x) = a + bx$ mit $a, b \in \mathbb{R}$ entstehen Daten $y(x_1), \dots, y(x_n)$ des linear transformierten quantitativen Merkmals $Y = a + bX$.

Beispiel 3.2

Gegeben seien die folgenden Temperaturdaten um 12 Uhr der letzten 6 Tage:

Tag	1	2	3	4	5	6
Temperatur in °C	12	5	7	-3	4	10
Temperatur in °F	53.6	41	44.6	26.6	39.2	50

Die Umrechnung der Werte von °C in °F (Fahrenheit) ist eine lineare Transformation mit $Y = 32 + 1.8 \cdot X$, wobei X die Temperatur in °C und Y in °F bezeichnet.

Satz 3.3. (Lineare Transformation und Lageparameter)

Gegeben seien Daten $x_1, \dots, x_n$ eines Merkmals X sowie ein linear transformiertes Merkmal $Y = a + bX$. Dann gilt:

$$\begin{aligned}\bar{y} &= a + b\bar{x} \\ y_{\text{mod}} &= a + bx_{\text{mod}}\end{aligned}$$

Bemerkung 3.4

1. Nutzen wir für den Median die alternative Definition aus Bemerkung 1.20, so transformiert sich auch dieser entsprechend. Es gilt dann:

$$y_{\text{med}} = a + bx_{\text{med}}$$

2. Das geometrische Mittel transformiert sich nicht entsprechend!

Satz 3.5. (Lineare Transformation und Streuungsparameter)

Gegeben seien Daten $x_1, \dots, x_n$ eines quantitativen Merkmals X sowie ein linear transformiertes Merkmal $Y = a + bX$. Dann gilt:

$$s_y = |b|s_x$$

Ganz analog transformieren sich die mittlere Abweichung, Spannweite sowie der Quartilsabstand.

Bemerkung 3.6

Nach dem letzten Satz gilt für die Varianz $s_y^2 = b^2 s_x^2$.

Beispiel 3.7. (Fortsetzung)

Gegeben waren die folgenden Temperaturdaten um 12 Uhr der letzten 6 Tage:

Tag	1	2	3	4	5	6
Temperatur in °C	12	5	7	-3	4	10
Temperatur in °F	53.6	41	44.6	26.6	39.2	50

Sei X die Temperatur in °C und Y in °F, dann ist $Y = 32 + 1.8 \cdot X$. Es gilt:

$$\bar{y} = 32 + 1.8 \cdot \bar{x} = 42.5$$

$$s_y = 1.8 \cdot s_x = 9.4849$$

Aufgabe 3.8

Vervollständige die folgende Tabelle:

	x_i	$5 + x_i$	$3x_i$	$55 + 2x_i$	$-2x_i$
	5				
	7				
	9				
	12				
	15				
Mittelwert					
Varianz					
Standardabweichung					
Spannweite					

Satz 3.9. (Lineare Transformation und Kovarianz bzw. Korrelation)

Gegeben seien Daten $x_1, \dots, x_n$ und $y_1, \dots, y_n$ zweier quantitativer Merkmale X und Y sowie linear transformierter Merkmale $U = a + bX$ und $V = c + dY$. Dann gilt:

$$s_{uv} = bds_{xy}$$

$$r_{uv} = \begin{cases} r_{xy} & , b \text{ und } d \text{ haben das gleiche Vorzeichen} \\ -r_{xy} & , b \text{ und } d \text{ haben unterschiedliche Vorzeichen} \end{cases}$$

Bemerkung 3.10

Der Korrelationskoeffizient zweier linear transformierter Merkmale bleibt also (bis auf Vorzeichen) erhalten und damit auch die Stärke des linearen Zusammenhangs. Die Koeffizienten der Ausgleichsgerade der transformierten Merkmale kann einfach mittels Satz 2.17 bestimmt werden.



Beispiel 3.11. (Fortsetzung)

Gegeben war die folgende Stichprobe zweier Merkmale Körpergröße X und Gewicht Y :

Körpergröße in cm	181	185	165	175	174	183
Gewicht in kg	78	94	63	81	71	90

Wir wollen diese nun in die englische Maßeinheiten foot (ft.) und stone (st.) umrechnen. Es gilt $1 \text{ ft.} = 0.3048 \text{ m}$ bzw. $1 \text{ st.} = 6.35 \text{ kg}$. Wir betrachten damit zwei neue Merkmale: $U = \frac{1}{30.48} \cdot X$ und $V = \frac{1}{6.35} \cdot Y$.

Körpergröße in ft.	5.94	6.07	5.41	5.74	5.71	6.00
Gewicht in st.	12.28	14.80	9.92	12.76	11.18	14.17



Für die Ausgleichsgerade in englischen Maßeinheiten gilt dann:

$$b' = \frac{s_{uv}}{s_u^2} = \frac{\frac{1}{30.48} \cdot \frac{1}{6.35} \cdot s_{xy}}{\left(\frac{1}{30.48}\right)^2 s_x^2} = 4.8 \cdot 1.4423 = 6.9229$$

$$a' = \bar{v} - b'\bar{u} = \frac{1}{6.35}\bar{y} - b'\frac{1}{30.48}\bar{x} = -27.7200$$


und damit $y' = -27.7200 + 6.9229x$.

Oftmals können wir mittels linearer Transformationen auch numerische Rechenprobleme einfach umgehen, wie das folgende Beispiel zeigt.

Beispiel 3.12

Gegeben seien die folgenden Daten zum Umsatz eines Automobilkonzerns der letzten Jahre:

Jahr	2008	2009	2010	2011	2012	2013	2014
Umsatz in Mrd. €	125	165	168	190	240	257	?



Frage: Wie ist der prognostizierte Umsatz für 2014?

Antwort: Sei X das Jahr und Y der Umsatz im jeweiligen Jahr. Der Korrelationskoeffizient beträgt $r_{xy} = 0.98$, der Zusammenhang ist also annähernd linear. Die Regressionsgerade lautet:

$$y = -51909.8381 + 25.9142x$$

Der Prognosewert für 2014 beträgt mithin (einsetzen in die Regressionsgerade) 281.5 Mrd. €.

Frage: Ist dieses Ergebnis numerisch stabil? Wir runden hierzu die Koeffizienten der Regressionsgeraden auf 2 Stellen, d. h. $y = -51909.84 + 25.91x$, und setzen das gesuchte Jahr 2014 erneut ein. Wir erhalten dann $y = 272.9$, d. h. nur einen Umsatz von 272.4 Mrd. €!

Lösung: Folgende einfache lineare Transformation stabilisiert und vereinfacht das Problem enorm: $U := X - 2008$, d. h. wir normieren das erste Jahr auf 0. Unsere Daten sehen dann wie folgt aus:

Jahr	0	1	2	3	4	5	6
Umsatz in Mrd. €	125	165	168	190	240	257	?

Die Regressionsgerade lautet dann:


$$y = 126.0476 + 25.9143x$$

Rechnen wir nun mit gerundeten Koeffizienten (diesmal nur eine Nachkommastelle!), so erhalten wir für das 6. Jahr $126.0 + 25.9 \cdot 6 = 281.4$ und damit fast das exakte Ergebnis von 281.5 Mrd. €, jedoch mit deutlich weniger numerischem Aufwand.

4 Regression - weiterführende Aspekte


Wir haben uns im Abschnitt 2.2 mit der sog. linearen Regression beschäftigt. Unsere Untersuchung zum Korrelationskoeffizienten hatten uns zur Erkenntnis gelangen lassen, dass ein Korrelationskoeffizient nahe ± 1 zwischen zwei Merkmalen X und Y auf einen linearen Zusammenhang hindeutet (der aber nicht notwendigerweise auch kausal sein muss). Hierzu hatten wir bereits einige Beispiele untersucht.

Beispiel Gewicht/Körpergröße



$$r_{xy} = 0.9207$$

Beispiel Umsatz/Jahr




$$r_{xy} = 0.9767$$

Den Nutzen von linearen Regressionen hatten wir bereits bei Prognosemodellen kennengelernt. Mittels der Regressions- oder Ausgleichsgeraden konnten wir Vorhersagen für die Merkmalsausprägung des einen Merkmals bei gegebener Ausprägung des anderen Merkmals machen (vgl. hierzu auch die obigen Beispiele - rote Punkte). Regressionsmodelle sind deshalb in der Praxis ein sehr wichtiges und nützliches Werkzeug.

In diesem Abschnitt wollen wir kurz über den Tellerrand der linearen Regressionen hinaus schauen (man spricht dabei auch von nicht-linearer Regression), denn der Zusammenhang zwischen zwei Merkmalen X und Y muss natürlich nicht unbedingt linear sein. Wir wollen uns hierzu einige Beispiele anschauen.

In den folgenden Graphiken versuchen wir die Daten des Streudiagramms mit einer Reihe

verschiedener Regressionen anzupassen (bspw. durch Polynome verschiedener Grade oder durch Exponential-, Logarithmus- bzw. Potenzfunktionen).



Die einzelnen Funktionen sind gegeben durch:

Typ	Regressionsgleichung
Linear	$0.746x + 0.7964$
Grad 2	$-0.0996x^2 + 1.9237x - 2.1019$
Grad 3	$0.0213x^3 - 0.4619x^2 + 3.7562x - 4.7626$
Grad 4	$0.0138x^4 - 0.2992x^3 + 2.1165x^2 - 4.5706x + 4.0701$
Grad 5	$0.002604x^5 - 0.061085x^4 + 0.516584x^3 - 2.047712x^2 + 5.270464x - 4.382542$
Grad 6	$-0.001679x^6 + 0.063404x^5 - 0.941992x^4 + 7.008854x^3 - 27.504482x^2 + 55.117755x - 41.937478$
Exponentiell	$1.5138 \exp^{0.1901x}$
Logarithmisch	$3.9423 \ln(x) - 1.3980$
Potenz	$0.7754x^{1.0703}$

Für alle Regression haben wir das Bestimmtheitsmaß R^2 mit angegeben (für die lineare Regression entspricht dies einfach dem bekannten r_{xy}^2), es liegt stets zwischen 0 und 1. Je näher das Bestimmtheitsmaß an 1 liegt, desto besser passt die Regression an die gegebenen Daten. Liegt das Bestimmtheitsmaß in der Nähe von 0, so passt die Regressionskurve nicht zu den Daten des Streudiagramms.

Welche Regression sollte wir im obigen Beispiel wählen? Naiv würde man denken, dass die Regression mit dem größten Bestimmtheitsmaß die Beste ist (also das Polynom mit Grad 6). Wenn wir uns die Regression mit Grad 6 genauer anschauen, stellen wir fest, dass diese einige „Wellen“ besitzt und sich deshalb besonders gut an die Daten anpasst. Dies liegt an den vielen freien Parametern für ein Polynom vom Grad 6 (nämlich 7): es besteht dabei die Gefahr des „overfitting“ (Überanpassung), d. h. wir bauen zu viele Parameter ein und machen das Regressionsmodell zu komplex (wir benötigen dann darüber hinaus eine hohe numerische Genauigkeit).

Bemerkung 4.1


Bei der Wahl der passenden Regression sollte Folgendes beachtet werden:

- Gibt es einen logischen Zusammenhang zwischen den Merkmalen (bspw. linear, quadratisch oder exponentiell), dann sollte dieser als Regressionsmodell gewählt werden.
- Ein einfaches Modell ist bei qualitativ gleichwertiger Anpassungsgüte einem komplexeren i. d. R. vorzuziehen.
- Die optische Anpassungsgüte der Regression sollte beurteilt werden.


Excel 4.2. (Regression)

Die oben dargestellten Regressionen können mit Excel wie folgt bestimmt werden.

1. Eingabe/Einlesen der Daten und Erstellung eines Streudiagramms.



2. Nach Rechtsklick auf die Datenpunkte wählen wir das Menü Trendlinie hinzufügen. Hiernach öffnet sich das Menüfenster Trendlinie formatieren.



3. Wahl des gewünschten Regressionstyps. Excel bietet – sofern zu den Daten passend – die folgenden Auswahlmöglichkeiten: Exponentiell, Linear, Logarithmisch, Polynomisch, Potenz, Gleitender Durchschnitt. Mittels Formel im Diagramm anzeigen, kann die Formel des Regressionstyps angezeigt werden.

Teil III

Wahrscheinlichkeitsrechnung

1 Grundlagen

1.1 Kombinatorik

Definition 1.1. (Fakultät)

Sei $n \in \mathbb{N}_0$ (natürliche Zahlen inklusive der Null). Wir definieren $n!$ (sprich „ n Fakultät“) als das Produkt aller natürlichen Zahlen von 1 bis n , d. h.

$$n! := 1 \cdot 2 \cdot \dots \cdot (n-1) \cdot n.$$

Darüber hinaus definieren wir $0! := 1$.

Beispiel 1.2

$$5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120, \quad 10! = 10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 3628800$$

Bemerkung 1.3

1. $n!$ wächst sehr schnell, bereits bei $70!$ kommt unser Taschenrechner an seine Grenzen.
2. Für große n kann zur näherungsweisen Bestimmung von $n!$ die folgende Formel von Stirling verwendet werden

$$\lg(n!) \approx \frac{1}{2} \lg(2\pi n) + n \lg\left(\frac{n}{e}\right)$$

wobei $\lg$ den Logarithmus zur Basis 10 bezeichne.

Satz 1.4. (Anzahl Permutationen)

Für n Objekte gibt es $n!$ verschiedene Möglichkeiten, diese anzuordnen. Man nennt diese verschiedenen Anordnungen der gegebenen n Objekte auch Permutationen.

Aufgabe 1.5

1. Wie viele verschiedene Möglichkeiten gibt es, die Buchstaben A, B, C anzuordnen. Berechne die Anzahl und gib alle Anordnungen an.
2. Wie viele verschiedene (!) Buchstabenfolgen kann man aus dem Wort MISSISSIPPI bilden?

Definition 1.6. (Binomialkoeffizient)

Seien $n \in \mathbb{N}$ und $k \in \mathbb{Z}$ gegeben. Wir definieren den Binomialkoeffizient $\binom{n}{k}$ (sprich „ n über

k “) durch :

$$\binom{n}{k} := \frac{n!}{k! \cdot (n-k)!} \quad \text{für } 0 \leq k \leq n$$

$$\binom{n}{k} := 0 \quad \text{für } k < 0 \text{ bzw. } k > n$$

Man sieht leicht, dass $\binom{n}{0} = \binom{n}{n} = 1$ gilt.

Aufgabe 1.7

Berechne die folgenden Binomialkoeffizienten:

$$\begin{array}{ccccccccc} \binom{0}{0} & & & & & & & & \\ \binom{1}{0} & \binom{1}{1} & & & & & & & \\ \binom{2}{0} & \binom{2}{1} & \binom{2}{2} & & & & & & \\ \binom{3}{0} & \binom{3}{1} & \binom{3}{2} & \binom{3}{3} & & & & & \\ \binom{4}{0} & \binom{4}{1} & \binom{4}{2} & \binom{4}{3} & \binom{4}{4} & & & & \end{array}$$

Für das Rechnen mit Binomialkoeffizienten kann der folgende Satz genutzt werden.

Satz 1.8. (Pascalsches Dreieck)

Es gilt

$$\binom{n}{k} + \binom{n}{k+1} = \binom{n+1}{k+1} \quad \text{und} \quad \binom{n}{k} = \binom{n}{n-k}$$

Aufgabe 1.9. (Fortsetzung)

Berechne die Binomialkoeffizienten aus Aufgabe 1.7 mittels der Formel des letzten Satzes.

Der folgende Satz zeigt eine schöne Anwendung der Binomialkoeffizienten.

Satz 1.10. (Binomische Formel)

Seien $a, b \in \mathbb{R}$ und $n \in \mathbb{N}$, dann gilt:

$$(a+b)^n = \sum_{i=0}^n \binom{n}{i} a^i b^{n-i}$$

Aufgabe 1.11

Multipliziere die folgenden Ausdrücke aus.

1. $(a+b)^2$

2. $(a + b)^3$

3. $(a + b)^4$

4. $(a + b)^5$

Eine wesentliche Anwendung der Binomialkoeffizienten gibt es beim Ziehen von Kugeln aus einer Urne. Wir betrachten hierzu eine Urne mit n verschiedenen Kugeln (z. B. sind alle Kugeln durchnummeriert oder haben verschiedene Farben, um sie unterscheidbar zu machen). Wir ziehen aus der Urne nacheinander k Kugeln. Beim Ziehen gibt es zwei mögliche Verfahrensweisen: entweder legen wir die gezogene Kugel zurück oder nicht. Darüber hinaus können wir beim Ziehen der k Kugeln deren Reihenfolge beachten oder außer Acht lassen.

Beispiel 1.12

Wir ziehen zwei Kugeln aus einer Urne mit drei nummerierten Kugeln. Wie viele Möglichkeiten gibt es?

1. mit Zurücklegen

(a) mit Beachtung der Reihenfolge: (1,1), (1,2), (1,3), (2,1), (2,2), (2,3), (3,1), (3,2), (3,3)

(b) ohne Beachtung der Reihenfolge: (1, 1), (1, 2), (1, 3), (2, 2), (2, 3), (3, 3)

2. ohne Zurücklegen

(a) mit Beachtung der Reihenfolge: (1, 2), (1, 3), (2, 1), (2, 3), (3, 1), (3, 2)

(b) ohne Beachtung der Reihenfolge: (1, 2), (1, 3), (2, 3)

Der folgende Satz beschreibt die Möglichkeiten beim Ziehen von Kugeln aus einer Urne im Allgemeinen.

Satz 1.13. (Ziehen aus einer Urne)

Gegeben sei eine Urne mit n verschiedenen Kugeln. Für das Ziehen von k Kugeln gibt es die folgende Anzahl an Möglichkeiten:

	mit Reihenfolge	ohne Reihenfolge
mit Zurücklegen	n^k	$\binom{n+k-1}{k}$
ohne Zurücklegen	$\frac{n!}{(n-k)!}$	$\binom{n}{k}$

Aufgabe 1.14

1. Wie viele Möglichkeiten gibt es beim „6 aus 49“?

2. Ein Fußballkader bestehe aus 15 Spielern. Wie viele mögliche Aufstellungen gibt es?

3. Eine Zeitschrift testet 20 Fahrräder in den Kategorien Verarbeitung, Gewicht und Design und listet dann pro Kategorie den Gewinner. Wie viele verschiedene Ausgänge gibt es insgesamt?
4. Der Code eines Autoradios wird vierstellig mit den Ziffern 0 bis 9 eingegeben. Wir haben leider den Code vergessen. Wie viele Möglichkeiten gibt es?
5. Fortsetzung der letzten Aufgabe: Wir erinnern uns, dass der Code nicht aus lauter verschiedenen Ziffern bestand. Wie viele Möglichkeiten gibt es nun? (Hinweis: Wie viele Kombinationen erfüllen diese Bedingung nicht?)

Aufgabe 1.15

Eine Gruppe von 30 Personen soll in 3 Teilgruppen zu je 10 Personen eingeteilt werden. Wie viele Möglichkeiten gibt es hierfür?

Aufgabe 1.16

Wie viele Kombinationen von 4 Tanzpaaren Dame/Herr lassen sich aus

- (a) 4 Damen und 4 Herren,
- (b) 6 Damen und 8 Herren

bilden?

1.2 Mengenlehre

Wir wollen uns in diesem Abschnitt mit einigen Grundbegriffen der Mengenlehre beschäftigen. Diese benötigen wir später als Basis für die Wahrscheinlichkeitsrechnung.

Definition 1.17. (Menge)

Unter einer Menge verstehen wir die Zusammenfassung unterscheidbarer Elemente zu einer Gesamtheit.

Wir bezeichnen Mengen i. d. R. mit Großbuchstaben $A, B, \dots$ und ihre Elemente mit Kleinbuchstaben $a, b, \dots$. Ist a ein Element der Menge A , so schreiben wir $a \in A$ ansonsten $a \notin A$. Listen wir die Elemente einer Menge auf, so schreiben wir diese in geschweifte Klammern.

In der Welt der Mengen gibt es eine besondere Menge, nämlich die Menge ohne Elemente $\{\}$: wir bezeichnen sie als leere Menge und schreiben $\emptyset$.

Beispiel 1.18

Beispiele für Mengen sind:

- $\mathbb{N}, \mathbb{Z}, \mathbb{Q}, \mathbb{R}, \mathbb{C}$
- $A = \{\text{blau, rot, gelb}\}$
- $B = \{1, 2, 3, 4, 5, 6\} \subset \mathbb{N}$ – Ergebnisse beim Würfeln
- $C = \{\text{Zahl, Kopf}\}$ – Ergebnisse eines Münzwurfes
- ...

Definition 1.19

Seien A und B zwei Mengen. Wie definieren:

- Gleichheit $A = B : \Longleftrightarrow$ falls A und B die gleichen Elemente besitzen
- Teilmenge $A \subset B : \Longleftrightarrow$ falls alle Elemente von A auch Elemente von B sind
In diesem Falle bezeichnen wir A als Teilmenge von B bzw. B als Obermenge von A .
- Kardinalität $|A| :=$ Zahl der Elemente von A

Bemerkung 1.20

Die Kardinalität (oft auch als Mächtigkeit bezeichnet) ist entweder endlich oder unendlich, d. h.


$$|A| \in \mathbb{N}_0 \quad \text{oder} \quad |A| = \infty .$$

Definition 1.21. (Operationen für Mengen)

Seien A und B zwei Mengen. Wir definieren die folgenden Operationen:

- Vereinigung $A \cup B :=$ Menge aller Elemente, die zu A oder B oder beiden gehören
- Schnitt $A \cap B :=$ Menge aller Elemente, die sowohl zu A als auch zu B gehören
- Differenz $A \setminus B :=$ Menge aller Elemente, die zu A aber nicht zu B gehören

Zur anschaulichen Darstellung von Mengenoperationen benutzt man oft sog. Venn-Diagramme. Diese sind im Folgenden für die oben definierten Mengenoperationen dargestellt.



Aufgabe 1.22

Gegeben sei die Menge der Ergebnisse beim Würfeln $\Omega = \{1, 2, 3, 4, 5, 6\}$. Wir definieren folgende Teilmengen: A = Menge aller ungerade Zahlen beim Würfeln, B = Menge aller Zahlen größer gleich 3 beim Würfeln. Bilde $A \cup B$, $A \cap B$ und $A \setminus B$.

Definition 1.23. (Kartesisches Produkt)

Seien A und B zwei Mengen. Wir definieren das kartesische Produkt $A \times B$ wie folgt:

$$A \times B := \{(a, b) : a \in A, b \in B\}$$

Das kartesische Produkt ist somit nichts anderes als die Menge aller möglichen Paare von Elementen aus A mit Elementen aus B .

Bemerkung 1.24

- Wir definieren $A^2 := A \times A$.
- Gegeben sei eine beliebige Anzahl an Mengen $A_1, A_2, \dots, A_n$, dann definieren wir $A_1 \times A_2 \times \dots \times A_n$ rekursiv analog zur obigen Definition, d. h.:

$$A_1 \times A_2 \times \dots \times A_n := \{(a_1, a_2, \dots, a_n) : a_1 \in A_1, a_2 \in A_2, \dots, a_n \in A_n\}$$

Aufgabe 1.25

Gib die Menge der Ergebnisse beim zweimaligen Würfeln an und stelle diese graphisch dar. Bilde folgende Teilmengen: A = Menge aller Ergebnisse, deren Summe 7 ist; B = Menge aller Ergebnisse, deren Summe 3 ist.

1.3 Axiome der Wahrscheinlichkeitsrechnung

Definition 1.26. (Zufallsexperiment und Ergebnismenge)

Ein Zufallsexperiment ist ein Versuch, der unter genau festgelegten Bedingungen durchgeführt wird, einen zufälligen Ausgang hat und beliebig oft wiederholbar ist. Als Versuch verstehen wir dabei einen Vorgang, bei dem mehrere (sich ausschließende) Ergebnisse (sog. Elementarereignisse oder Realisierungen) eintreten können, die nicht vorhersagbar sind. Die Menge aller möglichen Ergebnisse heißt Ergebnismenge (oder Ergebnisraum) und wird üblicherweise mit Ω bezeichnet.

Aufgabe 1.27

Begründe, dass es sich bei den folgenden Experimenten um Zufallsexperimente handelt und gib die Ergebnismenge Ω sowie deren Kardinalität an.

1. Würfeln mit einem Würfel

2. 2-maliges Würfeln mit einem Würfel
3. Ziehung der Lottozahlen
4. Münzwurf
5. Anzahl Blitzeinschläge pro Jahr im Großraum Stuttgart
6. Anzahl der Ausschussteile einer tägl. Produktionsmenge

Definition 1.28. (Ereignis)

Eine Teilmenge $A \subset \Omega$ heißt Ereignis. Ist das Ergebnis eines Zufallsexperimentes ein Element von A , so sagen wir, dass Ereignis A ist eingetreten. Hierbei gibt es folgende Spezialfälle:

- $A = \emptyset$ – unmögliches Ereignis (tritt nie ein)
- $A = \Omega$ – sicheres Ereignis (tritt immer ein)

Definition 1.29. (Disjunkte Ereignisse)

Zwei Ereignisse $A, B \subset \Omega$ heißen disjunkt oder unvereinbar, falls $A \cap B = \emptyset$.

Aufgabe 1.30

1. Gib jeweils zwei disjunkte bzw. nicht disjunkte Ereignisse beim einmaligen Werfen eines Würfels an.
2. Wir ziehen eine Kugel aus einer Urne mit 3 nummerierten Kugeln. Gib alle Elementarereignisse an. Gib darüber hinaus alle Ereignisse an.


Bemerkung 1.31. (Ereignisalgebra)

Wir können die Mengenoperationen des letzten Abschnittes auf Ereignisse anwenden und erhalten so neue Ereignisse. Seien $A, B \subset \Omega$, so gilt:

- $A \cup B$ – Ereignis A oder Ereignis B tritt ein oder beide gleichzeitig
- $A \cap B$ – Ereignisse A und B treten gleichzeitig ein
- $A^C := \Omega \setminus A$ – Ereignis A tritt nicht ein

Die hier beschriebenen Operationen geben der Ergebnismenge Ω eine algebraische Struktur (auch σ -Algebra genannt).

Die letzte Operation A^C – auch Komplement genannt –, kann ebenfalls mittels eines Venn-Diagramms wie folgt dargestellt werden.



Aufgabe 1.32

Wir betrachten das einmalige Werfen eines Würfels. Gib die folgenden Mengen an:

1. Ω
2. A = gerade Zahl
3. B = ungerade Zahl
4. C = Zahl mind. 2
5. D = Zahl mind. 4

Berechne alle möglichen Mengenoperationen der letzten Bemerkung mit den Mengen A, B, C und D .

Wir haben uns bis jetzt mit Ereignissen von Zufallsexperimenten beschäftigt. Nun widmen wir uns der Frage nach der Wahrscheinlichkeit von Ereignissen. Hier kommen sog. Wahrscheinlichkeitsmaße ins Spiel. Mittels eines Wahrscheinlichkeitsmaßes P wird jedem Ereignis $A \subset \Omega$ eine Wahrscheinlichkeit $0 \leq P(A) \leq 1$ zugeordnet. Eine Funktion heißt Wahrscheinlichkeitsmaß, wenn für sie die folgenden Axiome gelten.

Definition 1.33. (Axiome der Wahrscheinlichkeitsrechnung)

Eine Funktion P , die jedem Ereignis A eine Wahrscheinlichkeit $P(A)$ zuordnet, heißt Wahrscheinlichkeitsmaß, wenn die folgenden Axiome gelten:

- (I) Für jedes Ereignis $A \subset \Omega$ gilt $0 \leq P(A) \leq 1$.
- (II) Für das sichere Ereignis Ω gilt $P(\Omega) = 1$.
- (III) Für disjunkte Ereignisse A und B gilt $P(A \cup B) = P(A) + P(B)$.

Aus diesen Axiomen ergeben sich die nachstehenden Folgerungen.

- (I') Für das unmögliche Ereignis gilt $P(\emptyset) = 0$.
- (II') Für ein Ereignis $A \subset \Omega$ gilt $P(A^C) = 1 - P(A)$.

(III') Für zwei Ereignisse $A, B \subset \Omega$ gilt $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Aufgabe 1.34

Weise nach, dass die Folgerungen (I')-(III') gelten.

Bemerkung 1.35

Das Paar (Ω, P) wird auch Wahrscheinlichkeitsraum genannt. Wir werden in den folgenden Kapiteln einige Beispiele für Wahrscheinlichkeitsräume kennenlernen. Wir gehen von nun an stets davon aus, dass ein Wahrscheinlichkeitsraum (Ω, P) gegeben ist und P somit die Axiome der Wahrscheinlichkeitsrechnung 1.33 erfüllt.

Definition 1.36. (relative Häufigkeit)

Sei A ein Ereignis eines Zufallsexperiments. Führen wir das Zufallsexperiment n -mal durch und tritt dabei das Ereignis A k -mal ein, so definieren wir die relative Häufigkeit von A wie folgt:

$$h_n(A) = \frac{k}{n}$$

Die relative Häufigkeit $h_n(A)$ basiert also auf einer konkreten Stichprobe und hängt damit vom Zufall ab. Die Wahrscheinlichkeit $P(A)$ hingegen ist ein theoretischer Wert, der die eigentliche Durchführung des Zufallsexperiments nicht erfordert. Im Allgemeinen gilt:

$$h_n(A) \neq P(A)$$

Große praktische Bedeutung hat in diesem Zusammenhang das Gesetz der großen Zahlen.

Satz 1.37. (Gesetz der großen Zahlen)

Ein Zufallsexperiment werde n -mal unabhängig und identisch wiederholt, dann gilt

$$\lim_{n \rightarrow \infty} P(|h_n(A) - P(A)| < \varepsilon) = 1$$

für alle $\varepsilon > 0$.

Bemerkung 1.38

1. Grob gesprochen folgt aus dem Gesetz der großen Zahlen, dass es für große n immer wahrscheinlicher wird, dass $h_n(A)$ in der Nähe von $P(A)$ liegt (d. h. $h_n(A) \approx P(A)$).
2. Auf Basis des Gesetzes der großen Zahlen kann damit $P(A)$ (falls der konkrete Wert unbekannt ist) durch die relative Häufigkeit geschätzt werden. Die Schätzung wird umso besser sein, je größer n ist.

2 Laplace-Experiment

Wir beschäftigen uns im Folgenden mit sog. Laplace Experimenten.

Definition 2.1. (Laplace Experiment)

Ein Zufallsexperiment heißt Laplace Experiment, wenn es endlich viele Elementarereignisse gibt, die alle gleich wahrscheinlich sind.

Beispiel 2.2

Einige Beispiele für Laplace Experimente:

- Würfeln mit einem fairen Würfel
- Werfen einer fairen Münze
- Drehen eines Glücksrads
- ...

Einige Beispiele für Experimente, die keine Laplace Experimente sind:

- Ziehen aus einer Urne mit 3 roten und 10 schwarzen Kugeln (mit Elementarereignissen: rot, schwarz)
- Würfeln mit einem gezinkten Würfel
- Funktionskontrolle eines gefertigten Bauteils
- ...

Bemerkung 2.3

Das Würfeln mit einem Würfel bzw. das Werfen einer Münze ist natürlich nur dann ein Laplace Experiment, wenn der Würfel bzw. die Münze fair und nicht gezinkt sind. Im Folgenden werden wir dies stets voraussetzen.

Im nächsten Satz lernen wir ein erstes Wahrscheinlichkeitsmaß kennen.

Satz 2.4. (Satz von Laplace)

Sei Ω der Ereignisraum eines Laplace Experiments und sei $A \subset \Omega$ ein Ereignis, dann gilt:

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{Anzahl der Elementarereignisse in } A}{\text{Anzahl aller möglichen Elementarereignisse}}$$

Die Funktion P ist ein Wahrscheinlichkeitsmaß auf dem Ereignisraum Ω des Laplace Experiments. Es gelten mithin die Axiome der Wahrscheinlichkeitsrechnung.

Aufgabe 2.5

Eine faire Münze (Kopf/Zahl) wird dreimal geworfen. Gib die Ergebnismenge Ω sowie die Anzahl der Elementarereignisse an. Bestimme darüber hinaus die Wahrscheinlichkeit folgender Ereignisse:

- A = genau einmal Kopf
- B = mindestens einmal Zahl
- C = öfter Zahl als Kopf

Aufgabe 2.6

Eine faire Münze (Kopf/Zahl) wird zehnmal geworfen. Gib die Anzahl der Elementarereignisse an. Bestimme darüber hinaus die Wahrscheinlichkeit folgender Ereignisse:

- A = genau einmal Kopf
- B = mindestens dreimal Zahl
- C = gleich oft Zahl und Kopf

Aufgabe 2.7

Ein Würfel wird zweimal geworfen. Sei X die Augenzahl des ersten und Y die Augenzahl des zweiten Wurfes. Bestimme die Wahrscheinlichkeit folgender Ereignisse

- $A = (X = Y)$
- $B = (X + Y > 8)$
- $C = (X + Y)$ ist gerade

Welche Ereignisse sind paarweise disjunkt. Berechne darüber hinaus die Wahrscheinlichkeit der Ereignisse $A \cap B$, $A \cup B$, $B \setminus A$, B^C , $A \cap C$ und $A \cup C$.

Aufgabe 2.8

In einem Fahrradständer, der 12 Fahrrädern in einer Reihe angeordnet Platz bietet, stehen genau 2 Kinder-, 3 Damen- und 5 Herrenfahrräder. Unter der Annahme, dass jede Verteilung der Fahrräder auf die 12 Plätze die gleiche Wahrscheinlichkeit hat, bestimme man die Wahrscheinlichkeit dafür, dass

1. Platz 1 leer bleibt,
2. die Plätze 1 und 2 mit Herrenrädern besetzt sind,
3. die Plätze 1 und 2 mit Kinderrädern und die Plätze 8 bis 12 mit Herrenrädern besetzt sind,

4. die Plätze 1 und 2 leer bleiben und die Plätze 3, 5, 7, 9, 11 mit Herrenrädern besetzt sind.

3 Unabhängige Ereignisse

Definition 3.1. (Unabhängige Ereignisse)

Gegeben seien zwei Ereignisse $A, B \subset \Omega$. A und B heißen unabhängig, falls gilt:

$$P(A \cap B) = P(A) \cdot P(B)$$

Die zwei Ereignisse A und B heißen abhängig, wenn sie nicht unabhängig sind.

Sind A und B unabhängig, so können wir schreiben

$$P(A) = \frac{P(A \cap B)}{P(B)} \quad \text{bzw.} \quad P(B) = \frac{P(A \cap B)}{P(A)}.$$

Anschaulich heißt dies Folgendes. Nehmen wir an, Ereignis B tritt ein. Wie groß ist dann die Wahrscheinlichkeit, dass Ereignis A auch eintritt (damit tritt insgesamt $A \cap B$ ein)? Gemäß obiger Formel ist dies weiterhin $P(A)$, d. h. das Eintreten von B hat uns keine zusätzliche Information über das Eintreten von A geliefert. Ganz analog können wir für B argumentieren; dies begründet die Bezeichnung Unabhängigkeit.

Beispiel 3.2

Wir würfeln einmal. Sei $B = \{2, 4, 6\}$, d. h. der Wurf ist gerade. Sei weiter $A = \{2\}$, so gilt:

$$\begin{aligned} P(A) &= \frac{1}{6} \\ P(B) &= \frac{3}{6} \\ P(A \cap B) &= P(A) = \frac{1}{6} \neq P(A) \cdot P(B) \end{aligned}$$

Damit sind A und B nicht unabhängig. Der Grund ist einfach: Ereignis A alleine hat Wahrscheinlichkeit $\frac{1}{6}$. Wissen wir jedoch, dass gleichzeitig B eintritt (also der Wurf gerade ist), so reduziert sich die Anzahl der möglichen Ausgänge auf 2, 4 und 6. Damit ist die Wahrscheinlichkeit von A (vorausgesetzt, dass B eintritt) bereits $\frac{1}{3}$. Die beiden Ereignisse A und B sind also nicht unabhängig.

Das letzte Beispiel zeigt anschaulich, worum es sich bei der Abhängigkeit von Ereignissen handelt. Das Eintreten von B erlaubt quasi eine bessere Vorhersage von A , als wenn man keine zusätzliche Information hat. Bei unabhängigen Ereignissen ist dies nicht der Fall: Das Eintreten von B ändert die Wahrscheinlichkeit für A (unter der Bedingung, dass B eintritt) nicht.

Beispiel 3.3

Gegeben sei eine Urne mit 2 roten und 3 grünen Kugeln. Wir ziehen zwei Kugeln und betrachten folgende Ereignisse: A = erste Kugel ist grün, B = zweite Kugel ist grün.

(I) Ziehen mit Zurücklegen:

Dann gilt:

$$P(A \cap B) = \frac{3}{5} \cdot \frac{3}{5} = P(A) \cdot P(B)$$

D. h. die Ereignisse A und B sind unabhängig. Dies ist aufgrund der Konstellation durch Zurücklegen klar. Da immer die gleich Anzahl an grünen Kugeln vorhanden ist, sind die beiden Züge unabhängig.

2. Ziehen ohne Zurücklegen:

Dann gilt:

$$P(A \cap B) = \frac{3}{5} \cdot \frac{2}{4}$$

Weiter gilt natürlich $P(A) = \frac{3}{5}$. Wie berechnet man $P(B)$? Hier haben wir zwei Möglichkeiten: Entweder ziehen wir die Folge rot, grün (mit Wahrscheinlichkeit $\frac{2}{5} \cdot \frac{3}{4}$) oder grün, grün (mit Wahrscheinlichkeit $\frac{3}{5} \cdot \frac{2}{4}$). Damit gilt $P(B) = \frac{2}{5} \cdot \frac{3}{4} + \frac{3}{5} \cdot \frac{2}{4} = \frac{3}{5}$. Insgesamt also

$$P(A \cap B) \neq P(A) \cdot P(B)$$

d. h. A und B sind nicht unabhängig. Dies ist intuitiv klar: das nicht Zurücklegen der ersten grünen Kugel reduziert die Wahrscheinlichkeit eine zweite grüne Kugel zu ziehen.

Das letzte Beispiel zeigt, dass beim Ziehen mit Zurücklegen die Unabhängigkeit zwischen erstem und zweiten Zug gewahrt bleibt, beim Ziehen ohne Zurücklegen hingegen nicht.

Aufgabe 3.4

Mit einem Würfel wird zweimal gewürfelt. Welche der folgenden Ereignisse sind jeweils unabhängig?

- A = erster Wurf gerade
- B = zweiter Wurf gerade
- C = erster Wurf kleiner als zweiter Wurf

Aufgabe 3.5

Wir betrachten das Samstags-Lotto. Sind die folgenden Ereignisse unabhängig?

- A = erste Kugel gerade
- B = zweite Kugel gerade

4 Bedingte Wahrscheinlichkeit

Wir wollen in diesem Abschnitt den Begriff der bedingten Wahrscheinlichkeit einführen. Betrachten wir hierzu das folgende einfache Beispiel: Es wurden 500 Männer und 1500 Frauen befragt, ob sie eine Uhr tragen. Die folgende Tabelle zeigt das Ergebnis:

	Uhr	keine Uhr	Σ
Männer	300	200	500
Frauen	1000	500	1500
Σ	1300	700	2000

In Anteilen an der Gesamtstichprobe von 2000 Befragten, ergibt sich folgende Tabelle:

	Uhr	keine Uhr	Σ
Männer	15 %	10 %	25 %
Frauen	50 %	25 %	75 %
Σ	65 %	35 %	100 %

Schauen wir uns die Anteile nach Geschlechtern (links) bzw. für das Merkmal Uhr/keine Uhr an, so ergibt sich (gerundet auf ganze Prozent):

	Uhr	keine Uhr	Σ		Uhr	keine Uhr
Männer	60 %	40 %	100 %	Männer	23 %	29 %
Frauen	67 %	33 %	100 %	Frauen	77 %	71 %
				Σ	100 %	100 %

Wir wollen nun die folgenden Fragen beantworten. Dabei werden wir die Begriffe Anteil und Wahrscheinlichkeit zur Vereinfachung identifizieren.

1. Wie groß ist der Anteil der Männer unter den Personen, die eine Uhr tragen? Der Mathematiker schreibt hierfür $P(\text{Mann} | \text{Uhr})$ und meint den Anteil dafür, dass es sich um einen Mann handelt, gegeben die Tatsache, dass die befragte Person eine Uhr trägt. Aus der letzten Tabelle (rechts) können wir ableiten, dass

$$P(\text{Mann} | \text{Uhr}) = 0.23$$

gilt. Wie können wir dies berechnen? Es gilt

$$P(\text{Mann} | \text{Uhr}) = \frac{P(\text{Mann} \cap \text{Uhr})}{P(\text{Uhr})} = \frac{0.15}{0.65}.$$

2. Wie groß ist der Anteil Uhrenträger unter den Frauen? Aus der letzten Tabelle (links) können wir ableiten, dass

$$P(\text{Uhr} | \text{Frau}) = 0.67 = \frac{P(\text{Uhr} \cap \text{Frau})}{P(\text{Frau})} = \frac{0.5}{0.75}$$

gilt.

Die Beobachtungen des letzten Beispiels führen uns zur Definition bedingter Wahrscheinlichkeiten.

Definition 4.1. (Bedingte Wahrscheinlichkeit)

Gegeben seien zwei Ereignisse $A, B \subset \Omega$ mit $P(B) \neq 0$. Wir definieren die bedingte Wahrscheinlichkeit $P(A|B)$ (sprich „Wahrscheinlichkeit von A gegeben B “) durch:

$$P(A|B) := \frac{P(A \cap B)}{P(B)}$$

Beispiel 4.2. (Fortsetzung)

Wir gehen nochmal zu Beispiel 3.3 zurück. Gegeben war eine Urne mit 2 roten und 3 grünen Kugeln. Wir ziehen nun zwei Kugeln ohne Zurücklegen und betrachten folgende Ereignisse: A = erste Kugel ist grün, B = zweite Kugel ist grün. Es gilt

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{\frac{3}{5} \cdot \frac{2}{4}}{\frac{3}{5}} = \frac{2}{4}$$

Auch dies ist intuitiv klar: Ist der erste Zug eine grüne Kugel, bleiben beim zweiten Zug nur noch zwei grüne unter den vier restlichen Kugeln. Damit ist die Wahrscheinlichkeit $\frac{2}{4}$.

Aufgabe 4.3

Die folgende Tabelle zeigt Männer und Frauen einer Firma, unterteilt in Raucher und Nichtraucher.

	Raucher	Nichtraucher	Σ
Männer	800	200	1000
Frauen	200	300	500
Σ	1000	500	1500

1. Berechne die Wahrscheinlichkeit, dass eine Person raucht.
2. Berechne die Wahrscheinlichkeit, dass eine Person eine Frau ist.
3. Berechne die Wahrscheinlichkeit, dass eine Person eine Raucherin ist.
4. Wir treffen ein Frau, mit welcher Wahrscheinlichkeit ist sie Raucherin?
5. Sind die Ereignisse A = Raucher und B = Frau unabhängig?

Aufgabe 4.4

Viele Internetbenutzer klagen über Spam-Mails. Nehmen wir an, in 1 % der guten Mails und in 40 % der Spam-Mails kommt das Wort „Sonderangebot“ vor. Außerdem seien 10 % der Mails gut und 90 % seien Spam-Mails. Wie groß ist die Wahrscheinlichkeit, dass eine Mail, in der das Wort „Sonderangebot“ vorkommt, eine Spam-Mail ist?

Aufgabe 4.5

Ein Lostopf enthalte 7 Nieten und 3 Gewinne. Es werden zufällig 3 Lose gezogen und es ist bekannt, dass sich unter diesen 3 Losen ein Gewinn befindet. Wie groß ist die Wahrscheinlichkeit, dass die beiden anderen Lose Nieten sind?

Folgender Satz für die bedingte Wahrscheinlichkeit unabhängiger Ereignisse folgt direkt aus der Definition unabhängiger Ereignisse (für diese gilt $P(A \cap B) = P(A) \cdot P(B)$) sowie der Definition bedingter Wahrscheinlichkeiten.

Satz 4.6

Seien $A, B \subset \Omega$ unabhängige Ereignisse, dann gilt:

$$P(A|B) = P(A)$$

Seien $A, B \subset \Omega$ abhängige Ereignisse, dann gilt:

$$P(A|B) \neq P(A)$$

Inhaltlich hatten wir uns schon im Rahmen der Definition unabhängiger Ereignisse damit beschäftigt: Sind zwei Ereignisse A und B unabhängig, liefert das Eintreten des einen Ereignisses keine (zusätzliche) Information über die Wahrscheinlichkeit des Eintretens des anderen Ereignisses. Genau dies sagt der letzte Satz im Falle unabhängiger Ereignisse.

Aufgabe 4.7

Wir betrachten 2 Würfel. Berechne die bedingten Wahrscheinlichkeiten in allen Kombinationen der Ereignisse:

- A = erster Wurf ist gerade
- B = zweiter Wurf ist gerade
- C = erster Wurf zeigt kleinere Zahl als zweiter Wurf

Durch Umformen der Definition bedingter Wahrscheinlichkeiten folgt der nächste Satz.

Satz 4.8. (Multiplikationssatz)

Seien $A, B \subset \Omega$ zwei Ereignisse, so gilt:

$$P(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

Bemerkung 4.9

Ein mehrstufiges Zufallsexperiment (bspw. mehrfaches Ziehen aus einer Urne) kann anhand eines Wahrscheinlichkeitsbaumes (der alle möglichen Ergebnisse als Pfade sowie die (bedingten) Wahrscheinlichkeiten an den Kanten enthält) dargestellt werden. Für Wahrscheinlichkeitsbäume gilt:

1. *Pfadregel*: Die Wahrscheinlichkeit eines Pfades ist gleich dem Produkt der Wahrscheinlichkeiten (an den Kanten) entlang des Pfades.
2. *Summenregel*: Die Wahrscheinlichkeit eines Ereignisses, welches aus mehreren Pfaden besteht, erhält man durch Addition der Wahrscheinlichkeiten der einzelnen Pfade.

Aufgabe 4.10

Von 15 Glühlampen sind 10 in Ordnung und 5 haben einen Defekt. Wie wahrscheinlich ist es, bei 3 zufällig ausgewählten Glühlampen,

1. dass genau 3 Defekte dabei sind?
2. dass genau 2 in Ordnung sind?
3. dass genau eine in Ordnung ist?
4. dass keine defekt ist?

Entwickle einen Wahrscheinlichkeitsbaum aller möglichen Ergebnisse beim Ziehen von 3 Glühlampen und beantworte auf dieser Basis die obigen Fragen.

Aufgabe 4.11

Eine Urne enthält eine weiße, zwei rote und drei grüne Kugeln. Man zieht eine dieser Kugeln und legt diese in eine zweite Urne, in der sich anfänglich zwei rote und zwei grüne Kugeln befinden. Hiernach zieht man eine Kugel aus der zweiten Urne. Wie groß ist die Wahrscheinlichkeit,

1. dass die zweite gezogene Kugel rot ist?
2. dass die zweite gezogene Kugel grün ist?
3. dass die zweite gezogene Kugel weiß ist?

Satz 4.12. (Satz von der totalen Wahrscheinlichkeit)

Sei $A \subset \Omega$ ein Ereignis. Weiter sei eine Zerlegung des Ergebnisraumes wie folgt gegeben $\Omega = B_1 \cup B_2 \cup \dots \cup B_n$ wobei die B_i paarweise disjunkt sind, d. h. $B_i \cap B_j = \emptyset$ für $i \neq j$. Dann gilt:

$$P(A) = P(B_1) \cdot P(A|B_1) + P(B_2) \cdot P(A|B_2) + \dots + P(B_n) \cdot P(A|B_n)$$

Für den Spezialfall $\Omega = B \cup B^C$ gilt:

$$P(A) = P(B) \cdot P(A|B) + P(B^C) \cdot P(A|B^C)$$

Bemerkung 4.13

Der Inhalt des letzten Satzes ist intuitiv klar. Betrachten wir den Spezialfall $\Omega = B \cup B^C$. Die Wahrscheinlichkeit von A ergibt sich gemäß Satz als Summe der

- Wahrscheinlichkeit, dass A eintritt gegeben B , multipliziert mit der Wahrscheinlichkeit von B und der
- Wahrscheinlichkeit, dass A eintritt gegeben B^C , multipliziert mit der Wahrscheinlichkeit von B^C .

Aufgabe 4.14

In einer Fabrik werden auf vier Maschinen Glühlampen produziert. Die Anteile an der Gesamtproduktion sowie der Ausschussanteil pro Maschine sind wie folgt:

- Maschine A: 20 % Anteil an Gesamtproduktion, Ausschussanteil 2 %
- Maschine B: 50 % Anteil an Gesamtproduktion, Ausschussanteil 4 %
- Maschine C: 20 % Anteil an Gesamtproduktion, Ausschussanteil 6 %
- Maschine D: 10 % Anteil an Gesamtproduktion, Ausschussanteil 5 %

Wie groß ist die Wahrscheinlichkeit, dass eine zufällig ausgewählte Glühlampe der Produktion kaputt ist?

Mittels des Satzes 4.12 der totalen Wahrscheinlichkeit, ergibt sich der Satz von Bayes.

Satz 4.15. (Satz von Bayes)

Seien $A, B \subset \Omega$ zwei Ereignisse mit $P(B) > 0$. Dann gilt:

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)} = \frac{P(A) \cdot P(B|A)}{P(A) \cdot P(B|A) + P(A^C) \cdot P(B|A^C)}$$

Aufgabe 4.16. (Fortsetzung)

Wir kommen zurück zur vorherigen Aufgabe. Eine zufällig ausgewählte Glühbirne erweist sich als defekt. Wie groß ist die Wahrscheinlichkeit, dass sie von Maschine A (bzw. Maschine B, C, D) produziert wurde?

Aufgabe 4.17

Ein Labortest zur Diagnose einer Krankheit liefert bei Gesunden und Kranken jeweils in 95 % der Fälle eine korrekte Diagnose, wobei die Krankheit sehr selten ist (durchschnittlich ist nur einer von Hunderttausend krank). Angenommen wir unterziehen uns einem Test und die Diagnose lautet: „Krank“. Wie groß ist die Wahrscheinlichkeit, dass wir tatsächlich krank sind?

Aufgabe 4.18

Eine Produktion werde von 2 Kontrolleuren mit den Anteilen 30 % und 70 % sortiert. Die Wahrscheinlichkeit für eine Fehlentscheidung sei beim ersten Kontrolleur 0.03 und beim zweiten Kontrolleur 0.05.

Beim Versand wird ein fehlerhaft sortiertes Teil gefunden. Wie groß ist die Wahrscheinlichkeit, dass

1. es vom ersten oder
2. vom zweiten Kontrolleur sortiert wurde?

Wie groß ist die Wahrscheinlichkeit, dass ein zufällig ausgewähltes Teil richtig einsortiert wurde.

5 Zufallsvariablen

Definition 5.1. (Zufallsvariable)

Gegeben sei ein Wahrscheinlichkeitsraum (Ω, P) . Eine Zufallsvariable X ist eine Abbildung, die jedem Elementarereignis aus Ω eine reelle Zahl zuordnet.

Beispiel 5.2

Beispiele für Zufallsvariablen sind:

- Summe der Augenzahl beim Werfen von 3 Würfeln
- Anzahl der defekten Bauteile in einer Stichprobe
- Anzahl der Münzwürfe, bis erstmalig Kopf geworfen wird
- Füllmenge von maschinell abgefüllten Flaschen

Für eine gegebene Zufallsvariable X können wir fragen, welche Wahrscheinlichkeit gewisse Ausprägungen der Zufallsvariablen haben. Sei hierzu bspw. ein $a \in \mathbb{R}$ gegeben. Unter $P(X = a)$

verstehen wir die Wahrscheinlichkeit aller Elementarereignisse ω mit $X(\omega) = a$, d. h.

$$P(X = a) = P(\{\omega : X(\omega) = a\}) .$$

Ganz analog ist bspw. $P(X \in [a, b])$ für ein Intervall $[a, b] \subset \mathbb{R}$ definiert usw.

Beispiel 5.3

Sei X die Summe der Augenzahl beim Werfen von 3 Würfeln. Typische Fragestellungen können sein:

- $P(X = 3)$ – Wahrscheinlichkeit, dass die Summe 3 ist
- $P(X \geq 5)$ – Wahrscheinlichkeit, dass die Summe größer oder gleich 5 ist
- $P(4 \leq X \leq 10)$ – Wahrscheinlichkeit, dass die Summe größer gleich 4 und kleiner gleich 10 ist
- ...

Definition 5.4. (Unabhängigkeit von Zufallsvariablen)

Gegeben seien zwei Zufallsvariable X und Y . Die beiden Zufallsvariablen heißen unabhängig, falls gilt

$$P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B)$$

für alle $A, B \subset \mathbb{R}$. Die Zufallsvariablen X und Y heißen abhängig, wenn sie nicht unabhängig sind.

Diese Definition folgt der Definition der Unabhängigkeit zweier Ereignisse, die wir bereits kennengelernt haben.

Beispiel 5.5

Beispiele für unabhängige Zufallsvariablen:

- Würfeln mit 2 Würfeln: X = Augenzahl des ersten Würfels, Y = Augenzahl des zweiten Würfels
- n -maliges Ziehen mit Zurücklegen: X_i = Ergebnis der i -ten Ziehung

Beispiele für abhängige Zufallsvariablen:

- Würfeln mit 2 Würfeln: X = maximale Augenzahl der beiden Würfe, Y = Summe der Augenzahlen beider Würfel
- n -maliges Ziehen ohne Zurücklegen: X_i = Ergebnis der i -ten Ziehung

Aufgabe 5.6

Weise nach, dass die beiden Zufallsvariablen X und Y im ersten Beispiel für abhängige Zufallsvariablen (siehe Beispiel 5.5) tatsächlich abhängig sind. Betrachte hierzu $A = \{3\}$ und $B = \{5\}$, d. h. Maximum der beiden Würfe gleich 3 und Augensumme gleich 5.

5.1 Diskrete Zufallsvariable

Definition 5.7. (Diskrete Zufallsvariable)

Eine Zufallsvariable X wird diskret genannt, wenn sie nur endlich viele oder abzählbar unendlich viele Werte (d. h. nummerierbar mit Zahlen aus $\mathbb{N}$) annimmt.

Für eine diskrete Zufallsvariable gibt es also eine Folge $(x_i)_{i \in \mathbb{N}}$, die ihre Funktionswerte bzw. Ausprägungen vollständig aufzählt. Es gilt dann

$$\sum_{i=1}^{\infty} P(X = x_i) = 1$$

Definition 5.8. (Wahrscheinlichkeitsfunktion)

Sei X eine diskrete Zufallsvariable und seien $(x_i)_{i \in \mathbb{N}}$ ihre Ausprägungen. Wir definieren die Wahrscheinlichkeitsfunktion p_X wie folgt:

$$p_X(x) := \begin{cases} P(X = x_i) & , \text{ für } x = x_i \\ 0 & , \text{ sonst} \end{cases}$$

Für die Wahrscheinlichkeitsfunktion gilt natürlich:

$$\sum_{x_i} p_X(x_i) = 1$$

Bemerkung 5.9

Die Wahrscheinlichkeitsfunktion p_X wird auch Dichte der Zufallsvariable X genannt. Ihre graphische Darstellung erfolgt mittels eines Stabdiagramms. Hierbei werden Balken der Höhe $p_X(x_i) = P(X = x_i)$ über den x_i abgetragen.

Beispiel 5.10. (Diskrete Zufallsvariable)

1. Würfeln mit einem Laplace-Würfel mit der Zufallsvariablen X -gewürfelte Augenzahl. Es gilt

$$\sum_{i=1}^6 P(X = i) = \sum_{i=1}^6 \frac{1}{6} = 1 .$$

2. Würfeln mit einem Laplace-Würfel mit der Zufallsvariablen Y -Anzahl der Versuche bis eine ungerade Augenzahl fällt. Die Zufallsvariable Y nimmt abzählbar unendlich viele

Werte an, denn jede Wurfanzahl aus $\mathbb{N}$ ist potentiell möglich. Es gilt

$$P(Y = k) = \frac{1}{2^{k-1}} \cdot \frac{1}{2},$$

d. h. $k - 1$ mal wird eine gerade Zahl 2, 4, 6 geworfen (mit Wahrscheinlichkeit $\frac{3}{6} = \frac{1}{2}$) und im k -ten Wurf schließlich eine ungerade Zahl 1, 3, 5 (ebenfalls mit Wahrscheinlichkeit $\frac{1}{2}$), also:

$$\sum_{k=1}^{\infty} P(Y = k) = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{16} + \dots = 1$$



Definition 5.11. (Verteilungsfunktion einer diskreten Zufallsvariablen)

Sei X eine diskrete Zufallsvariable und seien $(x_i)_{i \in \mathbb{N}}$ ihre Ausprägungen. Die Verteilungsfunktion F_X der Zufallsvariable X ist wie folgt definiert:

$$F_X(x) := P(X \leq x) = \sum_{x_i \leq x} P(X = x_i) = \sum_{x_i \leq x} p_X(x_i)$$

Beispiel 5.12. (Fortsetzung)

Für die Zufallsvariable X aus dem letzten Beispiel gilt:



Aufgabe 5.13

1. Zeichne die Verteilungsfunktion der Zufallsvariablen Y aus Beispiel 5.10.
2. Berechne die folgenden Wahrscheinlichkeiten:
 - $P(Y \text{ ist gerade})$
 - $P(Y \in [1, 5])$
 - $P(Y \in [6, \infty))$

5.2 Stetige Zufallsvariable

Im letzten Abschnitt hatten wir uns mit diskreten Zufallsvariablen beschäftigt. Diese konnten nur endlich viele oder abzählbar unendlich viele Ausprägungen annehmen. Für viele praktische Beispiele benötigen wir jedoch Zufallsvariablen, die beliebige Ausprägungen in den reellen Zahlen bzw. einer Teilmenge der reellen Zahlen haben können. Betrachten wir z. B. die Zufallsvariable X -Länge eines Nagels einer Produktionseinheit. Dann kann X ein ganzes Intervall $[a, b]$ der reellen Zahlen abdecken, ist also nicht abzählbar. Wir benötigen also eine Erweiterung, die über diskrete Zufallsvariable hinausgeht.

Eine diskrete Zufallsvariable X hatte folgende schöne Eigenschaft: Es gab eine Wahrscheinlichkeitsfunktion (Dichte) $p_X(x)$, deren Funktionswerte sich zu 1 summierten, d. h.

$$\sum_{x_i} p_X(x_i) = 1 .$$

Wir wollen dies nun für die Definition stetiger Zufallsvariablen analog fordern. Das stetige Äquivalent zur Summe ist dabei das Integral.

Definition 5.14. (Stetige Zufallsvariable)

Eine Zufallsvariable X wird stetig genannt, wenn es eine nicht-negative Funktion $f_X \geq 0$ mit

$$\int_{-\infty}^{\infty} f_X(x) \, dx = 1$$


gibt, so dass für alle $a, b \in \mathbb{R} \cup \{-\infty, \infty\}$ mit $a \leq b$ gilt:

$$P(X \in [a, b]) = P(a \leq X \leq b) = \int_a^b f_X(x) \, dx$$

Die Funktion f wird auch Dichtefunktion (kurz: Dichte) der Zufallsvariable X genannt.

Beispiel 5.15

Die Körpergröße einer zufällig ausgewählten erwachsenen Person ist eine stetige Zufallsvariable. Für Frauen und Männer ist die Dichte wie folgt gegeben. Es handelt sich dabei jeweils um eine Normalverteilung, die wir in einem späteren Abschnitt noch genauer untersuchen werden.



Bemerkung 5.16

- Die Dichte einer stetigen Zufallsvariablen ist das Pendant zur Wahrscheinlichkeitsfunktion einer diskreten Zufallsvariablen.
- Im Gegensatz zu einer diskreten Zufallsvariable gilt für eine stetige Zufallsvariable X :

$$P(X = x) = \int_x^x f_X(u) du = 0$$

D. h. die Wahrscheinlichkeit, dass ein bestimmter Wert x angenommen wird ist 0.

- Die Dichte einer stetigen Zufallsvariablen ist das Pendant zum Histogramm für stetig klassierte Daten. Erheben wir immer mehr Daten und machen die Klassenbreite der Klassierung immer kleiner, so approximieren wir die Dichte immer besser.

Aufgrund der letzten Bemerkung ist es bei einer stetigen Zufallsvariablen X völlig unerheblich, ob wir Intervalle mit oder ohne Intervallgrenzen betrachten. Es gilt für $a, b \in \mathbb{R}$ mit $a \leq b$:

$$P(X \in [a, b]) = P(X \in (a, b]) = P(X \in [a, b)) = P(X \in (a, b))$$

Wir werden diese Tatsache von nun an stets benutzen: geben wir Wahrscheinlichkeiten für ein Intervall an, so können die Intervallgrenzen mit ein- oder ausgeschlossen werden. Das Ergebnis ändert sich dadurch nicht.

Definition 5.17. (Verteilungsfunktion einer stetigen Zufallsvariable)

Sei X eine stetige Zufallsvariable mit Dichtefunktion f_X . Die Verteilungsfunktion F_X der Verteilung X ist wie folgt definiert:

$$F_X(x) := P(X \leq x) = \int_{-\infty}^x f_X(u) du$$

Satz 5.18

Sei X eine stetige Zufallsvariable mit Dichte f_X und Verteilungsfunktion F_X . Sei weiter $[a, b] \in \mathbb{R}$, so gilt:

$$P(X \in [a, b]) = P(a \leq X \leq b) = F_X(b) - F_X(a)$$

Satz 5.19

Sei X eine stetige Zufallsvariable mit Dichte f_X und Verteilungsfunktion F_X . Es gilt

$$f_X(x) = F'_X(x)$$

an den Stellen, an denen die Verteilungsfunktion differenzierbar ist.

Aufgabe 5.20

Gegeben sei die Dichte der Zufallsvariable X_1 wie folgt:

$$f_{X_1}(x) = \begin{cases} 0 & , \text{ für } x < 1 \\ 3(x-1)^2 & , \text{ für } 1 \leq x \leq 2 \\ 0 & , \text{ für } x > 2 \end{cases}$$

Bestimme die Verteilungsfunktion F_{X_1} und skizziere diese. Bestimme weiterhin $P(X_1 \in [1.5, 2])$.

Aufgabe 5.21

Gegeben sei die Verteilungsfunktion der Zufallsvariable X_2 wie folgt:

$$F_{X_2}(x) = \begin{cases} 0 & , \text{ für } x < 1 \\ \frac{1}{3}(x^2 - 1) & , \text{ für } 1 \leq x \leq 2 \\ 1 & , \text{ für } x > 2 \end{cases}$$

Bestimme die Dichte f_{X_2} und skizziere diese. Bestimme weiterhin $P(X_2 \in [1, 1.5])$.

Die Definition von Quantilen für diskrete und stetige Zufallsvariable ist analog zur Definition im Kapitel Beschreibende Statistik.

Definition 5.22. (Quantil)

Sei X eine Zufallsvariable (diskret oder stetig) und sei $p \in (0, 1)$. Das p -Quantil – bezeichnet mit x_p – ist derjenige Wert, für den gilt

$$x_p = \inf\{x \in \mathbb{R} : F_X(x) \geq p\}$$

Definition 5.23. (Quantilfunktion)

Sei X eine Zufallsvariable (diskret oder stetig) mit der Verteilungsfunktion F_X . Die Quantilfunktion F_X^{-1} von X ist definiert durch

$$F_X^{-1}(p) = x_p$$

für $p \in (0, 1)$.

Bereits im Kapitel Beschreibende Statistik hatten wir folgende spezielle Quantile kennengelernt:

- $x_{0.5}$ nennt man Median
- $x_{0.25}, x_{0.5}$ und $x_{0.75}$ nennt man erstes, zweites und drittes Quartil
- $x_{0.01}, x_{0.02}, x_{0.03}, \dots$ nennt man erstes, zweites, drittes, ... Perzentil

Bemerkung 5.24

Das Quantil x_p ist also der Wert, für den p % der Wahrscheinlichkeitsmasse unter x_p und $(1 - p)$ % über x_p liegen.

5.3 Symmetrische Zufallsvariable

Definition 5.25. (Symmetrische Zufallsvariable)

Sei X eine Zufallsvariable. X heißt symmetrisch, falls es ein $c \in \mathbb{R}$ gibt, so dass für alle $d \in \mathbb{R}$ gilt:

- für X diskret:

$$P(X = c - d) = P(X = c + d)$$

- für X stetig:

$$f_X(c - d) = f_X(c + d)$$

Bemerkung 5.26

- Ist die Zufallsvariable X symmetrisch, so ist die Symmetrieachse durch $x = c$ gegeben.
- Sei μ der Erwartungswert einer symmetrischen Zufallsvariablen (Definition siehe nächster Abschnitt), so ist die Symmetrieachse durch $x = \mu$ gegeben.
- Anschaulich gilt für eine stetige symmetrische Zufallsvariable, dass die Wahrscheinlichkeit in der Nähe von $\mu + d$ zu landen genauso groß ist, wie die Wahrscheinlichkeit in der Nähe von $\mu - d$ zu landen.


Beispiel 5.27

Wir hatten bereits weiter oben ein Beispiel für eine symmetrische stetige Zufallsvariable ken-


nengelernt: die Körpergröße von Frauen bzw. Männern. Die Symmetrieachse lag bei 167 bzw. 181 cm.

Hier noch zwei Beispiele für symmetrische und asymmetrische Zufallsvariable.

Symmetrische Zufallsvariable



Asymmetrische Zufallsvariable



6 Erwartungswert einer Zufallsvariablen

Definition 6.1. (Erwartungswert)

Sei X eine diskrete Zufallsvariable mit Ausprägungen $(x_i)_{i \in \mathbb{N}}$ und Wahrscheinlichkeitsfunktion p_X . Wir definieren den Erwartungswert $E(X)$ von X wie folgt:

$$E(X) := \sum_{i=1}^{\infty} x_i \cdot p_X(x_i)$$

Sei X eine stetige Zufallsvariable mit Dichte f_X . Wir definieren den Erwartungswert $E(X)$ von X wie folgt:

$$E(X) := \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

Beispiel 6.2

Die Zufallsvariable $X = 1$ bildet jedes Elementarereignis auf die natürliche Zahle 1 ab. Für ihren Erwartungswert gilt mithin

$$E(1) = 1 \cdot P(X = 1) = 1 \cdot P(1 = 1) = 1 \cdot 1 = 1.$$

Bemerkung 6.3

- Der Erwartungswert ist das Pendant zum arithmetischen Mittel der beschreibenden Statistik.

- Im diskreten Fall wird dabei jede Realisierung mit ihrer Eintrittswahrscheinlichkeit gewichtet. Im stetigen Fall ist das Integral das Analogon dazu.
- Der Erwartungswert einer Verteilung entspricht dem „Schwerpunkt“ der Wahrscheinlichkeitsmasse (siehe folgende Bilder).

Es ist entscheidend, arithmetisches Mittel und Erwartungswert klar voneinander zu trennen. Das arithmetische Mittel $\bar{x}$ basiert auf einer konkreten Stichprobe und hängt damit vom Zufall ab. Der Erwartungswert $E(X)$ einer Zufallsvariable ist hingegen ein theoretischer Wert, der die eigentliche Durchführung des Zufallsexperiments nicht erfordert. Im Allgemeinen gilt:

$$\bar{x} \neq E(X)$$

Große praktische Bedeutung hat in diesem Zusammenhang das Gesetz der großen Zahlen.

Satz 6.4. (Gesetz der großen Zahlen)

Sei $X_1, X_2, X_3, \dots$ eine Folge paarweise unabhängiger und identisch verteilter Zufallsvariablen, deren Erwartungswerte existieren. Sei weiter $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, dann gilt



$$\lim_{n \rightarrow \infty} P(|\bar{X} - E(X)| < \varepsilon) = 1$$



für alle $\varepsilon > 0$.

Bemerkung 6.5

1. Grob gesprochen folgt aus dem Gesetz der großen Zahlen, dass es für große n immer wahrscheinlicher wird, dass der Mittelwert in der Nähe von $E(X)$ liegt (d. h. $\bar{x} \approx E(X)$).
2. Auf Basis des Gesetzes der großen Zahlen kann damit $E(X)$ (falls der konkrete Wert unbekannt ist) durch den Mittelwert geschätzt werden. Die Schätzung wird umso besser sein, je größer n ist.

Im Folgenden einige Beispiele für Erwartungswerte diskreter und stetiger Zufallsvariablen.





Bemerkung 6.6. (Faire und unfaire Spiele)

Wir können das Konzept des Erwartungswertes z. B. auf Spiele anwenden. Gibt X den eigenen Gewinn bei einem Spiel an, dessen Ausgang vom Zufall abhängt, dann ist:

- das Spiel vorteilhaft, falls $E(X) > 0$
- das Spiel für den Gegner vorteilhaft, falls $E(X) < 0$
- das Spiel ein Nullsummenspiel, falls $E(X) = 0$

Aufgabe 6.7

1. Jens und Andreas spielen folgendes Glücksspiel. Jens wirft einen Würfel. Kommt 1, 2 oder 3 gewinnt Jens 1 € von Andreas, kommt 4 gewinnt Jens 2 €, kommt 6 verliert Jens 5.6 €. Wird eine 5 gewürfelt, passiert nichts. Berechne den erwarteten Gewinn von Jens.

2. Gegeben sei die Dichte:

$$f(x) = \begin{cases} \frac{1}{2}x & , 0 \leq x \leq 2 \\ 0 & , \text{sonst} \end{cases}$$

Berechne den Erwartungswert der zugehörigen Zufallsvariable.

3. Berechne den Erwartungswert eines Laplace-Würfels.

Satz 6.8. (Eigenschaften des Erwartungswertes)

Seien X und Y Zufallsvariablen und $a, b \in \mathbb{R}$. Es gilt:

$$E(a \cdot X + b \cdot Y) = a \cdot E(X) + b \cdot E(Y)$$

Aus dem letzten Satz folgt insbesondere:

$$\begin{aligned} E(X + Y) &= E(X) + E(Y) \\ E(a \cdot X + b) &= a \cdot E(X) + b \end{aligned}$$

Aufgabe 6.9

Die Zufallsvariable X beschreibe die Augenzahl beim Werfen eines Würfels. Berechne den Erwartungswert der Zufallsvariable $Y := 2 \cdot X + 1$.

Satz 6.10

Seien X und Y unabhängige Zufallsvariablen, dann gilt:

$$E(X \cdot Y) = E(X) \cdot E(Y)$$

Bemerkung 6.11

Für zwei abhängige Zufallsvariablen gilt der Inhalt des letzten Satzes i. A. nicht. Darüber hinaus gilt i. d. R. $E\left(\frac{X}{Y}\right) \neq \frac{E(X)}{E(Y)}$.

Aufgabe 6.12

1. Wir werfen einen Würfel zweimal und bilden das Produkt der Augenzahlen beider Würfe. Was ist der Erwartungswert?
2. Wir werfen eine Münze zweimal. Berechne $E(Z)$, wobei Z definiert ist als $Z = X \cdot Y$ mit $X = 1$ bzw. $Y = 1$, falls der erste bzw. zweite Wurf Kopf zeigt und $X = 0$ bzw. $Y = 0$, falls der erste bzw. zweite Wurf Zahl zeigt.

7 Varianz einer Zufallsvariablen

Definition 7.1. (Varianz)

Sei X eine Zufallsvariable mit endlichem Erwartungswert $\mu = E(X)$. Wir definieren die Varianz $\sigma^2(X) = \text{Var}(X)$ von X wie folgt:

$$\sigma^2(X) := E[(X - \mu)^2]$$

Wir können diese Definition nun für diskrete und stetige Zufallsvariablen konkretisieren. Sei X eine diskrete Zufallsvariable mit Ausprägungen $(x_i)_{i \in \mathbb{N}}$ und Wahrscheinlichkeitsfunktion p_X . Sei weiter $\mu = E(X)$ ihr endlicher Erwartungswert. Dann gilt:

$$\sigma^2(X) := \sum_{i=1}^{\infty} (x_i - \mu)^2 \cdot p_X(x_i)$$

Sei X eine stetige Zufallsvariable mit Dichte f_X und endlichem Erwartungswert $\mu = E(X)$. Dann gilt:



$$\sigma^2(X) := \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f_X(x) \, dx$$

Definition 7.2. (Standardabweichung)

Sei X eine Zufallsvariable mit Varianz $\sigma^2(X)$. Wie definieren die Standardabweichung $\sigma(X)$ wie folgt:

$$\sigma(X) = \sqrt{\sigma^2(X)}$$

Die folgenden zwei Beispiele zeigen die anschauliche Bedeutung der Varianz bzw. Standardabweichung. Je kleiner die Varianz, desto mehr „Wahrscheinlichkeit“ konzentriert sich um den Erwartungswert.



Bemerkung 7.3

- Die Standardabweichung ist ein Maß für die Abweichung vom Erwartungswert.
- Die Standardabweichung bzw. Varianz ist das Pendant zur empirischen Standardabweichung bzw. Varianz aus dem Kapitel Beschreibende Statistik.
- Es gilt $\sigma^2(X) \geq 0$ und $\sigma(X) \geq 0$.
- Wir hatten in unserer obigen Definition stets vorausgesetzt, dass der Erwartungswert der betrachteten Zufallsvariablen endlich ist. Es gibt jedoch auch Zufallsvariablen, die keinen endlichen Erwartungswert haben. Im Rahmen der Vorlesung spielen diese Fälle jedoch keine Rolle.
- $\sigma^2(X)$ kann unendlich sein, obwohl der Erwartungswert endlich ist.
- Wir betrachten als Abweichungsmaß – analog zum Kapitel Beschreibende Statistik – die mittlere quadratische Abweichung $E[(X - \mu)^2]$ und nicht die mittlere Abweichung $E(|X - \mu|)$. Grund ist, dass die Betragsfunktion einige unschöne mathematische Eigenschaften hat (bspw. ist sie an der Stelle 0 nicht differenzierbar).
- Es gilt $E(|X - \mu|) \leq E[(X - \mu)^2]$.

Es ist entscheidend, empirische und theoretische Varianz klar voneinander zu trennen. Die empirische Varianz s_x^2 basiert auf einer konkreten Stichprobe und hängt damit vom Zufall ab. Die Varianz $\sigma^2(X)$ einer Zufallsvariable ist hingegen ein theoretischer Wert, der die eigentliche

Durchführung des Zufallsexperiments nicht erfordert. Im Allgemeinen gilt:

$$s_x^2 \neq \sigma^2(X)$$

Bemerkung 7.4

1. Große praktische Bedeutung hat auch in diesem Zusammenhang das Gesetz der großen Zahlen, welches für die Varianz völlig analog zum Satz 6.4 formuliert werden kann.
2. Grob gesprochen folgt aus dem Gesetz der großen Zahlen, dass es für große n immer wahrscheinlicher wird, dass die empirische Varianz in der Nähe von $\sigma^2(X)$ liegt (d. h. $s_x^2 \approx \sigma^2(X)$). Es ist dabei sehr entscheidend – wie in Satz 6.4 erwähnt –, dass die einzelnen Zufallsexperimente unabhängig und identisch ausgeführt werden (außerdem müssen die Erwartungswerte und Varianzen existieren).
3. Auf Basis des Gesetzes der großen Zahlen kann damit $\sigma^2(X)$ (falls der konkrete Wert unbekannt ist) durch die empirische Varianz s_x^2 geschätzt werden. Die Schätzung wird umso besser sein, je größer n ist.

Satz 7.5

Sei X eine Zufallsvariable mit endlichem Erwartungswert $\mu = E(X)$. Dann gilt:

$$\sigma^2(X) = E[(X - \mu)^2] = E(X^2) - \mu^2$$

Wir können diesen Satz für diskrete und stetige Zufallsvariablen konkretisieren. Ist X eine diskrete Zufallsvariable, so gilt:

$$\sigma^2(X) = \left(\sum_i x_i^2 \cdot p_X(x_i) \right) - \mu^2$$

Ist X eine stetige Zufallsvariable, so gilt:

$$\sigma^2(X) = \left(\int_{-\infty}^{\infty} x^2 \cdot f_X(x) \, dx \right) - \mu^2$$

Aufgabe 7.6

Berechne die Varianz und Standardabweichung eines Laplace-Würfels.

Aufgabe 7.7

Der Versuch, durch ein Space-Shuttle einen Satelliten einzufangen, ist mit einer Wahrscheinlichkeit $p = 0.85$ erfolgreich. Die Ergebnisse der einzelnen Versuche sind dabei unabhängig voneinander. Die Zufallsgröße X beschreibe die Anzahl der Versuche, den Satelliten einzufangen.

1. Mit welcher Wahrscheinlichkeit wird der Satellit in den ersten 5 Versuchen eingefangen

eingefangen?

2. Bestimme die Verteilungsfunktion von X .
3. Bestimme Erwartungswert und Varianz von X .

Satz 7.8

Sei X eine Zufallsvariable und $a, b \in \mathbb{R}$. Es gilt:

$$\begin{aligned}\sigma^2(a \cdot X + b) &= a^2 \cdot \sigma^2(X) \\ \sigma(a \cdot X + b) &= |a| \cdot \sigma(X)\end{aligned}$$

Satz 7.9

Seien X und Y unabhängige Zufallsvariablen. Es gilt:

$$\begin{aligned}\sigma^2(X + Y) &= \sigma^2(X) + \sigma^2(Y) \\ \sigma(X + Y) &= \sqrt{\sigma^2(X) + \sigma^2(Y)}\end{aligned}$$

Bemerkung 7.10


Für zwei abhängige Zufallsvariablen gilt der Inhalt des letzten Satzes nicht.

Aufgabe 7.11


1. Ein Laplace-Würfel habe statt der Zahlen 1 bis 6 die Zahlen 0, 3, 6, 9, 12, 15 aufgedruckt. Berechne $\sigma^2(X)$ und $\sigma(X)$, wobei X die gewürfelte Zahl bezeichnet.
2. Wir würfeln zweimal mit einem Laplace-Würfel. Es sei X -Augenzahl des ersten Wurfes und Y -Augenzahl des zweiten Wurfes. Berechne $\sigma^2(X + Y)$.

8 Interpretation der Dichte von Zufallsvariablen


In diesem Abschnitt wollen wir uns einige Aspekte zur Interpretation der Dichte bzw. Wahrscheinlichkeitsfunktion anschauen. Wir beschränken uns zur Visualisierung auf stetige Zufallsvariablen, für diskrete Zufallsvariablen gelten unsere Aussagen analog. Im Folgenden einige Beispiele inklusive einer Interpretation.




Grün liefert tendenziell kleinere Werte als blau.



Die Werte von grün unterscheiden sich tendenziell weniger stark, als die Werte von blau.



Werte in der Umgebung von grün treten tendenziell halb so häufig auf wie Werte in der Umgebung von rot.



In der Umgebung von rot ist grün tendenziell doppelt so häufig wie blau.

9 Arithmetisches Mittel bei Versuchswiederholungen

Wir betrachten ein Zufallsexperiment, welches wir n -mal unabhängig und identisch ausführen. Der Ausgang der i -ten Ausführung des Zufallsexperimentes werde durch die Zufallsvariable X_i beschrieben. Die Zufallsvariablen $X_1, X_2, \dots, X_n$ sind dann unabhängig und identisch verteilt.

Beispiel 9.1

Einige Beispiele für unabhängige und identisch verteilte Zufallsvariablen.

- Länge produzierter Nägel: Die Zufallsvariable X_i steht für die Länge des i -ten produzierten Nagels.

- Anzahl der Blitzeinschläge in Stuttgart pro Jahr: Die Zufallsvariable X_i stehe für die Anzahl der Einschläge im Jahr i .
- Würfeln: Die Zufallsvariable X_i stehe für die Augenzahl des i -ten Wurfes.

Folgende Zufallsvariablen sind nicht unabhängig und identisch verteilt:

- Ziehung der Lottozahlen: Die Zufallsvariable X_i gibt die Zahl der i -ten Ziehung an. Diese Zufallsvariablen sind nicht unabhängig, denn ist $X_1 = 15$, so kann X_2 nicht mehr 15 sein, da die Zahl bereits gezogen wurde.
- Ziehen ohne Zurücklegen.

Wir wollen uns nun anschauen, was passiert, wenn wir den Mittelwert aller unserer Versuche bilden. Wir betrachten also die Zufallsvariable:

$$\bar{X} := \frac{1}{n}(X_1 + \dots + X_n)$$

Der folgende Satz beschreibt die Eigenschaften von $\bar{X}$.

Satz 9.2

Seien $X_1, \dots, X_n$ unabhängige und identisch verteilte Zufallsvariablen mit $E(X_i) = \mu$ und $\sigma(X_i) = \sigma$, so gilt für $\bar{X} := \frac{1}{n}(X_1 + \dots + X_n)$:

$$\begin{aligned} E(\bar{X}) &= \mu \\ \sigma^2(\bar{X}) &= \frac{\sigma^2}{n} \\ \sigma(\bar{X}) &= \frac{\sigma}{\sqrt{n}} \end{aligned}$$

Bemerkung 9.3

- Die Zufallsvariable $\bar{X}$ hat den gleichen Erwartungswert wie die einzelnen Ausführungen X_i des Zufallsexperimentes.
- Mit wachsendem n (also mit immer mehr Versuchsausführungen bzw. Wiederholungen) wird die Standardabweichung $\sigma(\bar{X})$ immer kleiner. Wir können also die „Messgenauigkeit“ beliebig verbessern, indem wir viele Messungen durchführen und den Durchschnitt aus ihnen bilden.

10 Standardisierung einer Zufallsvariable

Definition 10.1. (Standardisierung)

Gegeben sei eine Zufallsvariable X mit Erwartungswert $E(X) = \mu$ und Standardabweichung

$\sigma(X) = \sigma$. Die zu X gehörige standardisierte Zufallsvariable Z ist wie folgt definiert:

$$Z := \frac{X - \mu}{\sigma}$$

Für die standardisierte Zufallsvariable Z gilt also:

$$\begin{aligned} E(Z) &= E\left(\frac{X - \mu}{\sigma}\right) \\ &= \frac{1}{\sigma} (E(X) - \mu) \\ &= \frac{1}{\sigma} (\mu - \mu) = 0 \\ \sigma^2(Z) &= \sigma^2\left(\frac{X - \mu}{\sigma}\right) \\ &= \frac{1}{\sigma^2} \sigma^2(X - \mu) \\ &= \frac{1}{\sigma^2} \sigma^2(X) = 1 \end{aligned}$$

D. h. $E(Z) = 0$ und $\sigma(Z) = 1$. Aus diesem Grunde wird Z standardisierte Zufallsvariable genannt. Darüber hinaus gilt:

$$P(X \leq x) = P\left(Z \leq \frac{x - \mu}{\sigma}\right)$$

Diese Beziehung werden wir später noch häufiger benutzen.

11 Diskrete Verteilungen

11.1 Binomialverteilung

Definition 11.1. (Bernoulli-Experiment)

Eine Zufallsvariable, die nur die zwei möglichen Ausprägungen 0 und 1 hat, heißt Bernoulli-Experiment. Wir bezeichnen die Wahrscheinlichkeit für die Ausprägungen 0 bzw. 1 wie folgt:

$$p := P(X = 1) \quad \text{bzw.} \quad q := 1 - p = P(X = 0)$$

Wir sagen auch, die Zufallsvariable X ist Bernoulli-verteilt.

Bemerkung 11.2

- Wir bezeichnen die Ausprägungen 0 und 1 oft auch als „Niete“ und „Treffer“ bzw. „Misserfolg“ und „Erfolg“.
- Jeder Zufallsvariable mit nur zwei Ausprägungen kann als Bernoulli-Experiment aufge-

fasst werden, indem wir die Ausprägungen einfach mit 0 und 1 bezeichnen.

Beispiel 11.3

Einige Beispiele für Bernoulli-Experimente:

- Ziehen von Losen (Ausprägungen: Niete, Gewinn)
- Münzwurf (Ausprägungen: Kopf, Zahl)
- Ausschuss einer Warenproduktion (Ausprägungen: in Ordnung, Ausschuss)
- ...

Satz 11.4. (Bernoulli-Experiment)

Sei X eine Bernoulli-verteilte Zufallsgröße. Es gilt:

$$\begin{aligned}E(X) &= p \\ \sigma^2(X) &= p \cdot q = p \cdot (1 - p) \\ \sigma(X) &= \sqrt{p \cdot q} = \sqrt{p \cdot (1 - p)}\end{aligned}$$

Seien nun $X_1, \dots, X_n$ identische und unabhängige Bernoulli-Experimente. Sei weiter $E(X_i) = p$ für $i = 1, \dots, n$. Die Verteilung X beschreibe die Anzahl der Erfolge der n Bernoulli-Experimente, X ist also definiert als:

$$X := \sum_{i=1}^n X_i$$

Dann gilt:

$$P(X = k) = \binom{n}{k} p^k \cdot (1 - p)^{n-k}$$

Wir nennen X auch die Binomialverteilung.

Definition 11.5. (Binomialverteilung)

Seien $n \in \mathbb{N}$ und $p \in [0, 1]$ gegeben. Die Binomialverteilung X ist definiert durch die folgende Wahrscheinlichkeitsfunktion:

$$p_X(k) = P(X = k) := \binom{n}{k} p^k \cdot (1 - p)^{n-k} \quad \text{für } k = 0, 1, \dots, n$$

Die Binomialverteilung beschreibt die Anzahl der Erfolge bei n identischen und unabhängigen Bernoulli-Experimenten. In diesem Falle sagen wir auch X ist binomialverteilt und schreiben $X \sim B(n; p)$. Wir setzen darüber hinaus $B(n; p)(k) := p_X(k) = P(X = k)$ für $k = 0, 1, \dots, n$.

Beispiel 11.6

Einige Beispiele für binomialverteilte Zufallsvariablen:

- Ziehen mit Zurücklegen aus einer Urne mit n Kugeln
- n -facher Münzwurf
- Anzahl Ausschussteile einer Produktion mit fester Ausschussrate
- ...

Excel 11.7. (Binomialverteilung)

Mittels der Funktion `BINOMVERT(Zahl_Erfolge; Versuche; Erfolgswahrscheinlichkeit; Kumuliert)` kann in Excel die Binomialverteilung berechnet werden. Ab Excel 2011 wird zusätzlich die Funktion `BINOM.VERT(Zahl_Erfolge; Versuche; Erfolgswahrscheinlichkeit; Kumuliert)` angeboten, die identisch zur obigen Funktion ist.

Die Eingabeparameter für $B(n; p)$ sind dabei die Folgenden:

- `Zahl_Erfolge` – k
- `Versuche` – n
- `Erfolgswahrscheinlichkeit` – p
- `Kumuliert` – 0 für $P(X = k)$ (genau k Erfolge) und 1 für $P(X \leq k)$ (höchstens k Erfolge)

Satz 11.8

Sei $X \sim B(n; p)$. Es gilt:

$$\begin{aligned} E(X) &= n \cdot p \\ \sigma^2(X) &= n \cdot p \cdot (1 - p) \\ \sigma(X) &= \sqrt{n \cdot p \cdot (1 - p)} \end{aligned}$$

Aufgabe 11.9

1. Eine Urne enthält 5 schwarze und 4 rote Kugeln. Wir ziehen 3 Kugeln mit Zurücklegen. Wie groß ist die Wahrscheinlichkeit, dass alle drei Kugeln die gleiche Farbe haben?
2. Die Wahrscheinlichkeit, nach einer Therapie geheilt zu sein, betrage 0.8. Wie groß ist die Wahrscheinlichkeit, dass von 10 Personen, die dieser Therapie unterzogen werden, weniger als 8 gesund werden?
3. Berechne für $X \sim B(6; 0.2)$ die Wahrscheinlichkeit $P(X = 2)$ sowie $E(X)$ und $\sigma(X)$.
4. Zeichne die Verteilungsfunktion für $B(4; 0.4)$.

Aufgabe 11.10

Aus einer Lieferung von Stahlbeton-Trägern werden 50 Teile zufällig herausgegriffen. Erfahrungsgemäß besitzen 99 % der Träger eine Bruchfestigkeit, die über dem Doppelten des vom Hersteller garantierten Wertes liegt. Wie groß ist die Wahrscheinlichkeit, dass höchstens drei dieser Teile eine Bruchfestigkeit besitzen, die höchstens den doppelten Wert des vom Hersteller angegebenen beträgt?

Aufgabe 11.11


In einer Versicherungsgesellschaft sei eine Gruppe von 600 Personen gleichen Alters versichert. Die Wahrscheinlichkeit, im Verlauf eines Jahres zu sterben, sei für jede dieser Personen 0.005 und unabhängig von den anderen. Jeder Versicherte zahlt einen Beitrag von 100 € am Anfang des Jahres, seine Hinterbliebenen erhalten im Todesfall eine Leistung von 15.000 €.


1. Wie groß ist der Erwartungswert des Gewinns der Gesellschaft?
2. Wie groß ist die Wahrscheinlichkeit, dass ein Mindestgewinn von 20.000 € erzielt wird?


Aufgabe 11.12

Erfahrungsgemäß ist die Wahrscheinlichkeit, dass die Frontscheibe bei einer automatischen Montage eines PKW nicht passgerecht eingesetzt werden kann, 0.005. Wie groß ist die Wahrscheinlichkeit $\tilde{p}$, dass dieser Fall nicht vor der Montage des 100. PKW auftritt, wenn die Montage der ersten 50 PKW fehlerfrei verlief?

Wir betrachten einige Beispiele binomialverteilter Zufallsvariablen.







Aus den Beispielen können wir direkt folgende Sätze ableiten.

Satz 11.13

Die Binomialverteilung ist nur symmetrisch für $p = 0$, $p = 0.5$ und $p = 1$. Ansonsten ist die Binomialverteilung nicht symmetrisch.

Darüber hinaus scheint es nach den Beispielen von oben möglich zu sein $B(n; 1 - p)$ aus $B(n; p)$ abzuleiten, nämlich durch Spiegelung an der Achse $\frac{n}{2}$. Der folgende Satz beschreibt diesen Sachverhalt.

Satz 11.14

Seien $n \in \mathbb{N}$ und $p \in [0, 1]$ gegeben. Es gilt:

$$B(n; p)(k) = B(n; 1 - p)(n - k)$$

Im Folgenden untersuchen wir, wie sich die Summe zweier unabhängiger binomialverteilter Zufallsgrößen verhält. Wenn die Trefferwahrscheinlichkeiten der beiden Zufallsvariablen gleich sind, so ist auch die Summe mit gleicher Trefferwahrscheinlichkeit binomialverteilt. Dies ist der Inhalt des folgenden Satzes.

Satz 11.15

Seien $X \sim B(n_1; p)$ und $Y \sim B(n_2; p)$ unabhängig. Die Summe $X + Y$ ist wieder binomialverteilt und es gilt:

$$X + Y \sim B(n_1 + n_2; p)$$

Sind die Trefferwahrscheinlichkeiten der beiden Binomialverteilungen verschieden, so ist ihre Summe i. A. nicht binomialverteilt. Die folgende Aufgabe liefert ein Beispiel hierzu.

Aufgabe 11.16

Seien $X \sim B(2; 0.3)$ und $Y \sim B(1; 0.5)$ unabhängig. Zeige, dass die Summe $X + Y$ nicht

binomialverteilt ist.

11.2 Poisson-Verteilung

Wir haben im letzten Abschnitt die Binomialverteilung kennengelernt. Wir möchten diese nun im Falle vieler Versuche, mit geringer Wahrscheinlichkeit für einen Treffer einsetzen und untersuchen, was passiert. Wir werden dabei auf eine neue Verteilung stoßen, die sog. Poisson-Verteilung.

Betrachten wir folgendes Beispiel. Wir haben 1000 produzierte Werkstücke und wissen, dass die produzierende Maschine eine Ausschussrate von 2 ‰ hat. Wir interessieren uns nun für die Wahrscheinlichkeit, dass in der Stichprobe 3 defekte Werkstücke sind. Hierzu wenden wir die Binomialverteilung des letzten Abschnitts an. Sei X die Anzahl der defekten Werkstücke unter den 1000 produzierten Werkstücken, dann gilt $X \sim B(1000, 0.002)$ und es folgt:

$$\begin{aligned} P(X = 3) &= \binom{1000}{3} \cdot 0.002^3 \cdot 0.998^{997} \\ &= \frac{1000!}{3! \cdot 997!} \cdot 0.002^3 \cdot 0.998^{997} \\ &= \frac{1000 \cdot 999 \cdot 998}{3!} \cdot 0.002^3 \cdot 0.998^{997} \end{aligned}$$

Wir können einige Terme dieses Produktes wie folgt approximieren:

$$\begin{aligned} P(X = 3) &= \frac{1000 \cdot 999 \cdot 998}{3!} \cdot 0.002^3 \cdot 0.998^{997} \\ &= \frac{1}{3!} \cdot 2^3 \cdot \underbrace{\left(\frac{1000}{1000}\right)}_{=1} \cdot \underbrace{\left(\frac{1000-1}{1000}\right)}_{\approx 1} \cdot \underbrace{\left(\frac{1000-2}{1000}\right)}_{\approx 1} \cdot (1 - 0.002)^{997} \end{aligned} \quad (3)$$

$$\approx \frac{1}{3!} \cdot 2^3 \cdot \left(1 - \frac{2}{1000}\right)^{1000} \cdot \underbrace{\left(1 - \frac{2}{1000}\right)^{-3}}_{\approx 1} \quad (4)$$

$$\approx \frac{1}{3!} \cdot 2^3 \cdot \left(1 - \frac{2}{1000}\right)^{1000}$$

Es gilt $\lim_{n \rightarrow \infty} (1 + x/n)^n = \exp(x)$ und damit folgt:

$$P(X = 3) \approx \frac{1}{3!} \cdot 2^3 \cdot \underbrace{\left(1 - \frac{2}{1000}\right)^{1000}}_{\approx \exp(-2)} \quad (5)$$

$$\approx \frac{1}{3!} \cdot 2^3 \cdot \exp(-2) = \frac{1}{3!} \cdot (E(X))^3 \cdot \exp(-E(X)) \quad (6)$$

Damit die Approximation auch in anderen Fällen hinreichend „gut“ ist, müssen zwei wesentliche Bedingungen erfüllt sein. Zum einen muss n groß genug sein (damit die Approximationen (3) und (5) hinreichend „gut“ sind) und zum anderen darf p nicht zu groß sein (damit die Approximation (4) hinreichend „gut“ ist). Als Faustregel in der Praxis gilt, dass die Näherung für $n \geq 50$ und $p \leq 0.05$ brauchbar ist.

Wir lernen aus diesen Überlegungen allerdings noch etwas viel Wesentlicheres: Für große Stichproben (in unserem Beispiel galt $n = 1000$) mit kleiner Trefferwahrscheinlichkeit (in unserem Beispiel war die Ausschussrate nur $p = 0.002$) hängt die Wahrscheinlichkeitsverteilung im Wesentlichen nur noch vom Erwartungswert der Ausschussteile (für die gesamte produzierte Menge) gemäß der obigen Formel (6) ab (die Größen n und p selbst spielen keine Rolle mehr).

Die obigen Überlegungen führen uns zu einer neuen Verteilung, der Poisson-Verteilung. Sie kann interpretiert werden als die Verteilung der seltenen Ereignisse, bei vielen unabhängigen Versuchen (im obigen Beispiel hatten wir $n = 1000$ unabhängige Bernoulli-Experimente mit jeweils geringer Trefferwahrscheinlichkeit von $p = 0.002$). Selten bezieht sich dabei auf den Einzelfall, wobei die Gesamtzahl trotzdem groß sein kann.

Wir definieren die Poisson-Verteilung wie folgt.

Definition 11.17. (Poisson-Verteilung)

Sei $\lambda > 0$ gegeben. Die Poisson-Verteilung X ist definiert durch die folgende Wahrscheinlichkeitsfunktion:

$$p_X(k) = P(X = k) := \frac{\lambda^k}{k!} \exp(-\lambda) \quad \text{für } k = 0, 1, 2, 3, \dots$$

In diesem Falle sagen wir auch X ist Poisson-verteilt und schreiben $X \sim \text{Po}(\lambda)$.

Bemerkung 11.18

Die Poisson-Verteilung kann auch wie folgt hergeleitet werden. Wir betrachten ein Zeit-, Flächen- oder Raumintervall, in dem zählbare zufällige Ereignisse stattfinden. Gelten die folgenden Poissonschen Annahmen, so ist die Gesamtzahl der Ereignisse Poisson-verteilt.

1. Die mittlere Anzahl der Ereignisse pro „Einheitsintervall“ ist überall gleich und damit insbes. unabhängig von dessen Lage.
2. In einem hinreichend kleinen Teilintervall treten die Ereignisse einzelnen auf, d. h. die Wahrscheinlichkeit, dass mehr als ein Ereignis auftritt, ist gleich Null und die Wahrscheinlichkeit für das Eintreten eines Ereignisses ist proportional zu dessen Größe.
3. Die Anzahl der Ereignisse in einem Teilintervall ist unabhängig von den Ereignissen in anderen dazu disjunkten Teilintervallen.

Was lokal in den hinreichend kleinen Teilintervallen geschieht, bestimmt dann bereits die globale Verteilung auf dem betrachteten Zeit-, Flächen- oder Raumintervall.

Beispiel 11.19

Wie bereits oben erläutert, nennt man die Poisson-Verteilung auch die Verteilung seltener Ereignisse. Im Folgenden einige Beispiele für die Anwendung der Poisson-Verteilung:

- Zahl der Unfälle an einer Kreuzung pro Jahr
- Anzahl der Blitzeinschläge im Raum Stuttgart pro Jahr
- Anzahl der Tippfehler pro Seite
- Anzahl der Bakterien in einer Nährlösung pro Liter
- Anzahl der Anrufe in einer Telefonzentrale pro Stunde
- ...

In der Praxis verwendet man die Poisson-Verteilung häufig bei der Zählung von vielen möglichen, aber einzeln relativ unwahrscheinlichen und unabhängigen Ereignissen. Die Zählung kann sich dabei auf ein Zeit-, Flächen- oder Raumintervall beziehen und die Objekte der Zählung müssen im betrachteten Intervall gleichmäßig verteilt sein. Die Poisson-Verteilung benötigt dann weder die Parameter n noch p (wie bei der Binomialverteilung) sondern nur das durchschnittliche Auftreten λ (in einem betrachteten Zeit- oder Raumintervall).

Excel 11.20. (Poisson-Verteilung)

Mittels der Funktion `POISSON(x; Mittelwert; Kumuliert)` kann in Excel die Poisson-Verteilung berechnet werden. Ab Excel 2011 wird zusätzlich die Funktion `POISSON.VERT(x; Mittelwert; Kumuliert)` angeboten, die identisch zur obigen Funktion ist.

Die Eingabeparameter für $Po(\lambda)$ sind dabei die Folgenden:

- $x = k$
- Mittelwert $= \lambda$
- Kumuliert $= 0$ für $P(X = k)$ (genau k Erfolge) und 1 für $P(X \leq k)$ (höchstens k Erfolge)


Die Poisson-Verteilung hat die folgenden Eigenschaften.

Satz 11.21

Sei $X \sim Po(\lambda)$. Es gilt:

$$\begin{aligned}E(X) &= \lambda \\ \sigma^2(X) &= \lambda \\ \sigma(X) &= \sqrt{\lambda}\end{aligned}$$

Im Folgenden einige Beispiele der Wahrscheinlichkeitsfunktionen konkreter Poisson-Verteilungen.



Je größer λ , desto weiter nach rechts wandert die Verteilung und desto symmetrischer wird sie. Man erkennt deutlich, dass sich die Masse um den Mittelwert λ sammelt und mit wachsendem Erwartungswert auch die Streuung wächst.

Aufgabe 11.22

Sei $X \sim \text{Po}(3)$. Berechne $E(X)$ sowie $\sigma(X)$. Berechne darüber hinaus $P(X \geq 4)$.

Aufgabe 11.23

1. Die Zahl der geschlüpften Bienen eines Bienenstocks ist poissonverteilt. Innerhalb von 20 Minuten schlüpfen durchschnittlich 10 Bienen. Wie wahrscheinlich ist es, dass innerhalb der nächsten 20 Minuten genau eine, 10 bzw. 20 Bienen schlüpfen? Wie wahrscheinlich ist es, dass innerhalb der nächsten Minute genau 1 bzw. 2 Bienen schlüpfen?
2. Ein Angler fängt pro Stunde im Schnitt 0.4 Fische. Wie wahrscheinlich ist es, dass er innerhalb der nächsten 3 Stunden mindestens 2 Fische fängt?

Aufgabe 11.24

An einer Tankstelle beträgt die Wahrscheinlichkeit, dass innerhalb einer Minute kein Fahrzeug ankommt, 0.0183.

1. Bestimme aus dieser Angabe den Erwartungswert der pro Minute ankommenden Fahrzeuge.
2. Wie groß ist die Wahrscheinlichkeit, dass in einer Minute mindestens 4 Fahrzeuge ankommen?

Wir haben bereits in unserem anfänglichen Beispiel gesehen, dass man die Binomialverteilung unter gewissen Voraussetzungen gut durch die Poisson-Verteilung approximieren kann. Dies ist der Inhalt des folgenden Satzes, der für die praktische Anwendung oft Vorteile bietet.


Satz 11.25. (Poisson-Approximation)

Sei $X \sim B(n; p)$ eine binomialverteilte Zufallsvariable. Sei weiter $n \geq 50$ und $p \leq 0.05$, so gilt folgende Näherung mit $\lambda = n \cdot p$

$$\binom{n}{k} p^k \cdot (1-p)^{n-k} \approx \frac{\lambda^k}{k!} \exp(-\lambda)$$

d. h. die Binomial-Verteilung kann durch die Poisson-Verteilung approximiert werden.

Insbes. die Bedingung kleiner Wahrscheinlichkeiten p ist dabei entscheidend. Ist p nicht klein, passt die Approximation nicht, wie das folgende Beispiel zeigt (mit $n = 100$ und $p = 0.8$). Die Poisson-Verteilung mit $\lambda = n \cdot p = 80$ besitzt dann auch eine entsprechend große Varianz und passt im Ergebnis nicht mehr zur Binomialverteilung.



Aufgabe 11.26

Sei $X \sim B(500; \frac{1}{500})$. Berechne $P(X = 0)$, $P(X = 1)$, $P(X = 2)$, $P(X \geq 3)$ und $P(X = 17)$ exakt, sowie mittels Poisson-Approximation.

Aufgabe 11.27

Die Wahrscheinlichkeit, dass ein Brennelement in einem Kernreaktor den Bedingungen einer Qualitätsprüfung nicht genügt, beträgt 0.0002. Wie groß ist die Wahrscheinlichkeit, dass

1. höchstens 2 von 500
2. genau 1 von 1000,
3. keines von 100

dieser Brennelemente die Qualitätsbedingung nicht erfüllen? Nutze die Approximation mittels

Poisson-Verteilung.

Wir betrachten nun, was passiert, wenn wir zwei unabhängige Poisson-verteilte Zufallsgrößen addieren. Die Summe ist wieder Poisson-verteilt, wobei sich der Parameter λ gemäß folgendem Satz ergibt.

Satz 11.28

Seien $X \sim \text{Po}(\lambda_1)$ und $Y \sim \text{Po}(\lambda_2)$ unabhängig. Die Summe $X + Y$ ist wieder Poisson-verteilt und es gilt:

$$X + Y \sim \text{Po}(\lambda_1 + \lambda_2)$$

Aufgabe 11.29

Wir gehen ins Kino. Im Durchschnitt treffen wir dort 6 weibliche und 3 männliche Bekannte.

1. Mit welcher Wahrscheinlichkeit treffen wir genau 6 weibliche Bekannte?
2. Mit welcher Wahrscheinlichkeit treffen wir mind. einen männlichen Bekannten?
3. Mit welcher Wahrscheinlichkeit treffen wir gar keinen Bekannten (also weder einen weiblichen noch einen männlichen Bekannten)?

11.3 Hypergeometrische Verteilung

Wir wenden uns in diesem Abschnitt einer weiteren Verteilung zu, der sog. hypergeometrischen Verteilung. Sie beschreibt das Ziehen aus einer Urne ohne Zurücklegen, bei der i. W. zwei Arten von Gegenständen gezogen werden können. Wir betrachten hierzu folgende Situation: Gegeben sei eine Urne mit N Kugeln, wovon M schwarz sind (entsprechend sind $N - M$ Kugel nicht schwarz). Wir ziehen n Kugeln und die Zufallsvariable X beschreibe die Anzahl der schwarzen Kugeln unter den gezogenen Kugeln. Dann gilt:

$$P(X = k) = \frac{\binom{M}{k} \cdot \binom{N-M}{n-k}}{\binom{N}{n}}$$

Die Interpretation der einzelnen Faktoren ist wie folgt:

- $\binom{M}{k}$ - Möglichkeiten (ohne Reihenfolge, ohne Zurücklegen) aus den M schwarzen Kugeln genau k zu ziehen
- $\binom{N-M}{n-k}$ - Möglichkeiten (ohne Reihenfolge, ohne Zurücklegen) aus den $N - M$ restlichen (nicht schwarzen) Kugeln die verbleibenden $n - k$ (nicht schwarzen) Kugeln zu ziehen
- $\binom{N}{n}$ - Möglichkeiten (ohne Reihenfolge, ohne Zurücklege) aus den N Kugeln genau n zu ziehen

Bemerkung 11.30

1. Durch das Ziehen ohne Zurücklegen sind die einzelnen Ziehungen nicht unabhängig, im Gegensatz zum Ziehen mit Zurücklegen.
2. Stichproben werden i. d. R. ohne Zurücklegen gezogen. Zur Beschreibung von Situationen, bei denen zwei Arten von Gegenständen (d. h. Gegenstände mit einer bestimmten Eigenschaft und Gegenstände ohne diese) gezogen werden können, wird die hypergeometrische Verteilung genutzt.
3. Im Falle des Ziehens mit Zurücklegen, käme (in der oben beschriebenen Situation) die Binomialverteilung zum Einsatz.
4. Wird eine Stichprobe aus einer laufenden Produktion mit fester Ausschussrate entnommen, kommt ebenfalls die Binomialverteilung zum Einsatz. In dieser Situation kann von der Unabhängigkeit der Züge ausgegangen werden.

Die folgende Definition fasst die obigen Erläuterungen zusammen.

Definition 11.31. (Hypergeometrische Verteilung)

Seien $N, M, n \in \mathbb{N}$ gegeben. Die hypergeometrische Verteilung X ist definiert durch die folgende Wahrscheinlichkeitsfunktion:

$$p_X(k) = P(X = k) := \frac{\binom{M}{k} \cdot \binom{N-M}{n-k}}{\binom{N}{n}} \quad \text{für } k = 0, 1, \dots, M$$

In diesem Falle sagen wir auch X ist hypergeometrisch verteilt und schreiben $X \sim H(N; M; n)$.

Excel 11.32. (Hypergeometrische Verteilung)

Mittels der Funktion `HYPGEOMVERT(Erfolge_S; Umfang_S; Erfolge_G; Umfang_G)` kann in Excel die Hypergeometrische Verteilung berechnet werden. Ab Excel 2011 wird zusätzlich die Funktion `HYPGEOM.VERT(Erfolge_S; Umfang_S; Erfolge_G; Umfang_G; kumuliert)` angeboten.

Die Eingabeparameter für $H(N; M; n)$ sind dabei die Folgenden:

- `Erfolge_S` – k
- `Umfang_S` – n
- `Erfolge_G` – M
- `Umfang_G` – N
- `Kumuliert` – 0 für $P(X = k)$ (genau k Erfolge) und 1 für $P(X \leq k)$ (höchstens k Erfolge) (nur verfügbar ab Excel 2011)

Bemerkung 11.33

1. Unser Taschenrechner bietet keine vordefinierte Funktion für die hypergeometrische Verteilung. Bei der Berechnung muss damit direkt auf die Definition zurückgegriffen werden.
2. Bei der Berechnung mittels Taschenrechner (und Rückgriff auf die Definition) kann es vorkommen, dass die auftretenden Binomialkoeffizienten nicht berechnet werden können (weil ihre Zahlenwerte zu groß sind). In solchen Situation kann die Approximation (sofern zulässig) mittels der Binomialverteilung hilfreich sein (siehe Satz 11.38).

Die hypergeometrische Verteilung hat die folgenden Eigenschaften.

Satz 11.34

Sei $X \sim H(N; M; n)$. Es gilt mit $p := \frac{M}{N}$:

$$\begin{aligned} E(X) &= n \cdot \frac{M}{N} = n \cdot p \\ \sigma^2(X) &= n \cdot \frac{M}{N} \cdot \left(1 - \frac{M}{N}\right) \cdot \frac{N-n}{N-1} = n \cdot p \cdot (1-p) \cdot \frac{N-n}{N-1} \end{aligned}$$

Bemerkung 11.35

1. Der Erwartungswert der hypergeometrischen Verteilung und der Binomialverteilung (in Falle des Ziehens mit Zurücklegen) stimmt überein.
2. Die Varianz der hypergeometrischen Verteilung ist für $n > 1$ immer kleiner als die Varianz der Binomialverteilung (um den Faktor $\frac{N-n}{N-1}$, dieser wird auch Endlichkeitskorrektur genannt) und mit wachsendem n nimmt der Unterschied zu. Grund ist, dass wir beim Ziehen ohne Zurücklegen pro Zug immer genauere Informationen über die in der Urne verbleibenden Kugeln erhalten. Dies ist beim Ziehen mit Zurücklegen nicht der Fall.

Aufgabe 11.36

1. Sei $X \sim H(30; 10; 6)$. Berechne die Wahrscheinlichkeiten $P(X = 3)$ und $P(X = 6)$.
2. Wie groß ist die Wahrscheinlichkeit, dass alle Lottozahlen einer Ziehung kleiner als 25 sind? Was ist der Erwartungswert für die Anzahl der gezogenen Zahlen unter 25?
3. Wie wahrscheinlich ist ein Dreier/Vierer/Fünfer/Sechser beim Lotto?
4. In einer Warenlieferung von 40 Stück befinden sich 5 defekte Bauteile; wir entnehmen 10 Bauteile. Wie groß ist die Wahrscheinlichkeit, dass wir 0, 1, 2, 3, 4 oder 5 defekte Bauteile erwischen? Was ist der Erwartungswert für die Anzahl defekter Bauteile in der Stichprobe?
5. In einer Fußballmannschaft stehen 5 Spieler vor ihrer fünften gelbe Karte (sie kommen alle im nächsten Spiel zum Einsatz). Wir erfahren nach dem Spiel, dass es 4 gelbe Karten

für diese Mannschaft gab. Wie groß ist die Wahrscheinlichkeit, dass im nächsten Spiel 0, 1, 2, 3 oder 4 pausieren müssen? Was ist der Erwartungswert für die Zahl der Spieler, die ein Spiel pausieren müssen?

Aufgabe 11.37

In einem Posten von 50 Paketen mit Bauteilen befinden sich 5 unvollständige Pakete. Wie groß ist die Wahrscheinlichkeit, dass ein Käufer, der

1. 20 Pakete kauft, genau zwei unvollständige Pakete erhält,
2. 5 dieser Pakete kauft, genau ein unvollständiges Paket erhält,
3. ein Paket kauft, ein vollständiges Paket erhält?

Nehmen wir an, die Urne enthält sehr viele Kugeln (z. B. $N = 1000$) und wir machen nur wenige Züge (z. B. $n = 5$). Dann ändert sich beim Ziehen ohne Zurücklegen die Situation zwischen den einzelnen Zügen kaum. Mithin können wir in diesem Fall die hypergeometrische Verteilung gut durch die Binomialverteilung approximieren; dies kann insbes. bei der Berechnung mittels Taschenrechner sehr hilfreich sein.

Satz 11.38

Gegeben seien $N, M, n \in \mathbb{N}$ mit $\frac{n}{N} \leq 0.05$. Dann gilt

$$\frac{\binom{M}{k} \cdot \binom{N-M}{n-k}}{\binom{N}{n}} \approx \binom{n}{k} \cdot \left(\frac{M}{N}\right)^k \cdot \left(1 - \frac{M}{N}\right)^{n-k},$$

d. h. in diesem Falle kann die hypergeometrische Verteilung durch die Binomialverteilung approximiert werden. Die Trefferwahrscheinlichkeit der entsprechenden Binomialverteilung ist $\frac{M}{N}$. Die Approximation passt umso besser, je kleiner $\frac{n}{N}$ ist.

Bemerkung 11.39

Wenn N gegen unendlich strebt, strebt die Endlichkeitskorrektur $\frac{N-n}{N-1}$ gegen 1 und damit die Varianz der hypergeometrischen Verteilung gegen $n \cdot p \cdot (1-p)$ (vergleiche Satz 11.34), was der Varianz der Binomialverteilung entspricht (beim Ziehen mit Zurücklegen).

Aufgabe 11.40

1. In einer Lieferung von 200 Bauteilen befinden sich 15 defekte Bauteile. Der Empfänger prüft 10 Bauteile auf Defekte. Wie wahrscheinlich ist es, dass sich in der Stichprobe des Empfängers 0, 1, 2 bzw. 3 defekte Bauteile befinden. Rechne exakt sowie mittels Approximation durch die Binomialverteilung. Beurteile die Güte der Approximation durch die Binomialverteilung.
2. Bei einer Wahl entfallen von 40 Mio. Stimmen 10 Mio. Stimmen auf Partei A. Wie groß

ist die Wahrscheinlichkeit, dass bei einer zufälligen Gruppe von 15 Menschen genau 5 Partei A gewählt haben?

Bemerkung 11.41

Im Gegensatz zur Binomial- und Poissonverteilung ist die Summe zweier unabhängiger hypergeometrisch verteilter Zufallsvariablen nicht hypergeometrisch verteilt.

12 Stetige Verteilungen

12.1 Gleichverteilung

Definition 12.1. (Gleichverteilung)

Gegeben sei ein nicht-leeres Intervall $[a, b] \subset \mathbb{R}$. Eine stetige Zufallsvariable X bezeichnet man als gleichverteilt auf dem Intervall $[a, b]$, wenn ihre Dichte durch die folgende Funktion

$$f_X(x) = \begin{cases} \frac{1}{b-a} & , \text{ für } x \in [a, b] \\ 0 & , \text{ sonst} \end{cases}$$

gegeben ist. In diesem Falle schreiben wir auch $X \sim U([a, b])$.

Bemerkung 12.2

Völlig analog ist die Gleichverteilung für links offene Intervalle $(a, b]$, rechts offene Intervalle $[a, b)$ bzw. offene Intervalle (a, b) definiert. Die folgenden Resultate gelten auch in diesen Fällen, da die Randpunkte bei stetigen Verteilungen keine Rolle spielen.

Satz 12.3

Sei $X \sim U([a, b])$. Es gilt:

$$\begin{aligned} E(X) &= \frac{a+b}{2} \\ \sigma^2(X) &= \frac{(b-a)^2}{12} \\ \sigma(X) &= \frac{b-a}{\sqrt{12}} \end{aligned}$$

Aufgabe 12.4

Eine Produktionsanlage für Nägel produziert Nägel, deren Längen zwischen 4.8 cm und 5.2 cm gleichverteilt sind. Berechne die Wahrscheinlichkeit, dass die Länge eines Nagels kleiner als 5 cm ist.

Bemerkung 12.5

Die Summe $X + Y$ zweier unabhängiger gleichverteilter Zufallsvariablen X und Y ist nicht gleichverteilt. Sind bspw. X und Y gleichverteilt auf demselben Intervall $[a, b]$, so ist $X + Y$ dreiecksverteilt. Betrachte hierzu die folgende Aufgabe.

Aufgabe 12.6

Seien $X, Y \sim U([0, 1])$ unabhängig. Bestimme die Dichte der Zufallsvariablen $X + Y$. Welche Gestalt hat sie?

Mittels der Gleichverteilung können wir andere Zufallsvariablen simulieren, vorausgesetzt die Quantilfunktion ist bekannt. Das Vorgehen hierzu beschreibt der folgende Satz.

Satz 12.7. (Inversionsmethode)

Sei $U \sim U([0, 1])$ eine auf $[0, 1]$ gleichverteilte Zufallsvariable und X eine Zufallsvariable. Es gilt

$$\tilde{X} := F_X^{-1}(U) \quad \text{hat Verteilungsfunktion } F_X$$

wobei F^{-1} die Quantilfunktion von X bezeichne.

Auf diese Weise können wir (z. B. mit Excel) die Zufallsvariablen aus dieser Vorlesung simulieren. Wir benötigen einzig einen Zufallszahlengenerator, der Zahlen in $[0, 1]$ gleichverteilt erzeugt sowie die jeweilige Quantilfunktion.

Excel 12.8. (Gleichverteilung)

Mittels der Funktion `ZUFALLSZAHL()` kann in Excel eine gleichverteilte Zufallsvariable zwischen 0 und 1 generiert werden.

12.2 Normalverteilung

Definition 12.9. (Normalverteilung)

Gegeben seien Parameter $\mu \in \mathbb{R}$ und $\sigma \in \mathbb{R}_{>0}$. Eine stetige Zufallsvariable X heißt normalverteilt zu den Parametern μ und σ , wenn ihre Dichte durch die folgende Funktion

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$$

gegeben ist. In diesem Falle schreiben wir auch $X \sim N(\mu, \sigma^2)$.

Bemerkung 12.10

- Die oben dargestellte Funktion f_X ist tatsächlich eine Dichtefunktion, insbes. ist die Fläche unter ihr gleich 1.

- Die Dichte f_X wird auch Gaußsche Glockenkurve genannt.
- Eine normalverteilte Zufallsvariable ist symmetrisch, mit Symmetrieachse μ .

Satz 12.11. (Gaußsche Glockenkurve)

Gegeben seien Parameter $\mu \in \mathbb{R}$ und $\sigma \in \mathbb{R}_{>0}$. Die Gaußsche Glockenkurve

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{x-\mu}{\sigma}\right)^2\right)$$

besitzt ein Maximum an der Stelle μ sowie zwei Wendepunkte an den Stellen $\mu \pm \sigma$.

Aufgabe 12.12


Beweise die Aussagen des letzten Satzes.

Satz 12.13


Sei $X \sim N(\mu, \sigma^2)$, dann gilt:

$$\begin{aligned} E(X) &= \mu \\ \sigma(X) &= \sigma \end{aligned}$$

Wir betrachten einige Beispiele der Normalverteilung.



$\sigma = 1$ $\mu = -2.5$, $\mu = 0$, $\mu = 2.5$




$\mu = 0$ $\sigma = 0.5$, $\sigma = 1$, $\sigma = 2$

Wir sehen deutlich, wie der Erwartungswert μ die Verteilung entlang der x -Achse verschiebt und die Standardabweichung σ die Verteilung staucht bzw. streckt.

Bemerkung 12.14. (Standardnormalverteilung)

Eine normalverteilte Zufallsgröße X mit den Parametern $\mu = 0$ und $\sigma = 1$ (d. h. $X \sim N(0, 1)$) nennt man auch standardnormalverteilt. Die Verteilungsfunktion der Standardnormalverteilung wird auch mit Φ bezeichnet, d. h. $\Phi(x) := F_X(x)$.

Schauen wir uns die Dichte der Standardnormalverteilung noch etwas genauer an. Die Funktion $\Phi(x)$ beschreibt die Fläche unter der Glockenkurve bis zur Stelle x .



Aus den obigen zwei Beispielen wird sofort folgender Satz ersichtlich.

Satz 12.15

Sei $z \in \mathbb{R}$, dann gilt:

$$\Phi(-z) = 1 - \Phi(z)$$

Bemerkung 12.16

1. Die Verteilungsfunktion Φ kann nicht explizit dargestellt werden, sie ist nur numerisch auswertbar. Zur Bestimmung von $\Phi(x)$ kann der Taschenrechner oder Excel genutzt werden. Darüber hinaus gibt es entsprechende Tabellen, die im Anhang zu finden sind.
2. Die Quantile der Standardnormalverteilung werden auch mit z_p für $p \in (0, 1)$ bezeichnet und es gilt $z_{1-p} = -z_p$.

Aufgabe 12.17

Sei $X \sim N(0, 1)$. Berechne die folgenden Wahrscheinlichkeiten: $P(X < 1.53)$, $P(X > 2)$ sowie $P(X \in [-2, 1.53])$ und $P(X \in [0.76, \infty))$.

Satz 12.18

Sei $X \sim N(\mu, \sigma^2)$ und seien weiter $a, b \in \mathbb{R}$ mit $a \neq 0$. Die Zufallsvariable $Y := a \cdot X + b$ ist

ebenfalls normalverteilt und es gilt:

$$Y \sim N(a\mu + b, a^2\sigma^2)$$

Aus dem letzten Satz folgt insbesondere, dass für $X \sim N(\mu, \sigma^2)$ gilt:

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

Vergleiche hierzu auch die Ausführungen im Abschnitt 10 zur Standardisierung von Zufallsvariablen.

Mittels dieser Transformation können wir nun ganz einfach die Verteilungsfunktion einer beliebigen Normalverteilung $X \sim N(\mu, \sigma^2)$ auf die der Standardnormalverteilung Φ zurückführen. Dies geschieht wie folgt:

$$\begin{aligned} F_X(x) &= P(X \leq x) \\ &= P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) \\ &= P\left(Z \leq \frac{x - \mu}{\sigma}\right), \quad \text{mit } Z \sim N(0, 1) \\ &= \Phi\left(\frac{x - \mu}{\sigma}\right) \end{aligned}$$

Hieraus folgt direkt der Inhalt des folgenden Satzes.

Satz 12.19

Sei $X \sim N(\mu, \sigma^2)$ und seien $x, a, b \in \mathbb{R}$ mit $a \leq b$. Es gilt:

$$\begin{aligned} P(X \leq x) &= \Phi\left(\frac{x - \mu}{\sigma}\right) \\ P(X \in [a, b]) = P(a \leq X \leq b) &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right) \end{aligned}$$

Sei weiter $p \in (0, 1)$. Das p -Quantil von X ist gegeben durch

$$\mu + \sigma z_p$$

wobei z_p das p -Quantil der Standardnormalverteilung bezeichnet.

Aufgabe 12.20

1. Sei $X \sim N(2, 5^2)$. Berechne die folgenden Wahrscheinlichkeiten: $P(X < 3)$, $P(X > 1.5)$ sowie $P(X \in [-2, 1])$ und $P(X \in [1, \infty))$.
2. Wir hatten die Verteilung der Körpergröße X von Männern bereits kennengelernt, es galt $X \sim N(181, 7.1^2)$. Wie groß ist die Wahrscheinlichkeit, dass ein Student an der

Hochschule Esslingen größer als 2 Meter ist?

Aufgabe 12.21

Seien $X_1 \sim N(0, 1)$, $X_2 \sim N(50, 1)$, $X_3 \sim N(100, 5^2)$ und $X_4 \sim N(100, 20^2)$. Berechne die folgende Wahrscheinlichkeiten:

- $P(X_1 \leq -1.5), P(X_1 \geq 0.5)$
- $P(X_2 \leq 48.5), P(X_2 \geq 51.3)$
- $P(X_3 \leq 99.5), P(X_3 \geq 104)$
- $P(X_4 \leq 80), P(X_4 \geq 143)$

Aufgabe 12.22

Wir erhalten eine Lieferung Kondensatoren, deren Kapazität K normalverteilt ist mit Erwartungswert $\mu = 200 \mu\text{F}$ und Varianz $\sigma^2 = 25 (\mu\text{F})^2$. Ein Kondensator gilt als nicht fehlerhaft, wenn seine Kapazität um nicht mehr als $5 \mu\text{F}$ vom Sollwert $200 \mu\text{F}$ abweicht.

Wie groß ist die Wahrscheinlichkeit, dass ein Kondensator fehlerhaft ist?

Satz 12.23

Sei $X \sim N(\mu, \sigma^2)$. Sei weiter $\alpha \in \mathbb{R}_{>0}$, dann gilt:

$$P(\mu - \alpha < X < \mu + \alpha) = 2\Phi\left(\frac{\alpha}{\sigma}\right) - 1$$

Sei nun $p \in (0, 1)$. Es gilt mit $\alpha = \sigma \cdot z_{\frac{p+1}{2}}$

$$P(\mu - \alpha < X < \mu + \alpha) = p$$

wobei $z_{\frac{p+1}{2}}$ das $\frac{p+1}{2}$ -Quantil der Standardnormalverteilung bezeichnet.

Bemerkung 12.24

1. Sei $X \sim N(\mu, \sigma^2)$. Aus dem letzten Satz folgt direkt, dass

$$P\left(\mu - \sigma \cdot z_{1-\frac{\alpha}{2}} \leq X \leq \mu + \sigma \cdot z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

gilt. Man nennt daher das um den Erwartungswert μ symmetrische Intervall

$$[\mu - \sigma \cdot z_{1-\frac{\alpha}{2}}, \mu + \sigma \cdot z_{1-\frac{\alpha}{2}}]$$

auch zweiseitigen Zufallsstrebereich zum Niveau $1 - \alpha$. Die Wahrscheinlichkeit, dass X innerhalb dieses Intervalls liegt, beträgt $1 - \alpha$.

2. Analog nennt man die Intervalle $(-\infty, \mu + \sigma \cdot z_{1-\alpha}]$ bzw. $[\mu - \sigma \cdot z_{1-\alpha}, \infty)$ einseitig nach oben bzw. einseitig nach unten beschränkten Zufallsstrebereich zum Niveau $1 - \alpha$. Die Wahrscheinlichkeit, dass X innerhalb dieser Intervalle liegt, beträgt jeweils $1 - \alpha$.
3. Zufallsstrebereiche werden im Rahmen von Hypothesentests eine wesentliche Rolle spielen. Durch sie sind die Bereiche gegeben, die zu keiner Ablehnung der Nullhypothese führen.

Mittels des letzten Satzes können wir ganz einfach folgende Regeln herleiten. Sei $X \sim N(\mu, \sigma^2)$, dann gilt

- $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx \frac{2}{3}$, d. h. mit Wahrscheinlichkeit $\frac{2}{3}$ liegen die Beobachtungen einer normalverteilten Zufallsgröße zwischen $\mu - \sigma$ und $\mu + \sigma$.
- $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0.95$, d. h. mit Wahrscheinlichkeit 0.95 liegen die Beobachtungen einer normalverteilten Zufallsgröße zwischen $\mu - 2\sigma$ und $\mu + 2\sigma$.
- $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0.9975$, d. h. mit Wahrscheinlichkeit 0.9975 liegen die Beobachtungen einer normalverteilten Zufallsgröße zwischen $\mu - 3\sigma$ und $\mu + 3\sigma$.

Aufgabe 12.25

Leite die obigen Aussagen her.

Aufgabe 12.26

Die Ergebnisse beim IQ-Test sind normalverteilt mit Durchschnitt 100 und Standardabweichung 15.

1. Wie viele Menschen haben einen IQ zwischen 90 und 110?
2. Welche Abweichung vom Durchschnitt 100 ist normal, wenn wir annehmen, dass 90 % der Menschen normal intelligent und insgesamt 10 % als außergewöhnlich intelligent bzw. mäßig intelligent bezeichnen?

Aufgabe 12.27

Wir betrachten die Kondensatoren aus Aufgabe 12.22. Wie müssen die Toleranzgrenzen vorgegeben werden, damit die Wahrscheinlichkeit fehlerhafter Kondensatoren kleiner als 0.001 ist?

Satz 12.28. (Additionssatz)

Seien $X \sim N(\mu_X, \sigma_X^2)$ und $Y \sim N(\mu_Y, \sigma_Y^2)$ unabhängig gegeben. Dann ist $X \pm Y$ ebenfalls

normalverteilt und es gilt:

$$\begin{aligned} X + Y &\sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2) \\ X - Y &\sim N(\mu_X - \mu_Y, \sigma_X^2 + \sigma_Y^2) \end{aligned}$$

Bemerkung 12.29

Seien $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ und paarweise unabhängig, dann folgt aus dem letzten Satz insbesondere, dass

$$\begin{aligned} \sum_{i=1}^n X_i &\sim N(n \cdot \mu, n \cdot \sigma^2) \quad \text{und} \\ \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i &\sim N\left(\mu, \frac{\sigma^2}{n}\right) \end{aligned}$$

gilt.

Aufgabe 12.30

1. Seien $X_1 \sim N(10, 2^2)$ und $X_2 \sim N(5, 5^2)$ unabhängig. Berechne $P(X_1 + X_2 \leq 20)$.
2. Seien $Y_1 \sim N(10, 5)$ und $Y_2 \sim N(5, 4)$ unabhängig. Berechne $P(Y_1 + Y_2 \leq 20)$.

Aufgabe 12.31

Eine Maschine produziere Bolzen, deren Durchmesser normalverteilt sind mit Mittelwert 9.8 mm und Standardabweichung 0.11 mm. Eine zweite Maschine bohrt Löcher in eine Metallplatte, deren Durchmesser normalverteilt sind mit Mittelwert 10 mm und Standardabweichung 0.08 mm. Wie groß ist die Wahrscheinlichkeit, dass ein beliebiger Bolzen in ein beliebiges Loch passt? Betrachte hierzu $X < Y$ bzw. $X - Y < 0$.

Aufgabe 12.32

Ein LKW habe eine Nutzlast von 6 Tonnen und werde durch einen Kran mit Kies beladen. Bei jeder einzelnen Beladung erfasse der Kran eine Masse, die normalverteilt mit Erwartungswert 250 kg und Standardabweichung 50 kg ist.

Wie viele Beladungsvorgänge sind mindestens nötig, damit mit einer Wahrscheinlichkeit von mehr als 0.95 die Nutzlast des LKW um mindestens 95 % ausgenutzt ist.

Excel 12.33. (Standardnormalverteilung $N(0, 1)$)

Mittels der Funktion **STANDNORMVERT(z)** kann in Excel die Verteilungsfunktion der Standardnormalverteilung berechnet werden. Der Eingabeparameter **z** ist der Wert, dessen Wahr-

lichkeit berechnet werden soll, d. h.

$$P(X \leq z) \quad \text{für } X \sim N(0, 1).$$

Seit Excel 2011 gibt es zusätzlich die Funktion `NORM.S.VERT(z; Kumuliert)`, die ebenfalls die Verteilungsfunktion der Standardnormalverteilung berechnet. Der Parameter `Kumuliert` bewirkt dabei folgendes: 0 berechnet den Wert der Dichtefunktion der Standardnormalverteilung bei z und 1 den Wert der Verteilungsfunktion der Standardnormalverteilung $P(X \leq z)$ bei z .

Excel 12.34. (Normalverteilung $N(\mu, \sigma^2)$)

Mittels der Funktion `NORMVERT(x; Mittelwert; Standabwn; Kumuliert)` kann in Excel die Verteilungsfunktion einer beliebigen Normalverteilung berechnet werden. Ab Excel 2011 wird zusätzlich die Funktion `NORM.VERT(x; Mittelwert; Standabwn; Kumuliert)` angeboten, die identisch zur obigen ist.

Die Eingabeparameter für $N(\mu, \sigma^2)$ sind dabei die Folgenden:

- `x` – x
- `Mittelwert` – μ
- `Standabwn` – σ
- `Kumuliert` – 0 berechnet die Dichtefunktion an der Stelle x und 1 die Verteilungsfunktion $P(X \leq x)$ an der Stelle x

12.3 Zentraler Grenzwertsatz

Der nächste Satz ist ein zentrales Ergebnis im Bereich der Wahrscheinlichkeitstheorie. Er liefert die Begründung dafür, dass viele der in der Praxis auftretenden Verteilungen annähernd glockenförmig sind. Seine wesentliche Aussage ist, dass der Mittelwert aus n unabhängigen und identisch verteilten Zufallsvariablen X_i näherungsweise normalverteilt ist. Dies ist durchaus überraschend, da die eigentliche Verteilung der Zufallsvariablen X_i keine Rolle spielt.

Satz 12.35. (Zentraler Grenzwertsatz)

Seien $X_1, X_2, X_3, \dots, X_n$ unabhängige und identisch verteilte Zufallsvariablen. Sei $E(X_i) = \mu$ und $\sigma(X_i) = \sigma$ für $i = 1, \dots, n$. Mit $\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i$ gilt

$$\bar{X} \rightarrow N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{für } n \rightarrow \infty$$

bzw.

$$\lim_{n \rightarrow \infty} P(\bar{X} \leq x) = \Phi\left(\frac{x - \mu}{\frac{\sigma}{\sqrt{n}}}\right).$$

Bemerkung 12.36

1. Über die eigentliche Verteilung der Zufallsvariablen X_i wurde keinerlei Annahme gemacht! Insbes. müssen die Zufallsvariablen X_i nicht selbst normalverteilt sein.
2. Unter sehr schwachen zusätzlichen Bedingungen gilt der Zentrale Grenzwertsatz auch dann, wenn die Zufallsvariablen X_i nicht identisch verteilt sind.
3. Wir können den obigen Satz auch für die Summe der X_i wie folgt umformulieren

$$\sum_{i=1}^n X_i \rightarrow N(n \cdot \mu, n \cdot \sigma^2) \quad \text{für } n \rightarrow \infty$$

bzw.

$$\lim_{n \rightarrow \infty} P\left(\sum_{i=1}^n X_i \leq x\right) = \Phi\left(\frac{x - n \cdot \mu}{\sqrt{n} \cdot \sigma}\right).$$

4. Für große n gelten daher die folgenden Approximationen

$$P(\bar{X} \leq x) \approx \Phi\left(\frac{x - \mu}{\frac{\sigma}{\sqrt{n}}}\right) \quad \text{bzw.} \quad P\left(\sum_{i=1}^n X_i \leq x\right) \approx \Phi\left(\frac{x - n \cdot \mu}{\sqrt{n} \cdot \sigma}\right).$$

Als Faustregel wird für eine gute Approximation oftmals die Bedingung $n \geq 30$ gefordert.

5. In der Praxis kann daher für die näherungsweise Berechnung von Wahrscheinlichkeiten für $\bar{X}$ und $\sum_{i=1}^n X_i$ einfach auf die entsprechende Normalverteilung zurückgegriffen werden.

Beispiel 12.37

Beim Roulette gibt es 18 rote Felder, 18 schwarze Felder sowie ein grünes Feld. Wir setzen 1 € auf Rot. Die Zufallsgröße X beschreibe den Gewinn des Casinos (bzw. unseren Verlust): sie hat also die Ausprägungen $X = -1$ falls ein rotes Feld kommt und $X = 1$ falls kein rotes Feld kommt. Dann gilt für den Erwartungswert des Gewinns des Casinos

$$E(X) = -1 \cdot \frac{18}{37} + 1 \cdot \frac{19}{37} = \frac{1}{37}$$

und für die Varianz

$$\text{Var}(X) = E(X^2) - (E(X))^2 = 1 - \left(\frac{1}{37}\right)^2 = 0.99927.$$

Es ist klar, dass beim Setzen auf schwarz der Erwartungswert und die Varianz der Zufallsvariablen gleich bleiben. Wir setzen nun 10000-mal (oder es spielen 10000 Spieler unabhängig voneinander und setzen jeweils einmal). Wie groß ist die Wahrscheinlichkeit, dass das Casino dabei einen Gewinn macht? Sei X_i die Zufallsvariable, die den Ausgang jedes einzelnen Spiels beschreibt. Diese sind alle unabhängig und gleichverteilt mit Erwartungswert und Varianz wie

oben hergeleitet. Wir suchen nun die Wahrscheinlichkeit

$$P(S > 0) \quad \text{mit } S = \sum_{i=1}^{10000} X_i.$$

Nach dem zentralen Grenzwertsatz ist

$$\frac{S - E(S)}{\sigma(S)}$$

approximativ standard-normalverteilt. Damit gilt:

$$P(S > 0) = P\left(\frac{S - E(S)}{\sigma(S)} > \frac{-E(S)}{\sigma(S)}\right) \approx 1 - \Phi\left(\frac{-E(S)}{\sigma(S)}\right) = \Phi\left(\frac{E(S)}{\sigma(S)}\right)$$

und mit

$$\begin{aligned} E(S) &= 10000 \cdot E(X_i) = 10000 \cdot \frac{1}{37} \approx 270.87 \\ \text{Var}(S) &= 10000 \cdot \text{Var}(X_i) = 10000 \cdot 0.99927 = 9992.7 \\ \sigma(S) &= 99.96 \end{aligned}$$

erhalten wir schließlich

$$P(S > 0) \approx \Phi(2.72) = 0.9967.$$

Es ist also nahezu sicher, dass das Casino einen Gewinn macht.

Aufgabe 12.38

1. Ein Zufallsexperiment mit Erwartungswert $\mu = 7$ und $\sigma = 4$ wird 30-mal durchgeführt und die Ergebnisse zusammengezählt. Berechne Erwartungswert und Standardabweichung der Summe X sowie $P(X \leq 230)$.
2. Die Fertigung eines Artikels bestehe aus 40 Arbeitsschritten. Es sei T_i die Dauer des i -ten Arbeitsschrittes in Stunden. Jedes T_i ist auf dem Intervall $[1, 2]$ gleichverteilt. Des Weiteren sind die T_i untereinander unabhängig. Bestimme approximativ die Verteilung der Gesamt-Produktionsdauer $T := T_1 + \dots + T_{40}$ und berechne $P(T > 63)$.

Aufgabe 12.39

Die Kohlenmonoxid-Konzentration eines Heizwerks habe den Erwartungswert μ und die Varianz $\sigma^2 = 0.0001 \text{ (g/cm}^3\text{)}^2$.

Wie oft muss die Konzentration unabhängig gemessen werden, so dass die Abweichung zwischen dem Erwartungswert und dem Mittel der Messwerte mit einer Wahrscheinlichkeit von mindestens 0.9 betragsmäßig kleiner als 0.003 g/cm^3 ist.

Der Zentrale Grenzwertsatz 12.35 kann insbes. genutzt werden, um die Binomialverteilung (als Summe von Bernoulli-verteilten Zufallsvariablen) zu approximieren. Bei der Approximation der

diskreten Binomialverteilung durch die stetige Normalverteilung erhält man i. A. bessere Resultate bei der Berücksichtigung einer sog. Stetigkeitskorrektur. Dies ist der Inhalt des folgenden Satzes.

Satz 12.40. (Grenzwertsatz von de Moivre-Laplace)

Sei $X \sim B(n; p)$ binomialverteilt und sei $n \cdot p \cdot (1 - p) > 9$, so gilt:


$$P(X \leq x) \approx \Phi\left(\frac{x + \frac{1}{2} - n \cdot p}{\sqrt{n \cdot p \cdot (1 - p)}}\right)$$

Für $a, b \in \mathbb{R}$ mit $a \leq b$ gilt:

$$P(X \in [a, b]) = P(a \leq X \leq b) \approx \Phi\left(\frac{b + \frac{1}{2} - n \cdot p}{\sqrt{n \cdot p \cdot (1 - p)}}\right) - \Phi\left(\frac{a - \frac{1}{2} - n \cdot p}{\sqrt{n \cdot p \cdot (1 - p)}}\right)$$

Je größer $n \cdot p \cdot (1 - p)$ ist, desto besser sind die beiden Näherungen.

Diese Möglichkeit der Approximation hatten wir bereits gesehen, als wir uns mit der Binomialverteilung beschäftigen. Hier noch einmal einige Beispiele (in rot ist die Approximation durch die Normalverteilung angegeben).



Bemerkung 12.41

1. Die beiden Korrekturen $b + \frac{1}{2}$ bzw. $a - \frac{1}{2}$ der oberen bzw. unteren Grenze werden als Stetigkeitskorrektur bezeichnet. Bei der Verwendung des Taschenrechners sind diese Korrekturen natürlich ebenfalls zu berücksichtigen.
2. Man beachte, dass es für die Binomialverteilung (als diskrete Verteilung) i. A. einen Unterschied macht, ob wir bei der Formulierung von Wahrscheinlichkeiten das Relationszeichen $\leq$ oder $<$ verwenden (anders als bei stetigen Verteilungen). Bspw. gilt

$$P(X < 120) = P(X \leq 119), \quad P(X \geq 50) = 1 - P(X \leq 49), \quad P(55 < X < 67) = P(56 \leq X \leq 66), \quad \dots$$

für eine binomialverteilte Zufallsvariable X .

3. Wir hatten bereits gesehen, dass unter gewissen Bedingungen die Binomialverteilung durch die Poisson-Verteilung bzw. die hypergeometrische Verteilung durch die Binomialverteilung approximiert werden kann. Folglich können die Poisson-Verteilung und die hypergeometrische Verteilung ebenfalls durch die Normalverteilung approximiert werden. Es gilt:
 - (a) Für $\lambda \geq 9$ kann die Poisson-Verteilung $Po(\lambda)$ durch die Normalverteilung $N(\lambda, \lambda)$ approximiert werden.
 - (b) Für $\frac{n}{N} \leq 0.05$ und $n \cdot p \cdot (1 - p) \geq 9$ (wobei $p = \frac{M}{N}$) kann die hypergeometrische Verteilung $H(N; M; n)$ durch die Normalverteilung $N\left(n \cdot p; n \cdot p \cdot (1 - p) \cdot \frac{N-n}{N-1}\right)$ approximiert werden.
4. In den beiden letztgenannten Fällen sind ebenfalls die Stetigkeitskorrekturen zu verwenden.
5. Da mittels Taschenrechner oder Excel die Wahrscheinlichkeiten der Binomial-, Poisson- und hypergeometrischen Verteilung leicht exakt berechnet werden können, werden die Approximationen durch die Normalverteilung nur noch selten benutzt.

Aufgabe 12.42

Nutze für die folgenden Aufgaben jeweils die Approximation nach de Moivre-Laplace.

1. Sei $X \sim B(60; 0.2)$. Berechne $P(X \leq 10)$ und $P(X \in [10, 14])$.
2. Eine Maschine hat eine Ausschussrate von 2 %. Die Produktion werde in Kisten zu je 5000 Stück verpackt. Berechne die Wahrscheinlichkeit, dass sich in einer Kiste 120 oder mehr Ausschussteile befinden.
3. Ein Multiple-Choice-Test hat 20 Fragen mit jeweils 3 Möglichkeiten (wobei jeweils immer genau eine Antwort richtig ist). Wie wahrscheinlich ist es, dass ein Student ohne jede Ahnung mindestens 5 richtige Antworten schafft?

Aufgabe 12.43

Ein Flugunternehmen weiß, dass im Mittel 16 % der gebuchten Personen nicht zum Abflug erscheinen. Aus diesem Grund werden die Flüge zu 120 Sitzplätzen i.d.R. überbucht, um die Zahl der ungenutzten Plätze nicht zu groß werden zu lassen.

1. Auf einen Flug wurden 130 Personen gebucht. Wie groß ist die Wahrscheinlichkeit, dass alle zum Abflug erscheinenden Personen auch einen Sitzplatz erhalten?
2. Wie viele Buchungen dürfen höchstens angenommen werden, wenn für den Flug mit Wahrscheinlichkeit 0.99 alle erscheinenden Personen auch einen Sitzplatz erhalten sollen?

Teil IV

Schliessende Statistik

1 Punktschätzer

In der Praxis gibt es oft Situationen, in denen uns die Verteilung eines Merkmals bekannt ist, nicht aber alle ihre Parameter. Wir können nun solange nicht mit der Verteilung arbeiten (um bspw. Aussagen über das Merkmal treffen), wie die Parameter unbekannt sind. Aus diesem Grund möchten wir uns in diesem Abschnitt damit befassen, wie die unbekannten Parameter geschätzt werden können (man spricht dabei auch von sog. Punktschätzern). Derartige Schätzung werden natürlich immer auf Stichproben basieren müssen (da die vollständige Untersuchung der Grundgesamtheit so gut wie nie durchführbar ist) und mit Unsicherheiten verbunden sein. Dass wir mit einem Punktschätzer den wahren Parameter tatsächlich „treffen“ ist dabei so gut wie ausgeschlossen. Aus diesem Grund werden wir später sog. Konfidenzintervalle einführen.

Bemerkung 1.1

Wir gehen in diesem Abschnitt stets von stetigen reellwertigen Zufallsvariablen aus.

Beispiel 1.2

Die Länge X von Nägeln sei normalverteilt mit unbekannten Parametern μ und σ^2 (d. h. $X \sim N(\mu, \sigma^2)$). Zur Schätzung der beiden Parameter erheben wir eine Stichprobe von n Nägeln. Wie können wir hieraus Rückschlüsse auf die Parameter μ und σ^2 ziehen? Naiv können wir folgendes tun

$$\begin{aligned}\hat{\mu} &= \bar{x} \\ \hat{\sigma}^2 &= s_x^2\end{aligned}$$

d. h. wir nehmen einfach den empirischen Mittelwert bzw. die empirische Varianz als Punktschätzer für μ bzw. σ^2 .

Frage: Sind die beiden Schätzer „gut“? Dies wollen wir im Folgenden detailliert untersuchen!

Aus dem letzten Beispiel können wir den mathematischen Hintergrund zu Punktschätzern ableiten. Eine Stichprobe an Daten $x_1, \dots, x_n$ zu einem Merkmal können wir auffassen als Realisierungen von unabhängigen und identisch verteilten Zufallsvariablen $X_1, \dots, X_n$. Was ist nun ein Schätzer bzw. eine Schätzfunktion?

Definition 1.3. (Schätzer)

Seien $X_1, \dots, X_n$ unabhängige und identisch verteilte Zufallsvariablen und sei $g: \mathbb{R}^n \rightarrow \mathbb{R}$ eine Funktion. Die Funktion T mit

$$T = g(X_1, \dots, X_n)$$

heißt Schätzer oder Schätzfunktion.

Ein Schätzer bzw. eine Schätzfunktion ist damit selbst wieder eine Zufallsvariable.

Beispiel 1.4. (Fortsetzung)

Im letzten Beispiel hatten wir bereits zwei Schätzer bzw. Schätzfunktionen kennengelernt:

$$\begin{aligned}\bar{X} &= g(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i \\ S^2 &= g(X_1, \dots, X_n) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\end{aligned}$$

Sowohl $\bar{X}$ als auch S^2 sind selbst wieder Zufallsvariablen.

Definition 1.5. (Schätzwert)

Eine konkrete Realisierung t der Zufallsvariable T heißt Schätzwert.

$$\begin{array}{ccc} X_1, \dots, X_n & \text{Zufallsvariable} & T = g(X_1, \dots, X_n) \\ & \downarrow & \\ x_1, \dots, x_n & \text{Realisation} & t = g(x_1, \dots, x_n) \end{array}$$

Schätzer oder Schätzfunktionen wollen wir nutzen, um unbekannte Parameter von Verteilungen zu schätzen (siehe Beispiel 1.2). Sei also θ ein zu schätzender Parameter und $\hat{\theta}_n(X_1, \dots, X_n)$ ein Schätzer für θ . Welche Eigenschaften sollte $\hat{\theta}_n(X_1, \dots, X_n)$ haben?

1. Der zu schätzende Parameter sollte nicht tendenziell unter- bzw. überschätzt werden (Schätzer ist erwartungstreu).
2. Der zu schätzende Parameter wird mit wachsendem Stichprobenumfang immer besser getroffen (Schätzer ist konsistent).

Definition 1.6. (Erwartungstreue und Konsistenz)

Sei $\hat{\theta}_n(X_1, \dots, X_n)$ ein Schätzer für einen unbekannten Parameter θ . Man nennt $\hat{\theta}_n$ erwartungstreu bzw. unverfälscht, falls gilt:

$$E(\hat{\theta}_n) = \theta$$

Man nennt $\hat{\theta}_n$ konsistent, falls für jedes $\varepsilon > 0$ gilt:

$$P(|\hat{\theta}_n - \theta| < \varepsilon) \rightarrow 1 \quad \text{für} \quad n \rightarrow \infty$$

Bemerkung 1.7

Das Konzept der Konsistenz war uns bereits beim Gesetz der großen Zahlen im letzten Kapitel begegnet.

1.1 Schätzer Erwartungswert

Gegeben sei eine Zufallsvariable X mit unbekanntem Erwartungswert $E(X) = \mu$. Als Schätzer $\hat{\mu}$ für den Erwartungswert benutzen wir folgende Zufallsvariable

$$\hat{\mu}(X_1, \dots, X_n) := \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

wobei $X_1, \dots, X_n$ alle paarweise unabhängig sind und $X_i \sim X$ (d. h. alle X_i sind wie X verteilt). Sei nun eine Stichprobe $x_1, \dots, x_n$ von unabhängigen Realisationen von X gegeben, so schätzen wir den Erwartungswert mittels:

$$\hat{\mu}(x_1, \dots, x_n) := \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Satz 1.8

Der Schätzer $\hat{\mu}$ für den Erwartungswert μ einer Verteilung X ist erwartungstreu und konsistent.

1.2 Schätzer Varianz

Gegeben sei eine Zufallsvariable X mit unbekannter Varianz $\text{Var}(X) = \sigma^2$. Als Schätzer $\hat{\sigma}^2$ für die Varianz benutzen wir folgende Zufallsvariable

$$\hat{\sigma}^2(X_1, \dots, X_n) := S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n \cdot \bar{X}^2 \right)$$

wobei $X_1, \dots, X_n$ alle paarweise unabhängig sind und $X_i \sim X$ (d. h. alle X_i sind wie X verteilt). Sei nun eine Stichprobe $x_1, \dots, x_n$ von unabhängigen Realisationen von X gegeben, so schätzen wir die Varianz mittels:

$$\hat{\sigma}^2(x_1, \dots, x_n) := s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2 \right)$$

Hierbei ist $\bar{X}$ bzw. $\bar{x}$ der im letzten Abschnitt besprochene Schätzer des Mittelwertes.

Satz 1.9

Der Schätzer $\hat{\sigma}^2$ für die Varianz σ^2 einer Verteilung X ist erwartungstreu und konsistent (falls $E(X^4) < \infty$ gilt).

Bemerkung 1.10

1. Die Bedingung $E(X^4) < \infty$ wird in den von uns betrachteten Situationen stets erfüllt sein.
2. Wir teilen beim Schätzer $\hat{\sigma}^2$ durch $n-1$, um einen erwartungstreuen Schätzer für die

Varianz zu erhalten. Man nennt diesen Schätzer auch die korrigierte Stichprobenvarianz, er kommt insbes. dann zum Einsatz, wenn der Erwartungswert μ von X nicht bekannt ist.

3. Ist der Erwartungswert μ von X hingegen bekannt, so liefert der folgende Schätzer

$$\tilde{S}_X^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

einen erwartungstreuen Schätzer. Man nennt diesen Schätzer auch die unkorrigierte Stichprobenvarianz.

4. Da uns i. d. R. der Erwartungswert der Verteilung nicht bekannt ist, verwenden wir ausschließlich die korrigierte Stichprobenvarianz als Schätzer im Rahmen dieser Vorlesung.

1.3 Schätzer Standardabweichung

Wir hatten im letzten Abschnitt einen Schätzer für die Varianz entwickelt. Wie schätzen wir nun die Standardabweichung? Einfach als Wurzel aus dem Schätzer für die Varianz? Leider liefert $\sqrt{\hat{\sigma}^2}$ jedoch im Allgemeinen keinen erwartungstreuen Schätzer!

Bemerkung 1.11

Dies kann leicht mit Excel überprüft werden. Simuliere hierzu eine normalverteilte Zufallsvariable und berechne aus dieser simulierten Stichprobe die Varianz sowie die Standardabweichung durch Wurzelziehen. Man sieht dabei, dass dieser Wert systematisch zu niedrig und damit kein guter Schätzer ist.

Bemerkung 1.12

Der Schätzer $\sqrt{\hat{\sigma}^2}$ ist nicht erwartungstreu! D. h. es gilt im Allgemeinen:

$$E(\sqrt{\hat{\sigma}^2}) \neq \sigma$$

Im Falle normalverteilter Zufallsvariablen können wir jedoch mit folgender Korrektur einen erwartungstreuen Schätzer erhalten.

Satz 1.13

Sei $X \sim N(\mu, \sigma^2)$ und sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen von X . Der Schätzer

$$c_n \cdot \sqrt{\hat{\sigma}^2}$$

mit $c_n = \sqrt{\frac{n-1}{2}} \cdot \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})}$ (wobei Γ die Gamma-Funktion bezeichnet) ist ein erwartungstreuer Schätzer der Standardabweichung von X .

Bemerkung 1.14

1. Die Gamma-Funktion ist wie folgt definiert:

$$\Gamma(x) := \int_0^{\infty} t^{x-1} \exp(-t) dt$$

Für die Gamma-Funktion gilt für $n \in \mathbb{N}$:

$$\Gamma(n+1) = n!$$

2. Die konkreten Werte der Gamma-Funktion können Tabellen entnommen werden.
3. Für große n ($n \geq 10$) liegt c_n nahe bei 1. Die Korrektur ist mithin marginal und kann vernachlässigt werden.
4. Die Werte für c_n mit $n = 2, \dots, 10$ sind im Folgenden tabelliert:

n	2	3	4	5	6	7	8	9	10
c_n	1.253	1.128	1.085	1.064	1.051	1.042	1.036	1.032	1.028

Aufgabe 1.15

Gegeben sind die folgenden unabhängigen Realisationen einer normalverteilten Zufallsvariable X :

2.65 7.55 5.53 4.97 4.43 4.41 5.94 5.56 2.24 4.84

Schätze den Erwartungswert, die Varianz und die Standardabweichung erwartungstreu. (Hinweis: Bei den Simulationen handelt es sich um 10 Werte einer Normalverteilung mit $\mu = 5$ und $\sigma^2 = 4$.)

1.4 Schätzer Wahrscheinlichkeit

Sei X eine Bernoulli-verteilte Zufallsvariable mit $P(X = 1) = p$ und $P(X = 0) = 1 - p$. Als Schätzer $\hat{p}$ für die Wahrscheinlichkeit p benutzen wir folgende Zufallsvariable

$$\hat{p}(X_1, \dots, X_n) := \frac{1}{n} \sum_{i=1}^n X_i$$

wobei $X_1, \dots, X_n$ alle paarweise unabhängig sind mit $X_i \sim X$ (d. h. alle X_i sind wie X verteilt). Sei nun eine Stichprobe $x_1, \dots, x_n$ von unabhängigen Realisationen von X gegeben, so schätzen wir den Anteil mittels:

$$\hat{p}(x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n x_i = \frac{\text{Anzahl der Stichprobenelemente mit Ausprägung 1}}{n}$$

Satz 1.16

Der Schätzer $\hat{p}$ für die Wahrscheinlichkeit $p = P(X = 1)$ einer Bernoulli-verteilten Zufallsvariable X ist erwartungstreu und konsistent.

2 Intervallschätzer

Wir hatten uns im letzten Abschnitt mit sog. Punktschätzern befasst. Natürlich ist klar, dass es unwahrscheinlich ist, dass der „wahre“ Parameter mit unserem Schätzer übereinstimmt (eine andere Stichprobe wird i. d. R. bereits zu einem anderen Schätzer führen). Aus diesem Grunde gehen wir in diesem Abschnitt einen Schritt weiter. Wir wollen nun zusätzlich zu unseren Punktschätzern noch sog. Konfidenzintervalle konstruieren, innerhalb derer der „wahre“ Parameter apriori mit hoher Wahrscheinlichkeit liegt. Hierzu müssen wir jedoch im ersten Schritt definieren, was wir darunter verstehen wollen. Der typische Ablauf beim Schätzen ist wie folgt:

1. Erheben der Daten
2. Schätzen des gewünschten Parameters mittels geeignetem Punktschätzer
3. Konstruktion eines Intervalles um den Punktschätzer

Liegt die Wahrscheinlichkeit bei diesem Vorgehen bei $1 - \alpha$ (z. B. mit $\alpha = 0.05$ oder $\alpha = 0.01$), dass der wahre Parameter innerhalb dieses Intervalls liegt, so sprechen wir von einem Konfidenzintervall zum Vertrauensniveau (oder kurz Niveau) $1 - \alpha$. Konkret heißt dies: Bei einem Konfidenzintervall zum Niveau $1 - 0.05 = 0.95$ liegt der wahre Parameter in durchschnittlich 95 von 100 bestimmten Konfidenzintervallen. Die folgende Definition fasst dies zusammen.

Definition 2.1. (Konfidenzintervall)

Ein Intervall, welches a priori mit einer gegebenen (i. d. R. hohen) Wahrscheinlichkeit $1 - \alpha$ (z. B. für $\alpha = 0.05$ oder $\alpha = 0.01$) den „wahren“ oder tatsächlichen Parameter θ enthält, wird Konfidenzintervall (auch Vertrauensintervall oder Vertrauensbereich) zum Vertrauensniveau (kurz Niveau) $1 - \alpha$ genannt.

Die a priori Wahrscheinlichkeit, dass der Parameter θ nicht im Konfidenzintervall liegt ist damit α . Man nennt α aus diesem Grunde auch Irrtumswahrscheinlichkeit.

Bemerkung 2.2

1. Der Begriff a priori bezieht sich auf die Tatsache, dass beim oben beschriebenen Vorgehen nur anfangs – nämlich beim Ziehen der Stichprobe – der Zufalls ins Spiel kommt, alles folgende ist dann deterministisch (Berechnung des Schätzers und des Konfidenzintervalls). Vor diesem Hintergrund ist auch die Aussage falsch, dass der wahre Parameter mit der Wahrscheinlichkeit $1 - \alpha$ in einem konkret bestimmten Konfidenzintervall liegt.
2. Man beachte den Unterschied zu Zufallsstrebereichen, die wir im letzten Kapitel für normalverteilte Zufallsvariablen kennengelernt hatten. Hier waren der Erwartungswert μ

und die Standardabweichung σ der Normalverteilung bekannt und das konstruierte Intervall enthielt die Zufallsvariable X mit einer gegebenen Wahrscheinlichkeit $1 - \alpha$ (dies kann natürlich völlig analog für den Mittelwert aus unabhängigen und wie X verteilten Zufallsvariablen formuliert werden). Bei Konfidenzintervallen hingegen ist der wahre Parameter (bspw. der Erwartungswert μ) unbekannt und das Intervall wird auf Basis des Schätzers (bspw. des Mittelwerts $\bar{x}$) konstruiert und soll eine Aussage über die Lage des wahren Parameters machen.

2.1 Intervallschätzer für Normalverteilungen

In diesem Abschnitt sei X stets eine normalverteilte Zufallsvariable, d. h. $X \sim N(\mu, \sigma^2)$ mit Erwartungswert $E(X) = \mu$ und Varianz $\text{Var}(X) = \sigma^2$.

2.1.1 Intervallschätzer Erwartungswert bei bekannter Varianz

Wir möchten nun ein Konfidenzintervall für den Erwartungswert μ bei bekannter Varianz bestimmen. Dazu seien $X_1, \dots, X_n$ unabhängige Zufallsvariable mit $X_i \sim X$ (d. h. alle X_i sind wie X verteilt und haben insbes. den gleichen Erwartungswert und die gleiche Varianz). Dann gilt mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

also

$$P\left(-z_{1-\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

bzw.

$$P\left(\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha. \quad (7)$$

Mit Wahrscheinlichkeit $1 - \alpha$ liegt der Erwartungswert μ also in dem in Formel (7) definierten Intervall. Sei nun $x_1, \dots, x_n$ eine Stichprobe von unabhängigen Realisationen von X . Das Konfidenzintervall zum Niveau $1 - \alpha$ lautet dann

$$\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right]$$

wobei $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ der Mittelwert aus der Stichprobe ist. Dies ist ein sog. zweiseitiges Konfidenzintervall. Ganz analog können wir einseitige Konfidenzintervalle bestimmen.

Satz 2.3. (Konfidenzintervalle Erwartungswert bei bekannter Varianz)

Sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable X mit bekannter Varianz σ^2 . Ein Konfidenzintervall zum Niveau $1 - \alpha$ (bzw. mit einer Irrtumswahrscheinlichkeit von α) für den Erwartungswert μ ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$	μ liegt zwischen ... und ...
einseitig nach unten begrenzt	$\left[\bar{x} - z_{1-\alpha} \frac{\sigma}{\sqrt{n}}, \infty \right)$	μ ist größer als ...
einseitig nach oben begrenzt	$\left(-\infty, \bar{x} + z_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right]$	μ ist kleiner als ...

Hierbei ist $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

Bemerkung 2.4

1. Die a priori Wahrscheinlichkeit, dass μ im Konfidenzintervall liegt, beträgt $1 - \alpha$. Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt.
2. Für n gegen unendlich strebt $\frac{\sigma}{\sqrt{n}}$ (bei gegebenem Konfidenzniveau) gegen Null. Damit werden unsere zweiseitigen Konfidenzintervalle immer kleiner.
3. Mit steigendem Konfidenzniveau werden die Konfidenzintervalle (bei festem n) immer größer.
4. Soll ein zweiseitiges Konfidenzintervall die Länge L nicht überschreiten, so muss für den Stichprobenumfang n gelten:

$$n \geq \left(\frac{2z_{1-\alpha/2}\sigma}{L} \right)^2$$

5. Die zweiseitigen Konfidenzintervalle sind symmetrisch um $\bar{x}$.

Excel 2.5. (Quantile z_α der Standardnormalverteilung)

Mittels der Funktion **NORM.S.INV(p)** können ab Excel-Version 2011 die Quantile der Standardnormalverteilung berechnet werden. Der Eingabeparameter **p** ist der Wert, dessen Quantil berechnet werden soll, d. h. $p = \alpha$ für das Quantil z_α .

In älteren Excel-Versionen kann die Funktion **STANDNORMINV(p)** genutzt werden.

Beispiel 2.6

Einer Schraubenproduktion wurde eine Stichprobe von 10 Schrauben entnommen. Die Stichprobe ergab:

i	1	2	3	4	5	6	7	8	9	10
x_i in mm	10	8	9	10	11	11	9	12	8	9

Wir nehmen an, dass die Schraubenlänge X normalverteilt ist mit $\sigma^2 = 4 \text{ mm}^2$, d. h. $X \sim N(\mu, 4)$. Ein zweiseitiges Konfidenzintervall für den Erwartungswert μ zum Niveau $0.95 = 1 - 0.05$ bestimmt sich wie folgt. Auf Basis der Parameter

$$\begin{aligned}\alpha &= 0.05 \\ n &= 10 \\ \bar{x} &= 9.7 \\ \sigma &= 2 \\ z_{1-\alpha/2} &= z_{0.975} = 1.9600\end{aligned}$$

ergibt sich:

$$\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right] = \left[9.7 - 1.9600 \cdot \frac{2}{\sqrt{10}}, 9.7 + 1.9600 \cdot \frac{2}{\sqrt{10}} \right] = [8.46, 10.94]$$

Bemerkung 2.7

- Wie oben beschrieben, gilt für $\alpha = 0.05$ (wie im letzten Beispiel gewählt), dass bei durchschnittlich 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt. Dies macht natürlich keine Aussage über ein einzelnes Konfidenzintervall (wie im letzten Beispiel berechnet). Ob ein konkretes Konfidenzintervall zu den 95 Intervallen gehört, die den wahren Parameter enthalten, oder zu den 5 Intervallen, die ihn nicht enthalten, kann man nicht wissen. Da jedoch die Anzahl der Konfidenzintervalle, die den wahren Parameter nicht enthalten, klein ist, ist ein gewisses Vertrauen gerechtfertigt, dass dieser Fall nicht eingetreten ist (daher auch der Begriff Konfidenz- oder Vertrauensintervall).
- Der letzte Punkt zeigt nochmals deutlich ein Grundproblem der schließenden Statistik: Aussagen auf Basis von Stichproben können falsch sein!

Aufgabe 2.8

Die Messwerte einer normalverteilten Zufallsvariable mit bekannter Standardabweichung $\sigma = 4.1$ betragen 4, 12, 8, 7, 3. Berechne

- ein zweiseitiges Konfidenzintervall für μ zur Irrtumswahrscheinlichkeit 5 % sowie
- ein nach unten beschränktes einseitiges Konfidenzintervall für μ zur Irrtumswahrscheinlichkeit 3.5 %.

2.1.2 Intervallschätzer Erwartungswert bei unbekannter Varianz


Wir möchten nun ein Konfidenzintervall für den Erwartungswert μ bei unbekannter Varianz bestimmen. Dazu seien $X_1, \dots, X_n$ unabhängige Zufallsvariable mit $X_i \sim X$ (d. h. alle X_i sind wie X verteilt und haben insbes. den gleichen Erwartungswert und die gleiche Varianz). Dann gilt mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ und $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

wobei t_{n-1} die t -Verteilung mit $n-1$ Freiheitsgraden bezeichnet (wir werden dies im Rahmen der Vorlesung jedoch nicht herleiten).

Bemerkung 2.9

1. Wir werden uns im Rahmen der Vorlesung nicht weiter mit der t -Verteilung beschäftigen.
2. Sei $p \in (0, 1)$. Wir bezeichnen mit $t_{n;p}$ das p -Quantil der t -Verteilung mit n Freiheitsgraden.
3. Analog zur Standardnormalverteilung gilt die folgende Symmetrie: $t_{n;p} = -t_{n;1-p}$.
4. Die Quantile der t -Verteilung zu gegebenem Freiheitsgrad n können aus Verteilungstabellen entnommen werden.
5. Für große n (i. d. R. $n \geq 30$) gilt $t_n(x) \approx \Phi(x)$, d. h. die t -Verteilung kann durch die Standardnormalverteilung approximiert werden. Insbesondere gilt dann $t_{n;p} \approx z_p$.
6. Im Folgenden ist die Dichte der t -Verteilung für einige Freiheitsgrade n beispielhaft dargestellt. Die Standardnormalverteilung $N(0, 1)$ ist in rot dargestellt.



Wir können nun ganz analog wie im letzten Abschnitt vorgehen, müssen dabei jedoch die t -Verteilung heranziehen. Es gilt mithin

$$P\left(-t_{n-1;1-\alpha/2} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{n-1;1-\alpha/2}\right) = 1 - \alpha$$

bzw.

$$P\left(\bar{X} - t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}}\right) = 1 - \alpha. \quad (8)$$

Ganz analog wie im letzten Abschnitt, ergibt sich der folgende Satz.

Satz 2.10. (Konfidenzintervalle Erwartungswert bei unbekannter Varianz)

Sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable X mit unbekannter Varianz. Ein Konfidenzintervall zum Niveau $1 - \alpha$ (bzw. mit einer Irrtumswahrscheinlichkeit von α) für den Erwartungswert μ ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$\left[\bar{x} - t_{n-1;1-\alpha/2} \frac{s_x}{\sqrt{n}}, \bar{x} + t_{n-1;1-\alpha/2} \frac{s_x}{\sqrt{n}}\right]$	μ liegt zwischen ... und ...
einseitig nach unten begrenzt	$\left[\bar{x} - t_{n-1;1-\alpha} \frac{s_x}{\sqrt{n}}, \infty\right)$	μ ist größer als ...
einseitig nach oben begrenzt	$\left(-\infty, \bar{x} + t_{n-1;1-\alpha} \frac{s_x}{\sqrt{n}}\right]$	μ ist kleiner als ...

Hierbei ist $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ und $s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

Bemerkung 2.11

1. Die a priori Wahrscheinlichkeit, dass μ im Konfidenzintervall liegt, beträgt $1 - \alpha$. Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt.
2. Für n gegen unendlich strebt $\frac{s_x}{\sqrt{n}}$ (bei gegebenem Konfidenzniveau) gegen Null. Damit werden unsere zweiseitigen Konfidenzintervalle immer kleiner.
3. Mit steigendem Konfidenzniveau werden die Konfidenzintervalle (bei festem n) immer größer.
4. Die zweiseitigen Konfidenzintervalle sind symmetrisch um $\bar{x}$.
5. Die Bestimmung des Stichprobenumfangs, damit eine bestimmte Länge L des Konfidenzintervalls nicht überschritten wird, ist schwierig, da wir die Varianz nicht vorab kennen.
6. Aufgrund der Approximation der t -Verteilung durch die Normalverteilung für große n ,

können in diesem Fall die Quantile der t -Verteilung durch die der Standardnormalverteilung ersetzt werden.

Excel 2.12. (Quantile $t_{n;p}$ der t -Verteilung)

Mittels der Funktion `T.INV(p, df)` können ab Excel-Version 2011 die Quantile der t -Verteilung berechnet werden. Die Eingabeparameter sind dabei:

- $p - p$
- $df - n$

In älteren Excel-Versionen kann die Funktion `TINV(p, df)` genutzt werden: **hier ist allerdings Vorsicht geboten!** Um das Quantil $t_{n;p}$ für $p > 0.5$ zu erhalten, muss $2 \cdot (1 - p)$ für p eingegeben werden.

Beispiel 2.13. (Fortsetzung)

Einer Schraubenproduktion wurde eine Stichprobe von 10 Schrauben entnommen. Die Stichprobe ergab:

i	1	2	3	4	5	6	7	8	9	10
x_i in mm	10	8	9	10	11	11	9	12	8	9

Wir nehmen an, dass die Schraubenlänge X normalverteilt ist mit σ^2 unbekannt, d. h. $X \sim N(\mu, \sigma^2)$. Ein zweiseitiges Konfidenzintervall für den Erwartungswert μ zum Niveau 0.95 = $1 - 0.05$ bestimmt sich wie folgt. Auf Basis der Parameter

$$\begin{aligned}
 \alpha &= 0.05 \\
 n &= 10 \\
 \bar{x} &= 9.7 \\
 s_x &= 1.3375 \\
 t_{n-1;1-\alpha/2} &= t_{9;0.975} = 2.2622
 \end{aligned}$$

ergibt sich:

$$\begin{aligned}
 \left[\bar{x} - t_{n-1;1-\alpha/2} \frac{s_x}{\sqrt{n}}, \bar{x} + t_{n-1;1-\alpha/2} \frac{s_x}{\sqrt{n}} \right] &= \left[9.7 - 2.2622 \cdot \frac{1.3375}{\sqrt{10}}, 9.7 + 2.2622 \cdot \frac{1.3375}{\sqrt{10}} \right] \\
 &= [8.74, 10.66]
 \end{aligned}$$

Aufgabe 2.14

Die Messwerte einer normalverteilten Zufallsvariable mit unbekannter Standardabweichung betragen 4, 12, 8, 7, 3. Berechne

1. ein zweiseitiges Konfidenzintervall für μ zur Irrtumswahrscheinlichkeit 5 % sowie
2. ein nach unten beschränktes einseitiges Konfidenzintervall für μ zur Irrtumswahrscheinlichkeit 1 %.

Aufgabe 2.15

Bei 10 Messungen der Streckgrenze X des Kohlenstoffstahls St 70 ergaben sich folgende Werte (in N/mm^2):

332, 354, 338, 340, 345, 360, 366, 352, 346, 342

Wir nehmen an, dass die Streckgrenze normalverteilt ist. Ermittle ein zweiseitiges Konfidenzintervall zum Niveau 0.95 für

1. den Erwartungswert der Streckgrenze bei unbekannter Varianz,
2. den Erwartungswert der Streckgrenze bei bekannter Varianz von $105 \text{ N}^2/\text{mm}^4$.

Wie groß muss der Stichprobenumfang im zweiten Fall mindestens gewählt werden, damit der Schätzer mit einer Wahrscheinlichkeit von 95 % um höchstens 4 N/mm^2 vom wahren Parameter abweicht.

2.1.3 Intervallschätzer Differenz zweier Erwartungswerte bei bekannter Varianz

Wir möchten nun ein Konfidenzintervall für die Differenz der Erwartungswerte zweier Normalverteilungen bei bekannter Varianz bestimmen. Seien X und Y zwei unabhängige normalverteilte Zufallsvariablen mit $X \sim N(\mu_X, \sigma_X^2)$ und $Y \sim N(\mu_Y, \sigma_Y^2)$. Nach dem Additionssatz für normalverteilte Zufallsvariable gilt:

$$X - Y \sim N(\mu_X - \mu_Y, \sigma_X^2 + \sigma_Y^2)$$

Wir können damit völlig analog zum Vorgehen in Abschnitt 2.1.1 ein Konfidenzintervall für die Differenz der Erwartungswerte konstruieren. Dazu seien $X_1, \dots, X_n$ unabhängige Zufallsvariablen mit $X_i \sim X$ und $Y_1, \dots, Y_m$ unabhängige Zufallsvariablen mit $Y_i \sim Y$, dann gilt

$$\frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\left(\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}\right)} \sim N(0, 1)$$

mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ und $\bar{Y} = \frac{1}{m} \sum_{i=1}^m Y_i$. Völlig analog zum Vorgehen in Abschnitt 2.1.1 erhalten wir die folgenden Konfidenzintervalle.

Satz 2.16. (Konfidenzintervalle Differenz Erwartungswerte bei bekannter Varianz)

Sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable X mit bekannter Varianz σ_X^2 und sei $y_1, \dots, y_m$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable Y mit bekannter Varianz σ_Y^2 . Ein Konfidenzintervall zum Niveau $1 - \alpha$ (bzw. mit einer Irrtumswahrscheinlichkeit von α) für die Differenz der Er-

wartungswert $\mu_X - \mu_Y$ ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$\left[(\bar{x} - \bar{y}) - z_{1-\alpha/2} \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}, (\bar{x} - \bar{y}) + z_{1-\alpha/2} \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right]$	$\mu_X - \mu_Y$ liegt zwischen ... und ...
einseitig nach unten begrenzt	$\left[(\bar{x} - \bar{y}) - z_{1-\alpha} \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}, \infty \right)$	$\mu_X - \mu_Y$ ist größer als ...
einseitig nach oben begrenzt	$\left(-\infty, (\bar{x} - \bar{y}) + z_{1-\alpha} \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right]$	$\mu_X - \mu_Y$ ist kleiner als ...

Hierbei ist $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ und $\bar{y} = \frac{1}{m} \sum_{i=1}^m y_i$.

Bemerkung 2.17

1. Die a priori Wahrscheinlichkeit, dass $\mu_X - \mu_Y$ im Konfidenzintervall liegt, beträgt $1 - \alpha$. Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt.
2. Für n und m gegen unendlich strebt $\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}$ (bei gegebenem Konfidenzniveau) gegen Null. Damit werden unsere zweiseitigen Konfidenzintervalle immer kleiner.
3. Mit steigendem Konfidenzniveau werden die Konfidenzintervalle (bei festem n und m) immer größer.
4. Die zweiseitigen Konfidenzintervalle sind symmetrisch um $\bar{x} - \bar{y}$.
5. Der obige Satz gilt insbesondere natürlich bei gleichen Varianzen.

Aufgabe 2.18

Zwei baugleiche Maschinen A und B produzieren Nägel mit einer bekannten Standardabweichung von $\sigma = 2$ mm. Nach vielen Jahren in Produktion kann sich jedoch der Soll- bzw. Erwartungswert der produzierten Nägel verschoben haben. Hierzu nehmen wir eine Stichprobe von 20 Nägeln beider Maschinen und erhalten als Mittelwerte $\bar{x}_A = 101.7$ und $\bar{x}_B = 98.2$. Bestimme ein einseitiges nach unten begrenztes Konfidenzintervall für die Differenz der Erwartungswerte zum Niveau 0.95. Interpretiere das Ergebnis im Hinblick auf die Frage, ob die Maschinen noch vergleichbar arbeiten.

2.1.4 Intervallschätzer Differenz zweier Erwartungswerte bei unbekannter gleicher Varianz

Wir möchten nun ein Konfidenzintervall für die Differenz der Erwartungswerte zweier Normalverteilungen bei unbekannter (aber gleicher) Varianz bestimmen. Seien X und Y zwei unabhängige normalverteilte Zufallsvariablen mit $X \sim N(\mu_X, \sigma^2)$ und $Y \sim N(\mu_Y, \sigma^2)$ (insbes. seien also die Varianzen gleich). Nach dem Additionssatz für normalverteilte Zufallsvariable gilt:

$$X - Y \sim N(\mu_X - \mu_Y, \sigma^2 + \sigma^2)$$

Wir können damit völlig analog zum Vorgehen in Abschnitt 2.1.2 ein Konfidenzintervall mittels der t -Verteilung konstruieren. Seien $X_1, \dots, X_n$ unabhängige Zufallsvariablen mit $X_i \sim X$ und $Y_1, \dots, Y_m$ unabhängige Zufallsvariablen mit $Y_i \sim Y$, dann gilt

$$\frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\tilde{S} \left(\sqrt{\frac{1}{n} + \frac{1}{m}} \right)} \sim t_{n+m-2}$$

mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $\bar{Y} = \frac{1}{m} \sum_{i=1}^m Y_i$ und der gewichteten Varianz:

$$\tilde{S}^2 = \frac{(n-1) \cdot S_X^2 + (m-1) \cdot S_Y^2}{n+m-2}$$

Völlig analog zum Vorgehen in Abschnitt 2.1.2 erhalten wir die folgenden Konfidenzintervalle.

Satz 2.19. (Konfidenzintervalle Differenz Erwartungswerte bei unbekannter gleicher Varianz)

Sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable X mit unbekannter Varianz σ^2 und sei $y_1, \dots, y_m$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable Y mit unbekannter Varianz σ^2 (insbes. seien also die Varianzen von X und Y gleich). Ein Konfidenzintervall zum Niveau $1 - \alpha$ (bzw. mit einer Irrtumswahrscheinlichkeit von α) für die Differenz der Erwartungswert $\mu_X - \mu_Y$ ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$[(\bar{x} - \bar{y}) - s \cdot t_{n+m-2; 1-\alpha/2}, (\bar{x} - \bar{y}) + s \cdot t_{n+m-2; 1-\alpha/2}]$	$\mu_X - \mu_Y$ liegt zw. ... und ...
eins. nach unten begrenzt	$[(\bar{x} - \bar{y}) - s \cdot t_{n+m-2; 1-\alpha}, \infty)$	$\mu_X - \mu_Y$ ist gr. als ...
eins. nach oben begrenzt	$(-\infty, (\bar{x} - \bar{y}) + s \cdot t_{n+m-2; 1-\alpha}]$	$\mu_X - \mu_Y$ ist kl. als ...

Hierbei ist $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{y} = \frac{1}{m} \sum_{i=1}^m y_i$, $s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$, $s_y^2 = \frac{1}{m-1} \sum_{i=1}^m (y_i - \bar{y})^2$

und $s = \sqrt{(n-1)s_x^2 + (m-1)s_y^2} \cdot \sqrt{\frac{n+m}{n \cdot m \cdot (n+m-2)}}$.

Bemerkung 2.20

1. Die a priori Wahrscheinlichkeit, dass $\mu_X - \mu_Y$ im Konfidenzintervall liegt, beträgt $1 - \alpha$. Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt.
2. Für n und m gegen unendlich strebt s (bei gegebenem Konfidenzniveau) gegen Null. Damit werden unsere zweiseitigen Konfidenzintervalle immer kleiner.
3. Mit steigendem Konfidenzniveau werden die Konfidenzintervalle (bei festem n und m) immer größer.
4. Die zweiseitigen Konfidenzintervalle sind symmetrisch um $\bar{x} - \bar{y}$.
5. Aufgrund der Approximation der t -Verteilung durch die Standardnormalverteilung für große n , können in diesem Fall die Quantile der t -Verteilung durch die der Standardnormalverteilung ersetzt werden.

Aufgabe 2.21

Ein Motorradrennstall testet Reifen zweier Hersteller A und B . Hierzu wurde deren Lebensdauer X_A und X_B bei 201 Reifensätzen getestet. Es ergaben sich folgende Werte:

	A	B
$\bar{x}$	57.2	54.8
s_x	4	5.5

Die Lebensdauern der beiden Reifentypen sind voneinander unabhängig und jeweils normalverteilt mit gleichen Varianzen. Bestimme ein zweiseitiges Konfidenzintervall zum Niveau 0.95 für den Unterschied ihrer Lebensdauern.

2.1.5 Intervallschätzer Varianz


Wir möchten nun ein Konfidenzintervall für die Varianz σ^2 bestimmen. Dazu seien $X_1, \dots, X_n$ unabhängige Zufallsvariable mit $X_i \sim X$. Dann gilt mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ und $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

$$\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi_{n-1}^2$$

wobei χ_{n-1}^2 die χ^2 -Verteilung mit $n-1$ Freiheitsgraden bezeichnet (wir werden dies im Rahmen der Vorlesung jedoch nicht herleiten).

Bemerkung 2.22

1. Wir werden uns im Rahmen der Vorlesung nicht weiter mit der χ^2 -Verteilung beschäftigen. Wichtig ist, dass ihre Dichte nur für $x > 0$ definiert ist.
2. Darüber hinaus ist die χ^2 -Verteilung nicht symmetrisch. Dies müssen wir bei der Bestimmung der Konfidenzintervalle berücksichtigen.
3. Sei $p \in (0, 1)$. Wir bezeichnen mit $\chi_{n;p}^2$ das p -Quantil der χ^2 -Verteilung.
4. Die Quantile der χ^2 -Verteilung zu gegebenem Freiheitsgrad n können mittels Tabellen bestimmt werden.
5. Für $n > 100$ kann die χ^2 -Verteilung durch die Normalverteilung mit Erwartungswert n und Standardabweichung $\sqrt{2n}$ approximiert werden.
6. Im Folgenden ist die Dichte der χ^2 -Verteilung für einige Freiheitsgrade n beispielhaft dargestellt.



Wir können nun ganz analog wie im letzten Abschnitt verfahren, müssen dabei jedoch die χ^2 -Verteilung heranziehen und dabei beachten, dass diese nicht symmetrisch ist. Es gilt mithin

$$P\left(\chi_{n-1;\alpha/2}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{n-1;1-\alpha/2}^2\right) = 1 - \alpha$$

bzw.

$$P\left(\frac{(n-1)S^2}{\chi_{n-1;1-\alpha/2}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{n-1;\alpha/2}^2}\right) = 1 - \alpha \quad (9)$$

Ganz analog zum Vorgehen im letzten Abschnitt ergibt sich der folgende Satz.

Satz 2.23. (Konfidenzintervall Varianz bzw. Standardabweichung)

Sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen einer normalverteilten Zufallsvariable X mit unbekanntem Erwartungswert. Ein Konfidenzintervall zum Niveau $1 - \alpha$ (bzw. mit einer Irrtumswahrscheinlichkeit von α) für die Varianz σ^2 ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$\left[\frac{(n-1)s_x^2}{\chi_{n-1;1-\alpha/2}^2}, \frac{(n-1)s_x^2}{\chi_{n-1;\alpha/2}^2} \right]$	σ^2 liegt zw. ... und ...
einseitig nach unten begrenzt	$\left[\frac{(n-1)s_x^2}{\chi_{n-1;1-\alpha}^2}, \infty \right)$	σ^2 ist größer als ...
einseitig nach oben begrenzt	$\left[0, \frac{(n-1)s_x^2}{\chi_{n-1;\alpha}^2} \right]$	σ^2 ist kleiner als ...

Hier ist $s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

Ein Konfidenzintervall für die Standardabweichung σ ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$\left[\sqrt{\frac{(n-1)s_x^2}{\chi_{n-1;1-\alpha/2}^2}}, \sqrt{\frac{(n-1)s_x^2}{\chi_{n-1;\alpha/2}^2}} \right]$	σ liegt zw. ... und ...
einseitig nach unten begrenzt	$\left[\sqrt{\frac{(n-1)s_x^2}{\chi_{n-1;1-\alpha}^2}}, \infty \right)$	σ ist größer als ...
einseitig nach oben begrenzt	$\left[0, \sqrt{\frac{(n-1)s_x^2}{\chi_{n-1;\alpha}^2}} \right]$	σ ist kleiner als ...

Bemerkung 2.24

1. Die a priori Wahrscheinlichkeit, dass σ^2 bzw. σ im jeweiligen Konfidenzintervall liegt, beträgt $1 - \alpha$. Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt.
2. Für große Stichproben werden die Konfidenzintervalle (zu gegebenem Konfidenzniveau) tatsächlich klein.
3. Mit steigendem Konfidenzniveau werden die Konfidenzintervalle (bei festem n) immer größer.

Excel 2.25. (Quantile $\chi^2_{n;p}$ der χ^2 -Verteilung)

Mittels der Funktion `CHIQU.INV(p, df)` können ab Excel-Version 2011 die Quantile der χ^2 -Verteilung berechnet werden. Die Eingabeparameter sind dabei:

- `p` – p
- `df` – n

In älteren Excel-Versionen kann die Funktion `CHIINV(p, df)` genutzt werden: **hier ist allerdings Vorsicht geboten!** Um das Quantil $\chi^2_{n;p}$ zu erhalten, muss $1 - p$ für `p` eingegeben werden.

Aufgabe 2.26

Die Marketingabteilung einer Supermarktkette möchte für die Dimensionierung des Marktes wissen, wie viel Geld die Haushalte eines Stadtteils durchschnittlich für Lebensmittel ausgeben und wie diese Ausgaben streuen. Eine Stichprobe vom Umfang $n = 25$ ergab einen Mittelwert von $\bar{x} = 250$ € bei einer empirischen Standardabweichung von $s_x = 50$ €. Innerhalb welcher Grenzen ist mit einem Konfidenzniveau von 95 % der Parameter σ zu finden? Wir nehmen an, dass die Haushaltsausgaben normalverteilt sind.

2.2 Intervallschätzer Erwartungswert für beliebige Verteilungen

Sei X eine Zufallsvariable mit beliebiger Verteilung (insbes. also nicht notwendigerweise normalverteilt). Sei weiter $\mu = E(X)$ und $\sigma^2 = \text{Var}(X)$. Wir möchten nun ein Konfidenzintervall für den Erwartungswert $\mu = E(X)$ bestimmen. Seien dazu $X_1, \dots, X_n$ unabhängige Zufallsvariable mit $X_i \sim X$. Mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ gilt nach dem zentralen Grenzwertsatz

$$\bar{X} \rightarrow N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{für } n \rightarrow \infty$$

d. h. $\bar{X}$ ist für große n näherungsweise normalverteilt und wir können Konfidenzintervalle für μ approximativ völlig analog zum Fall von Normalverteilungen bestimmen.

Ist die Varianz bekannt, gehen wir wie in Abschnitt 2.1.1 vor, ansonsten wie in Abschnitt 2.1.2. Völlig analog gelten die in den entsprechenden Abschnitten gemachten Bemerkungen bis auf einen wesentlichen Unterschied.

Bemerkung 2.27

1. Nach dem zentralen Grenzwertsatz gilt für große n lediglich (bspw. bei bekannter Varianz):

$$P\left(-z_{1-\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right) \approx 1 - \alpha$$

Zwar gilt dies umso genauer, je größer n ist, aber eben nicht exakt. Damit ist auch das Konfidenzintervall **nicht exakt** sondern lediglich eine **Approximation**.

2. Die a priori Wahrscheinlichkeit (sowohl für den Fall bekannter als auch unbekannter Varianz), dass μ im jeweiligen Konfidenzintervall liegt, beträgt **nur approximativ** $1 - \alpha$ (für große n). Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich **ungefähr** 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt (für große n).
3. Für $n \geq 30$ gilt die Approximation i. d. R. jedoch recht gut.

Aufgabe 2.28

Eine Studie zur Analyse einer Krankheit X bei 100 Erkrankten ergab, dass die Krankheit im Durchschnitt mit 43 Jahren bei einer Standardabweichung von 7.3 Jahren auftrat. Berechne ein Konfidenzintervall zum Niveau 0.90 für das Alter der Erkrankung.

Aufgabe 2.29

Eine Umfrage bei 300 Pkw-Fahrern ergab eine durchschnittliche jährliche Fahrleistung von 15000 km bei einer Varianz von $110 \cdot 10^6 \text{ km}^2$. Bestimme ein zweiseitiges Konfidenzintervall für die mittlere jährliche Fahrleistung zum Niveau 0.95. Welche Annahmen müssen wir hierzu machen bzw. wie ist das Ergebnis zu interpretieren?

2.3 Intervallschätzer Wahrscheinlichkeit

Wir möchten nun ein Konfidenzintervall für den Parameter p einer Bernoulli-verteilten Zufallsvariable bestimmen. Sei hierzu X eine Bernoulli-verteilte Zufallsvariable mit $P(X = 1) = p$ und $P(X = 0) = 1 - p$. Seien nun $X_1, \dots, X_n$ unabhängige Zufallsvariable mit $X_i \sim X$. Mit $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ gilt nach dem zentralen Grenzwertsatz (wie im letzten Abschnitt):

$$\bar{X} \rightarrow N\left(p, \frac{p \cdot (1-p)}{n}\right) \quad \text{für } n \rightarrow \infty$$

Damit folgt, dass für große n gilt:

$$P\left(-z_{1-\alpha/2} \leq \frac{\bar{X} - p}{\frac{\sqrt{p(1-p)}}{\sqrt{n}}} \leq z_{1-\alpha/2}\right) \approx 1 - \alpha$$

Hieraus können wir ein **approximatives** Konfidenzintervall für p bestimmen (beachte jedoch, dass $\sigma = \sqrt{p(1-p)}$ noch auftaucht). Darüber hinaus fügen wir noch – da wir die diskrete Binomialverteilung mit der stetigen Normalverteilung approximiert haben – eine Stetigkeitskorrektur ein (diese soll die Beschränkung der Irrtumswahrscheinlichkeit durch α sicherstellen). Sei nun eine Stichprobe $x_1, \dots, x_n$ unabhängiger Realisationen von X gegeben, so erhalten wir ein Konfidenzintervall wie folgt

$$\left[\hat{p} - z_{1-\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} - \frac{0.5}{n}, \hat{p} + z_{1-\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} + \frac{0.5}{n} \right]$$

mit

$$\hat{p} = \frac{\text{Anzahl der Stichprobenelemente mit Ausprägung 1}}{n} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Satz 2.30. (Asymptotische Konfidenzintervalle Wahrscheinlichkeit)

Sei $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen einer Bernoulli-verteilten Zufallsvariable X mit $P(X = 1) = p$ und $P(X = 0) = 1 - p$. Ein **approximatives** Konfidenzintervall zum Niveau $1 - \alpha$ (bzw. mit einer **approximativen** Irrtumswahrscheinlichkeit von α) für die Wahrscheinlichkeit p ist wie folgt gegeben:

Art	Intervall	Beschreibung
zweiseitig	$\left[\hat{p} - z_{1-\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} - \frac{0.5}{n}, \hat{p} + z_{1-\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} + \frac{0.5}{n} \right]$	p liegt zwischen ... und ...
eins. nach unten begrenzt	$\left[\hat{p} - z_{1-\alpha} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} - \frac{0.5}{n}, 1 \right]$	p ist größer als ...
eins. nach oben begrenzt	$\left[0, \hat{p} + z_{1-\alpha} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} + \frac{0.5}{n} \right]$	p ist kleiner als ...

Hierbei ist:

$$\hat{p} = \frac{\text{Anzahl der Stichprobenelemente mit Ausprägung 1}}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Bemerkung 2.31

1. Es handelt sich dabei lediglich um ein **approximatives** Konfidenzintervall. Für $\alpha = 0.05$ bedeutet dies, dass bei durchschnittlich **ungefähr** 95 von 100 Konfidenzintervallen der wahre Parameter innerhalb dieser liegt (für große n). Beachte hierzu auch die entsprechenden Ausführungen des letzten Abschnitts.
2. Im konkreten Fall muss geprüft werden, ob die Approximation mittels Normalverteilung zulässig ist (vgl. Grenzwertsatz von de Moivre und Laplace).
3. Für große n ist die Stetigkeitskorrektur $\frac{0.5}{n}$ vernachlässigbar. Für kleine n soll der Korrekturfaktor $\frac{0.5}{n}$ die Beschränkung der Irrtumswahrscheinlichkeit durch α sicherstellen.
4. Für n gegen unendlich strebt $\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}$ (bei gegebenem Konfidenzniveau) gegen Null. Damit werden unsere zweiseitigen Konfidenzintervalle immer kleiner.

5. Mit steigendem Konfidenzniveau werden die Konfidenzintervalle (bei festem n) immer größer.
6. Es kann in Ausnahmefällen passieren, dass (infolge der Approximation durch die Normalverteilung) die untere bzw. obere Grenze des Konfidenzintervalls kleiner als 0 bzw. größer als 1 ist. In solchen Fällen wird die untere bzw. obere Grenze durch 0 bzw. 1 ersetzt.

Aufgabe 2.32

Eine Umfrage unter 2000 Wahlberechtigten ergab, dass 120 Partei A wählen würden. Kann zu einem Konfidenzniveau von 0.95 davon ausgegangen werden, dass Partei A die 5 %-Hürde überwindet?

Aufgabe 2.33

Bei der Herstellung von Transistoren lässt sich ein gewisser Anteil an fehlerhaften Transistoren nicht vermeiden. Zur Schätzung des Ausschussanteils werden der Produktion 160 Transistoren entnommen. Nach Prüfung stellen wir fest, dass sich darunter 12 defekte Transistoren befinden.

Bestimme ein zweiseitiges Konfidenzintervall zum Niveau 0.95 für den Ausschussanteil. Wie genau kann dieser geschätzt werden?

3 Hypothesentests

Wir wenden uns nun Hypothesentests zu und betrachten hierzu ein einführendes Beispiel.

Beispiel 3.1

Eine Maschine produziere Nägel, deren Solllänge 100 mm beträgt. Wir vermuten, dass die Maschine nicht mehr zum gewünschten Sollwert produziert (bspw. aufgrund von Verschleiß) und möchten dies untersuchen. Wir nehmen an, dass die Länge der produzierten Nägel X normalverteilt ist, mit langjährig bekannter Varianz $\sigma^2 = 4$ (d. h. $X \sim N(\mu, 4)$).

Wir wollen nun einen Test konzipieren, der zwischen den folgenden Hypothesen entscheidet: Der Nullhypothese (auch mit H_0 bezeichnet)

$$H_0 : \mu = 100$$

und der Alternativhypothese (auch mit H_1 bezeichnet)

$$H_1 : \mu \neq 100 .$$

Anschaulich bedeutet die Hypothese H_0 , dass die Maschine noch gemäß Sollwert produziert (also i. O. ist) und die Hypothese H_1 , dass die Maschine nicht mehr zum richtigen Sollwert produziert (also nicht i. O. ist und nachjustiert werden muss).

Wir wollen nun zwischen den beiden Hypothesen entscheiden und entnehmen dazu eine Stichprobe von 10 Nägeln. Gleichzeitig benötigen wir eine Regel, wann wir uns – auf Basis unserer Stichprobe – für H_0 und wann für H_1 entscheiden. Hierzu legen wir den folgenden sog. zentralen Streubereich (kurz: Streubereich) fest

$$[100 - 1.24, 100 + 1.24] = [98.76, 101.24]$$

zusammen mit folgender Regel:

- (I) Falls der Mittelwert $\bar{x}$ aus unserer Stichprobe **nicht** im Intervall $[98.76, 101.24]$ liegt, so verwerfen wir die Nullhypothese H_0 und entscheiden uns für die Alternativhypothese H_1 . Wir nehmen mithin an, dass die Maschine nicht mehr zum richtigen Sollwert produziert.
- (II) Falls der Mittelwert $\bar{x}$ aus unserer Stichprobe im Intervall $[98.76, 101.24]$ liegt, so verwerfen wir die Nullhypothese H_0 nicht. In diesem Falle spricht also nichts dagegen, dass die Maschine noch zum richtigen Sollwert produziert.

Im letzten Beispiel haben wir ein erstes einfaches Testverfahren kennengelernt. Wir wollen dieses nun näher untersuchen und widmen uns hierzu den folgenden Fragen.

(I) Welche Fehlentscheidungen können bei unserem Test auftreten?

Es gibt zwei mögliche Fehlentscheidungen, die wir im Folgenden diskutieren wollen.

- (a) *Mit welcher Wahrscheinlichkeit lehnen wir die Hypothese H_0 unberechtigter Weise ab (bzw. mit welcher Wahrscheinlichkeit kommen wir zum Ergebnis, dass die Maschine nicht mehr korrekt funktioniert, obwohl alles in Ordnung ist)?*

Wenn wir H_0 zugrunde legen (d. h. $X \sim N(100, 4)$ und damit $\bar{X} \sim N(100, \frac{4}{10})$), so gilt

$$P(98.76 \leq \bar{X} \leq 101.24) \approx 0.95,$$

d. h. mit einer Wahrscheinlichkeit von rund $1 - 0.95 = 0.05$ lehnen wir H_0 ab (kommen also zum Schluss, dass die Maschine nicht mehr korrekt funktioniert), obwohl sie zur gewünschten Soleinstellung von 100 mm produziert. Wir nennen dies auch einen Fehler 1. Art. Die Wahrscheinlichkeit hierfür (in unserem Beispiel also rund 0.05) nennen wir auch Signifikanzniveau des Tests. Man beachte, dass diese sehr klein ist.

Bemerkung 3.2

I. d. R. wird man umgekehrt vorgehen und das Signifikanzniveau des Tests vorgeben (bspw. $\alpha = 0.05$ oder $\alpha = 0.01$) und dann – unter Zugrundelegung von H_0 – den zentralen Streubereich bestimmen. Das entsprechende Vorgehen hierzu hatten wir in Bemerkung 12.24, Kapitel III (Wahrscheinlichkeitsrechnung) dargestellt.

- (b) *Mit welcher Wahrscheinlichkeit lehnen wir die Hypothese H_0 nicht ab, obwohl sie falsch ist (bzw. mit welcher Wahrscheinlichkeit kommen wir zum Ergebnis, dass die Maschine korrekt funktioniert, obwohl dies nicht der Fall ist)?*

Nehmen wir hierzu bspw. an, der Erwartungswert hätte sich auf 101.5 mm verschoben (d. h. $X \sim N(101.5, 4)$ und damit $\bar{X} \sim N(101.5, \frac{4}{10})$), so gilt

$$P(98.76 \leq \bar{X} \leq 101.24) \approx 0.34,$$

d. h. mit einer Wahrscheinlichkeit von rund 0.34 bemerken wir in diesem Falle eine veränderte Solleinstellung nicht. Wir kommen also zum Schluss, dass nichts dagegen spricht, dass die Maschine ordnungsgemäß funktioniert, obwohl sie nicht zur gewünschten Solleinstellung produziert. Wir nennen dies auch einen Fehler 2. Art.

Bemerkung 3.3

Leider haben wir die Wahrscheinlichkeit für einen Fehler 2. Art nicht unter Kontrolle. Diese kann – wie wir im letzten Beispiel gesehen haben – potentiell auch sehr groß sein. Nehmen wir bspw. an, der Erwartungswert hätte sich auf 100.01 mm verschoben, dann wäre die Wahrscheinlichkeit für einen Fehler 2. Art sogar rund 0.95! In solchen Extremfällen ist es natürlich schwer, die Änderung überhaupt festzustellen.

Die folgende Tabelle fasst noch einmal die möglichen Fehlentscheidungen bei statistischen Tests zusammen:

	H_0 ist wahr	H_1 ist wahr
Annahme von H_0	richtige Entscheidung	Fehler 2. Art
Ablehnung von H_0	Fehler 1. Art	richtige Entscheidung

Bemerkung 3.4

Es ist auch an dieser Stelle nochmals wichtig zu betonen, dass Aussagen und Entscheidungen, die auf Basis von Stichproben getroffen werden, natürlich falsch sein können.

(II) Wie kann man den Ausgang eines Tests interpretieren?

Betrachten wir folgende zwei Szenarien für Ablauf des Tests:

Szenario 1: Der Mittelwert der Nagellänge aus unserer Stichprobe von 10 Nägeln betrage $\bar{x} = 100.75$. Gemäß unserer Entscheidungsregel kommen wir zum Schluss, dass nichts gegen die Nullhypothese spricht, denn die Abweichung zwischen Mittelwert und Sollwert ist gering (auch bei ordnungsgemäß funktionierender Maschine kann es natürlich immer zu Abweichungen in der Produktion kommen). In diesem Szenario spricht also nichts gegen die Maschine. Beachte jedoch, dass ein Fehler 2. Art passiert sein kann, dessen Wahrscheinlichkeit wir nicht unter Kontrolle haben (und die potentiell sehr hoch sein kann). Mithin kann dieser Ausgang auch nicht als Beweis für die Funktionstüchtigkeit der Maschine erachtet werden. Es spricht lediglich nichts gegen ihre Funktionstüchtigkeit.

Szenario 2: Der Mittelwert der Nagellänge aus unserer Stichprobe von 10 Nägeln betrage $\bar{x} = 103.28$. Gemäß unserer Entscheidungsregel kommen wir zum Schluss, dass die Nullhypothese abzulehnen und die Alternativhypothese anzunehmen ist, denn die Abweichung zwischen Mittelwert und Sollwert ist zu groß. Eine derart große oder noch größere Abweichung ist bei funktionstüchtiger Maschine (wenn also H_0 wahr ist) nur sehr unwahrscheinlich (die Wahrscheinlichkeit wird durch das Signifikanzniveau $\alpha \approx 0.05$ nach oben beschränkt). Wir entscheiden uns daher dafür,

die Alternativhypothese anzunehmen, d. h. die Maschine arbeitet nicht mehr gemäß Sollvorgaben und muss nachjustiert werden. Beachte jedoch, dass ein Fehler 1. Art passiert sein kann. Die Wahrscheinlichkeit hierfür war jedoch klein und wir hatten sie vollständig unter Kontrolle, deshalb wird dieser Ausgang des Tests als statistisch signifikant (oder statistisch bewiesen) erachtet. Wir haben also einen guten Grund, an die Richtigkeit der Alternativhypothese zu glauben.

Bemerkung 3.5

Die folgenden beiden Aspekte sind zentral bei Hypothesentests:

1. Die Nullhypothese H_0 sollte nur dann abgelehnt werden, wenn die Stichprobe deutlich gegen H_0 spricht.
2. Nur das Verwerfen von H_0 ist eine statistisch signifikante Aussage.

3.1 Vorgehen bei statistischen Tests

Auf Basis des einführenden Beispiels können wir das allgemeine Vorgehen bei statistischen Tests ableiten.

1. Aufstellen der Nullhypothese H_0 und der Alternativhypothese H_1 .
2. Festlegen des Signifikanzniveaus α , d. h. der Wahrscheinlichkeit für einen Fehler 1. Art.
3. Berechnung des zentralen Streubereiches zum Signifikanzniveau α .
4. Erheben einer Stichprobe und Berechnen der zugehörigen Prüfgröße.
5. Entscheidung über Ablehnung oder Nicht-Ablehnung von H_0 .
6. Fazit für das konkrete Anwendungsproblem

Bemerkung 3.6

1. Das Signifikanzniveau wird oftmals auch als Irrtums- oder Fehlerwahrscheinlichkeit bezeichnet.
2. Wie bereits weiter oben erwähnt, gibt man bei Tests i. d. R. das Signifikanzniveau α vor und bestimmt daraus – unter Zugrundelegung von H_0 – den zentralen Streubereich (siehe auch Bemerkung 12.24, Kapitel III (Wahrscheinlichkeitsrechnung) für normalverteilte Zufallsvariablen).

In den folgenden Abschnitten möchten wir noch einige entscheidende Aspekte zur Wahl der Hypothesen und des Signifikanzniveaus statistischer Tests diskutieren.

3.1.1 Wahl der Hypothesen

Wir betrachten im Rahmen der Vorlesung nur Hypothesen, die sich auf einen unbekannten Parameter θ beziehen. Dieser wird i. d. R. ein unbekannter Erwartungswert einer Verteilung sein. Die folgenden Hypothesen sind dabei möglich.

Nullhypothese H_0	Alternativhypothese H_1	Art
$\theta = \theta_0$	$\theta \neq \theta_0$	zweiseitig
$\theta \leq \theta_0$	$\theta > \theta_0$	einseitig
$\theta \geq \theta_0$	$\theta < \theta_0$	einseitig

Auf Basis unseres einführenden Beispiels hatten wir bereits diskutiert, wie der Ausgang eines statistischen Tests zu interpretieren ist:

Nicht-Ablehnung von H_0

Da wir die Wahrscheinlichkeit für einen Fehler 2. Art nicht unter Kontrolle haben (diese kann potentiell sehr groß sein), ist die Nullhypothese H_0 in diesem Fall nicht statistisch bewiesen, es spricht lediglich nichts dagegen, dass H_0 richtig ist. Die Alternativhypothese H_1 konnte damit nicht erhärtet.

Ablehnung von H_0 und Annahme von H_1

Die Wahrscheinlichkeit für einen Fehler 1. Art haben wir unter Kontrolle (durch Wahl des Signifikanzniveaus α). Wenn α hinreichend klein ist, so tritt ein Fehler 1. Art nur selten auf. Bei Ablehnung von H_0 und Annahme von H_1 betrachten wir die Alternativhypothese H_1 daher als statistisch signifikant nachgewiesen (bei einem Signifikanzniveau α).

Die letzten beiden Aspekte zeigen, dass nur das Verwerfen von H_0 (bzw. die Annahme von H_1) eine statistisch abgesicherte Entscheidung ist. Die Nicht-Ablehnung von H_0 hingegen ist eine eher „schwache“ Aussage. Im Normalfall ist daher die Alternativhypothese H_1 diejenige, die statistisch signifikant nachgewiesen werden soll und die Hypothese H_0 (als logisches Gegenteil) mithin diejenige, die widerlegt werden soll. In unserem einführenden Beispiel wollen wir – sofern möglich – H_0 verwerfen und H_1 statistisch signifikant nachweisen. Hierdurch wäre ein signifikanter Nachweis erbracht, dass die Maschine nicht mehr gemäß Sollvorgaben produziert.

Beispiel 3.7

Wir wollen nachweisen, dass Rauchen die Lebenserwartung verkürzt. Hierzu wählen wir:

$$H_0 = \text{Lebenserwartung Raucher} \geq \text{Lebenserwartung Nichtraucher}$$

$$H_1 = \text{Lebenserwartung Raucher} < \text{Lebenserwartung Nichtraucher}$$

Führt unsere Stichprobe dann zur Ablehnung von H_0 , so ist H_1 statistisch signifikant nachgewiesen (mit Signifikanzniveau α).

Es gibt Ausnahmen von dieser Regel, bspw. wenn die Ablehnung einer Hypothese einen

gefährlichen (teuren, ...) Fehler darstellt. In derartigen Fällen sollte diese Hypothese zur Nullhypothese H_0 gemacht werden.

Beispiel 3.8

Das Wasser einer neu erschlossenen Quelle wird nur dann als Trinkwasser zugelassen, wenn der Schwermetallgehalt pro ml höchstens μ_0 Einheiten beträgt. Je nach Situation würden wir beim Testen folgende Hypothesen wählen:

- Für einen neugebohrten Brunnen in einem trinkwasserarmen Dürregebiet:
 $H_0 : \mu \leq \mu_0$ und $H_1 : \mu > \mu_0$
- Für eine Trinkwasserquelle in Baden-Württemberg: $H_0 : \mu \geq \mu_0$ und $H_1 : \mu < \mu_0$

3.1.2 Wahl des Signifikanzniveaus

Das Signifikanzniveau α gibt die obere Schranke für die Wahrscheinlichkeit eines Fehlers 1. Art an. Es kann beliebig gewählt werden und sollte natürlich klein sein (gängige Werte sind $\alpha = 0.05$ oder $\alpha = 0.01$). Das Signifikanzniveau sollte allerdings auch nicht zu klein gewählt werden, denn durch Reduktion des Fehlers 1. Art, erhöhen wir im Gegenzug (unter sonst gleichen Umständen) den Fehler 2. Art, d. h. die Wahrscheinlichkeit eine falsche Nullhypothese nicht abzulehnen. Je kleiner das Signifikanzniveau ist, desto „extremer“ muss die Prüfgröße sein, dass wir die Nullhypothese auch tatsächlich ablehnen. Zwischen den Fehlern 1. und 2. Art muss also ein „trade-off“ stattfinden (im Idealfall möchte man beide klein halten). Insbesondere bei sehr kleinen Stichproben wird der Fehler 2. Art i. d. R. hoch sein, weshalb auf eine genügend große Stichprobe zu achten ist.

3.2 Hypothesentests für Normalverteilungen

3.2.1 Hypothesentest Erwartungswert bei bekannter Varianz

Sei $X \sim N(\mu, \sigma^2)$ eine normalverteilte Zufallsvariable mit bekannter Varianz σ^2 . Seien weiter die Hypothesen H_0 und H_1 sowie das Signifikanzniveau α gegeben. Der entsprechende Zufallsstrebereich kann dann – auf Basis der Hypothese H_0 – wie in Bemerkung 12.24 (Kapitel III, Wahrscheinlichkeitsrechnung) konstruiert werden. Das Testvorgehen wird im folgenden Satz zusammengefasst.

Satz 3.9. (Hypothesentest Erwartungswert bei bekannter Varianz – „Gauß-Test“)

Sei $X \sim N(\mu, \sigma^2)$ mit bekannter Varianz σ^2 . Sei weiter μ_0 ein zu testender Wert für den Erwartungswert von X sowie α das Signifikanzniveau, zu dem getestet werden soll. Die Streubereiche zum Signifikanzniveau α sind wie folgt gegeben:

H_0	H_1	Streubereich
$\mu = \mu_0$	$\mu \neq \mu_0$	$\left[\mu_0 - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \mu_0 + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$
$\mu \geq \mu_0$	$\mu < \mu_0$	$\left[\mu_0 - z_{1-\alpha} \frac{\sigma}{\sqrt{n}}, \infty \right)$
$\mu \leq \mu_0$	$\mu > \mu_0$	$\left(-\infty, \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right]$

Sei weiter $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen von X und $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ die Prüfgröße. Es gilt:

$\bar{x} \in \text{Streubereich} \implies H_0 \text{ wird nicht abgelehnt bzw. akzeptiert}$
 $\bar{x} \notin \text{Streubereich} \implies H_0 \text{ wird abgelehnt und } H_1 \text{ angenommen}$

Beispiel 3.10

Ein Glühbirnenproduzent behauptet, dass seine Glühbirnen eine Lebensdauer von mindestens 800 Tagen haben. Wir bezweifeln dies und erheben hierzu eine Stichprobe von 16 Glühbirnen. Der Mittelwert unserer Stichprobe beträgt $\bar{x} = 780$ Tage. Kann die Aussage des Produzenten bei einem Signifikanzniveau von 0.05 widerlegt werden? Wir nehmen an, dass die Lebensdauer X der Glühbirnen normalverteilt ist, mit einer langjährig bekannten Standardabweichung von 30 Tagen (d. h. $X \sim N(\mu, 30^2)$).

Im Folgenden das Vorgehen des Tests:

1. $H_0 : \mu \geq \mu_0 = 800, H_1 : \mu < \mu_0 = 800$
2. $\alpha = 0.05$
3. Für den Streubereich gilt

$$\left[\mu_0 - z_{1-\alpha} \frac{\sigma}{\sqrt{n}}, \infty \right) = \left[800 - z_{0.95} \frac{\sigma}{\sqrt{n}}, \infty \right)$$

und mit

$$z_{0.95} = 1.6449, \quad \sigma = 30, \quad n = 16$$

schließlich

$$\text{Streubereich} = \left[800 - 1.6449 \cdot \frac{30}{\sqrt{16}}, \infty \right) = [787.66, \infty).$$

4. Die Stichprobe von 16 Glühbirnen ergab $\bar{x} = 780$.
5. Da $\bar{x} \notin \text{Streubereich}$, lehnen wir die Nullhypothese H_0 ab.

6. **Fazit:** Es ist statistisch signifikant nachgewiesen (bei einer Fehler- bzw. Irrtumswahrscheinlichkeit von 0.05), dass die Lebensdauer der Glühbirnen unter 800 Tagen liegt und die Angabe des Herstellers damit nicht korrekt ist.

Aufgabe 3.11

Bei der Produktion von Bolzen beträgt der Sollwert für den Durchmesser 10 mm. Der Durchmesser sei normalverteilt mit einer durch die Maschine festgelegten, bekannten Standardabweichung von 0.5 mm. Zur Überprüfung der Einstellungen wurden 100 Teile entnommen und daraus der mittlere Durchmesser zu 10.15 mm bestimmt. Muss die Maschine nachjustiert werden? Prüfe zu einem Signifikanzniveau von 0.05.

3.2.2 Hypothesentest Erwartungswert bei unbekannter Varianz

Sei $X \sim N(\mu, \sigma^2)$ eine normalverteilte Zufallsvariable mit unbekannter Varianz σ^2 . Seien weiter die Hypothesen H_0 und H_1 sowie das Signifikanzniveau α gegeben. Der entsprechende Zufallsstrebereich kann dann – auf Basis der Hypothese H_0 – analog zum letzten Abschnitt konstruiert werden, wobei jedoch (wie in Abschnitt 2.1.2 diskutiert) die Quantile der Standardnormalverteilung durch die der entsprechenden t -Verteilung sowie σ durch s_x zu ersetzen sind. Das Testvorgehen wird im folgenden Satz zusammengefasst.

Satz 3.12. (Hypothesentest Erwartungswert bei unbekannter Varianz – „t-Test“)

Sei $X \sim N(\mu, \sigma^2)$ mit unbekannter Varianz σ^2 . Sei weiter μ_0 ein zu testender Wert für den Erwartungswert von X sowie α das Signifikanzniveau, zu dem getestet werden soll. Die Streubereiche zum Signifikanzniveau α sind wie folgt gegeben:

H_0	H_1	Streubereich
$\mu = \mu_0$	$\mu \neq \mu_0$	$\left[\mu_0 - t_{n-1; 1-\alpha/2} \frac{s_x}{\sqrt{n}}, \mu_0 + t_{n-1; 1-\alpha/2} \frac{s_x}{\sqrt{n}} \right]$
$\mu \geq \mu_0$	$\mu < \mu_0$	$\left[\mu_0 - t_{n-1; 1-\alpha} \frac{s_x}{\sqrt{n}}, \infty \right)$
$\mu \leq \mu_0$	$\mu > \mu_0$	$\left(-\infty, \mu_0 + t_{n-1; 1-\alpha} \frac{s_x}{\sqrt{n}} \right]$

mit $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ und $s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

Sei weiter $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen von X und $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ die Prüfgröße. Es gilt:

$\bar{x} \in \text{Streubereich} \implies H_0$ wird nicht abgelehnt bzw. akzeptiert
 $\bar{x} \notin \text{Streubereich} \implies H_0$ wird abgelehnt und H_1 angenommen

Bemerkung 3.13

1. Es ist wichtig, klar zwischen der (theoretischen) Varianz σ^2 und der empirischen Varianz s_x^2 zu unterscheiden (ebenso zwischen σ und s_x). Bei σ^2 handelt es sich um den Parameter der Normalverteilung. Die empirische Varianz s_x^2 – als Schätzer für σ^2 – wird auf Basis einer konkreten Stichprobe ermittelt und wir hatten bereits gesehen, dass i. d. R. $\sigma^2 \neq s_x^2$ gilt.
2. Falls die (theoretische) Varianz σ^2 vorab nicht bekannt ist, bleibt uns nur, sie mittels s_x^2 zu schätzen. In diesem Fall ist das obige Testverfahren (t-Test) zu verwenden.
3. Ob σ^2 bekannt oder unbekannt ist, geht aus der Formulierung der Aufgabe hervor.
 - (a) Wird in der Aufgabenstellung von einer bekannten Varianz bzw. Standardabweichung gesprochen, so nutzen wir den Gauß-Test 3.9 des letzten Abschnitts.
 - (b) Ist in der Aufgabenstellung neben dem Mittelwert aus der erhobenen Stichprobe auch die empirische Varianz (oder empirische Standardabweichung) der Stichprobe angegeben, ist dies ein Zeichen dafür, dass die Varianz σ^2 unbekannt ist (denn sonst bestünde nicht die Notwendigkeit zur Bestimmung der empirischen Varianz bzw. empirischen Standardabweichung).

Aufgabe 3.14

Ein Autohersteller behauptet, dass der Verbrauch eines bestimmten Modelles unter 4.3 Litern auf 100 km liegt. Ein Automobilclub möchte untersuchen, ob dies tatsächlich nachgewiesen werden kann. Hierzu werden 15 Fahrzeuge dieses Modelles getestet, dabei ergibt sich ein durchschnittlicher Verbrauch von 4.2 Litern auf 100 km bei einer Standardabweichung von 0.28 Litern. Ist damit die Aussage des Autoherstellers bei einer Irrtumswahrscheinlichkeit von 0.05 bewiesen? Wir nehmen an, dass der Verbrauch normalverteilt ist.

Aufgabe 3.15

Es wird vermutet, dass eine Produktionsanlage die Kilotüten mit Mehl befüllt, im Mittel wesentlich weniger als 1000 g abfüllt und damit nachjustiert werden muss. Zur Überprüfung der Anlage werden 20 Tüten entnommen, hierbei ergibt sich ein durchschnittliches Gewicht von 998.92 g bei einer Standardabweichung von 0.734 g. Wir nehmen an, dass das Gewicht normalverteilt ist. Führen Sie einen geeigneten Test zum Signifikanzniveau von 0.05 durch und beantworten Sie die Frage, ob die Anlage nachjustiert werden muss.

3.2.3 Hypothesentest Vergleich Erwartungswerte bei unbekannter gleicher Varianz

Seien $X \sim N(\mu_x, \sigma^2)$ und $Y \sim N(\mu_y, \sigma^2)$ zwei normalverteilte Zufallsvariablen mit unbekannten (aber gleichen) Varianzen. Seien weiter die Hypothesen H_0 und H_1 sowie das Signifikanzniveau α gegeben. Der entsprechende Zufallsstrebereich kann dann unter Nutzung der Darstellung in Abschnitt 2.1.4 konstruiert werden. Das Testvorgehen wird im folgenden Satz zusammengefasst.

Satz 3.16. (Hypothesentest Vergleich Erwartungswerte bei unbekannter gleicher Varianz – „Zweistichproben t-Test“)

Sei $X \sim N(\mu_x, \sigma^2)$ und $Y \sim N(\mu_y, \sigma^2)$ mit unbekannten (aber gleichen) Varianzen σ^2 . Sei weiter α das Signifikanzniveau, zu dem getestet werden soll. Die Streubereiche zum Signifikanzniveau α sind wie folgt gegeben:

H_0	H_1	Streubereich
$\mu_x = \mu_y$	$\mu_x \neq \mu_y$	$[-s \cdot t_{n+m-2; 1-\alpha/2}, s \cdot t_{n+m-2; 1-\alpha/2}]$
$\mu_x \geq \mu_y$	$\mu_x < \mu_y$	$[-s \cdot t_{n+m-2; 1-\alpha}, \infty)$
$\mu_x \leq \mu_y$	$\mu_x > \mu_y$	$(-\infty, s \cdot t_{n+m-2; 1-\alpha}]$

mit $s = \sqrt{(n-1)s_x^2 + (m-1)s_y^2} \cdot \sqrt{\frac{n+m}{n \cdot m \cdot (n+m-2)}}$.

Seien weiter $x_1, \dots, x_n$ bzw. $y_1, \dots, y_m$ Stichproben unabhängiger Realisationen von X bzw. Y und $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ bzw. $\bar{y} = \frac{1}{m} \sum_{i=1}^m y_i$ die Prüfgrößen. Es gilt:

$\bar{x} - \bar{y} \in \text{Streubereich} \implies H_0$ wird nicht abgelehnt bzw. akzeptiert

$\bar{x} - \bar{y} \notin \text{Streubereich} \implies H_0$ wird abgelehnt und H_1 angenommen

Aufgabe 3.17

Zwei Marathonläufer X und Y laufen innerhalb einer Woche jeweils 5 Trainingseinheiten von je 20 km. Dabei soll untersucht werden, ob Sportler X signifikant besser als Sportler Y ist. Die benötigten Zeiten von X und Y seien normalverteilt mit gleicher Varianz. Die Trainingszeiten in Stunden während einer Woche sind in folgender Tabelle gegenübergestellt:

i	1	2	3	4	5
x_i	2.2	2.3	2.6	2.0	2.9
y_i	2.5	2.2	2.7	2.8	2.7

Teste zu einem Signifikanzniveau von 0.05.

Aufgabe 3.18

Zum Testen eines neuen Kraftstoffs erhalten 5 Pkw zunächst 10 Liter des herkömmlichen Kraftstoffes (A) und hiernach 10 Liter des neuen Kraftstoffes (B). Bei diesem Vorgehen wurden folgende Fahrleistungen (in km) gemessen:

Pkw-Nr.	1	2	3	4	5
mit A	95	106	110	115	94
mit B	96	115	115	114	100

Ist die Fahrleistung mit dem neuen Kraftstoff wesentlich höher als mit dem alten? Teste zu einer Fehlerwahrscheinlichkeit von 0.05. Wir nehmen an, dass die Fahrleistung normalverteilt ist (mit gleichen Varianzen).

3.3 Hypothesentests für Wahrscheinlichkeiten

Sei X eine Bernoulli-verteilte Zufallsvariable mit $P(X = 1) = p$ und $P(X = 0) = 1 - p$. Seien weiter die Hypothesen H_0 und H_1 sowie das Signifikanzniveau α gegeben. Völlig analog zu den Ausführungen in Abschnitt 2.3, kann der entsprechende approximative Zufallsstrebereich konstruiert werden. Das Testvorgehen wird im folgenden Satz zusammengefasst.

Satz 3.19. (Approximativer Hypothesentest Wahrscheinlichkeit)

Sei X eine Bernoulli-verteilte Zufallsvariable mit $P(X = 1) = p$ und $P(X = 0) = 1 - p$. Sei weiter p_0 ein zu testender Wert für die Wahrscheinlichkeit p sowie α das Signifikanzniveau zu dem getestet werden soll. Die approximativen Streubereiche zum Signifikanzniveau α sind wie folgt gegeben:

H_0	H_1	Streubereich
$p = p_0$	$p \neq p_0$	$\left[p_0 - z_{1-\alpha/2} \frac{\sqrt{p_0(1-p_0)}}{\sqrt{n}} - \frac{0.5}{n}, p_0 + z_{1-\alpha/2} \frac{\sqrt{p_0(1-p_0)}}{\sqrt{n}} + \frac{0.5}{n} \right]$
$p \geq p_0$	$p < p_0$	$\left[p_0 - z_{1-\alpha} \frac{\sqrt{p_0(1-p_0)}}{\sqrt{n}} - \frac{0.5}{n}, 1 \right]$
$p \leq p_0$	$p > p_0$	$\left[0, p_0 + z_{1-\alpha} \frac{\sqrt{p_0(1-p_0)}}{\sqrt{n}} + \frac{0.5}{n} \right]$

Sei weiter $x_1, \dots, x_n$ eine Stichprobe unabhängiger Realisationen von X und

$$\hat{p} = \frac{\text{Anzahl der Stichprobenelemente mit Ausprägung 1}}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

die Prüfgröße. Es gilt:

$$\begin{aligned} \hat{p} \in \text{Streubereich} &\implies H_0 \text{ wird nicht abgelehnt bzw. akzeptiert} \\ \hat{p} \notin \text{Streubereich} &\implies H_0 \text{ wird abgelehnt und } H_1 \text{ angenommen} \end{aligned}$$

Bemerkung 3.20

1. Es handelt sich hierbei – wie in Abschnitt 2.3 diskutiert – nur um einen approximativen

Hypothesentest auf Basis des zentralen Grenzwertsatzes. Insbes. die Irrtumswahrscheinlichkeit ist damit nur approximativ!

2. Im konkreten Fall muss geprüft werden, ob die Approximation mittels Normalverteilung zulässig ist (vgl. Grenzwertsatz von de Moivre und Laplace).
3. Durch Verwenden der Binomialverteilung (zur Bestimmung der zentralen Streubereiche) kann die Approximation mittels Normalverteilung vermieden und die Irrtumswahrscheinlichkeit besser eingehalten werden.

Aufgabe 3.21

Eine Studie aus dem Jahr 2000 besagt, dass es in Deutschland 25 % Raucher gibt. Wir möchten prüfen, ob der Anteil der Raucher gesunken ist und befragen hierzu 1000 Personen. Unter den Befragten befinden sich 238 Raucher. Kann hierdurch unsere Hypothese nachgewiesen werden? Führe einen Test zum Signifikanzniveau 0.05 durch.

3.4 Abschließende Bemerkungen

Wir schließen das Kapitel mit einigen Bemerkungen zu Hypothesentests.

1. Wir hatten bei unserer Stichprobe stets vorausgesetzt, dass sie Ergebnis unabhängiger Realisierungen ist. Dies ist sehr wesentlich für die Aussagekraft eines Tests! Wollen wir bspw. anhand einer Stichprobe testen, ob die Tages-Sonnenscheindauer mindestens 8 Stunden beträgt, darf unsere Stichprobe nicht aus aufeinander folgenden Tagen bestehen. In diesem Fall wäre nämlich die Wahrscheinlichkeit groß, dass aufgrund der Wetterlage die einzelnen Realisierungen nicht unabhängig sind.
2. Beim Testen ist das Formulieren der Hypothesen sowie das Festlegen der Irrtumswahrscheinlichkeit vor Erhebung der Stichprobe durchzuführen. Ansonsten ist die Gefahr groß, aus gegebenen Daten einer Stichprobe einen Test zu konstruieren, der zu einem „gewünschten“ Ergebnis führt. Dies ist natürlich nicht sinnvoll! Wird aus gegebenem Datenmaterial eine Hypothese abgeleitet, so muss ein Test zwingend mit Datenmaterial einer neuen Stichprobe erfolgen!

Teil V

Statistische Qualitätskontrolle

1 Einführung

Wir möchten uns in diesem Kapitel mit einigen Aspekten der statistischen Qualitätskontrolle befassen und aufzeigen, wie wir hierzu das bisher erlernte gewinnbringend anwenden können.

Es ist klar, dass jeder Herstellungsprozess mit statistischen Schwankungen behaftet ist und deshalb Sollvorgaben niemals zu 100 % eingehalten werden können. Dennoch haben wir gewisse Anforderungen an die Genauigkeit unserer Produktion sowie an Toleranzbereiche für akzeptable Schwankungen. Im ersten Abschnitt zur Prozessfähigkeitskontrolle möchten wir uns mit diesem Aspekt beschäftigen und uns der Frage widmen, inwieweit unser Produktionsprozess überhaupt für die geforderte Genauigkeit geeignet ist.

Im zweiten Abschnitt zu Qualitätsregelkarten möchten wir Methoden kennenlernen, mit Hilfe derer wir nachverfolgen können, ob unser Produktionsprozess während der Produktion die geforderten Sollwerte bzw. Toleranzen auch tatsächlich einhält. Auf diese Weise bemerken wir frühzeitig, falls sich ungewünschte Änderungen im Produktionsprozess ergeben und können dadurch schnell und zielgerichtet eingreifen.

2 Prozessfähigkeit

Wir fixieren folgende Notation für die Vorgaben an unsere Produktion:

- OGW – oberer Grenzwert: dieser „darf“ nicht überschritten werden
- UGW – unterer Grenzwert: dieser „darf“ nicht unterschritten werden
- M – Mittelwert der Grenzwerte, d. h. $M = \frac{\text{OGW} + \text{UGW}}{2}$
- T – Toleranzbreite, d. h. $T = \text{OGW} - \text{UGW}$

Bemerkung 2.1

Wir sind uns darüber im Klaren, dass die Forderung, dass die Grenzwerte nicht überschritten werden dürfen, natürlich derart zu verstehen ist, dass eine Überschreitung sehr unwahrscheinlich ist. Die geforderte Fehlerwahrscheinlichkeit (oder Ausschussquote) ist eine der wesentlichen Anforderungen an unseren Produktionsprozess.

Wir nehmen weiter an, dass das zu untersuchende Merkmal X normalverteilt ist mit Erwartungswert $\mu = E(X)$ und Varianz $\sigma^2 = \text{Var}(X)$ (d. h. $X \sim N(\mu, \sigma^2)$).

Bemerkung 2.2

Es gilt:

1.

$$P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) = 1 - 0.002700$$

D. h. die Wahrscheinlichkeit, dass X außerhalb des 3σ -Toleranzbereiches liegt, ist rund 0.27 %. Damit liegt im Schnitt eines von 370 Teilen nicht im Toleranzbereich.

2.

$$P(\mu - 4\sigma \leq X \leq \mu + 4\sigma) = 1 - 0.000063$$

D. h. die Wahrscheinlichkeit, dass X außerhalb des 4σ -Toleranzbereiches liegt, ist rund 0.0063 %. Damit liegt im Schnitt eines von 15787 Teilen nicht im Toleranzbereich.

3.

$$P(\mu - 6\sigma \leq X \leq \mu + 6\sigma) = 1 - 0.19 \cdot 10^{-10}$$

D. h. die Wahrscheinlichkeit, dass X außerhalb des 6σ -Toleranzbereiches liegt, ist rund $1.9 \cdot 10^{-7}$ %. Damit liegt im Schnitt eines von 507 Mio. Teilen nicht im Toleranzbereich.

Eine der wesentlichen Kennzahlen zur Beurteilung der Prozessfähigkeit ist der c_p -Wert.

Definition 2.3. (Capability of Process)

Wir definieren die Kennzahl c_p wie folgt:

$$c_p := \frac{T}{6\sigma}$$

Der c_{pk} -Wert bezieht bei der Beurteilung schließlich auch die Lage des Erwartungswerts μ relativ zu den Toleranzgrenzen mit ein.

Definition 2.4

Wir definieren die Kennzahl c_{pk} wie folgt:

$$c_{pk} := \frac{\min(\text{OGW} - \mu, \mu - \text{UGW})}{3\sigma} = \frac{\text{Abstand von } \mu \text{ zur näheren Toleranzgrenze}}{3\sigma}$$

Mittels der Aussagen in Bemerkung 2.2 gilt dann annähernd (analog für den c_p -Wert):

1. $c_{pk} = 1$ – im Schnitt maximal eines von 370 Teilen der Produktion liegt nicht im Toleranzbereich (dies entspricht einer 3-Sigma-Regel)
2. $c_{pk} = \frac{4}{3}$ – im Schnitt maximal eines von 15787 Teilen der Produktion liegt nicht im Toleranzbereich (dies entspricht einer 4-Sigma-Regel)
3. $c_{pk} = 2$ – im Schnitt maximal eines von 507 Mio. Teilen der Produktion liegt nicht im Toleranzbereich (dies entspricht einer 6-Sigma-Regel)

Die Kennzahlen c_p und c_{pk} sind damit ein Maß für die Güte unserer Produktion, d. h. dafür, wie viele Teile der Produktion nicht im Toleranzbereich liegen. Je größer c_p bzw. c_{pk} sind, desto weniger Teile liegen nicht innerhalb der Toleranzgrenzen.

Definition 2.5. (Prozessfähigkeit)

In der Praxis spricht man (i. d. R.) von Prozessfähigkeit, wenn

$$c_p \geq \frac{4}{3} \quad \text{und} \quad c_{pk} \geq \frac{4}{3}$$

gilt. Dies entspricht einer 4-Sigma-Regel.

Bemerkung 2.6

1. Ist $c_p < \frac{4}{3}$ so liegt (i. d. R.) Prozessunfähigkeit vor, d. h. gängige Qualitätsstandards können nicht eingehalten werden. Sollen diese doch eingehalten werden, muss über eine Prozessverbesserung (bspw. genauere Maschinen) nachgedacht werden.
2. Ist $c_p \geq \frac{4}{3}$, aber $c_{pk} < \frac{4}{3}$, so ist man prinzipiell in der Lage Prozessfähigkeit herzustellen, indem der Sollwert μ in Richtung M verschoben wird. Dies kann in der Praxis i. d. R. sehr leicht durch eine Neujustierung der Produktion (Anpassung des Sollmaßes) erreicht werden. Die Varianz der Produktion kann jedoch i. d. R. nicht direkt beeinflusst werden.
3. Manchmal wird in der Praxis auch $c_p \geq 2$ und $c_{pk} \geq 2$ gefordert; dies entspricht einer 6-Sigma-Regel.

3 Qualitätsregelkarten

Wir wollen in diesem Abschnitt die folgenden zwei Qualitätsregelkarten (QRK) besprechen.

- $\bar{x}$ -Karte ($\bar{x}$ -Quer-Karte) zur Überwachung des Ziel- oder Sollwertes
- s -Karte zur Überwachung der Streuung um den Ziel- oder Sollwert

Für jeden dieser Kartentypen werden Eingriffs- und Warngrenzen festgelegt. Diese sind wie folgt definiert:

- **Eingriffsgrenzen:** Liegen die Einträge auf der Karte außerhalb dieser Grenzen, wird sofort in den Prozess eingegriffen (bspw. wird sofort die betroffene Maschine neu justiert). Die Eingriffsgrenzen werden i. d. R. derart festgelegt, dass bei korrekter Einstellung nur in 1 % der Fälle Fehlalarme auftreten.
- **Warngrenzen:** Liegen die Einträge auf der Karte außerhalb dieser Grenzen, wird der Prozess mit erhöhter Aufmerksamkeit verfolgt (eventuell werden bald die Eingriffsgrenzen überschritten). Die Warngrenzen werden i. d. R. derart festgelegt, dass bei korrekter Einstellung nur in 5 % der Fälle Fehlalarme auftreten.

Bei der Verfolgung der Einträge auf den Karten werden darüber hinaus folgende Auffälligkeiten überprüft:


- **Trend:** Liegen mindestens 8 aufeinanderfolgende Punkte monoton ansteigend oder absteigend, dann liegt ein Trend vor. Dies deutet darauf hin, dass sich die Einstellungen der

Maschine kontinuierlich verändert haben und sich weiter verändern werden.

- **Run:** Liegen mindestens 8 aufeinanderfolgende Punkte auf derselben Seite der Mittellinie (siehe nächster Abschnitt), spricht man von einem Run. Dies deutet darauf hin, dass sich die Einstellung verändert hat und der Prozess nicht mehr richtig justiert ist.
- **Regelmäßige Schwankungen:** Sind regelmäßige Schwankungen (bspw. im Tagesverlauf oder zu Schichtwechseln) erkennbar, sollte der Prozess daraufhin untersucht werden.

Beispiel 3.1

Im Folgenden sind die beiden Typen der Qualitätsregelkarten beispielhaft dargestellt:



3.1 $\bar{x}$ -Karte

Mittels einer $\bar{x}$ -Karte soll ein normalverteiltes Merkmal X mit Mittelwert μ und Varianz σ^2 überwacht werden. Hintergrund der $\bar{x}$ -Karte ist die Fragen, ob sich der Mittelwert verändert oder bereits verändert hat.

Das Entwickeln und Führen der Karte ist im Folgenden dargestellt.

1. Bestimmen der grundlegenden Parameter μ und σ : Diese werden aus einem ungestörten Prozessverlauf geschätzt (siehe hierzu Abschnitt 4) oder durch die Sollwerte vorgegeben.
2. Festlegung des Stichprobenumfangs n für die Prüfung im laufenden Prozess. Bspw. werden jeweils $n = 5$ Werkstücke entnommen und untersucht.
3. Vorbereitung der $\bar{x}$ -Karte:
 - (a) Erwartungswert μ als Mittellinie einzeichnen.
 - (b) Einzeichnen der Warngrenzen. Diese liegen bei:

$$\mu \pm z_{1-0.05/2} \frac{\sigma}{\sqrt{n}} = \mu \pm 1.96 \cdot \frac{\sigma}{\sqrt{n}}$$

Innerhalb dieses Intervalls liegen die Mittelwerte $\bar{x}_i$ (s. u.) mit Wahrscheinlichkeit 95 %.

- (c) Einzeichnen der Eingriffsgrenzen. Diese liegen bei:

$$\mu \pm z_{1-0.01/2} \frac{\sigma}{\sqrt{n}} = \mu \pm 2.576 \cdot \frac{\sigma}{\sqrt{n}}$$

Innerhalb dieses Intervalls liegen die Mittelwerte $\bar{x}_i$ (s. u.) mit Wahrscheinlichkeit 99 %.

4. Führen der $\bar{x}$ -Karte:

- (a) Der laufenden Produktion werden zu festgelegten Zeitpunkten t_i jeweils n Teile entnommen und untersucht. Aus der Stichprobe wird der Mittelwert $\bar{x}_i$ gebildet.
- (b) Der Mittelwert $\bar{x}_i$ wird auf der Karte eingetragen.
- (c) Es wird geprüft, ob die Warn- oder Eingriffsgrenzen überschritten werden. Darüber hinaus erfolgt die Prüfung auf Trends und Runs.

Bemerkung 3.2

Das oben beschriebene Vorgehen zu $\bar{x}$ -Karten kann ohne Modifikationen auch für nicht-normalverteilte Merkmale X verwendet werden. Gemäß Grenzwertsatz sind die Mittelwerte (großer) Stichproben näherungsweise normalverteilt.

Aufgabe 3.3

In einer Fabrik werden Produkte mit einer Ziellänge von 216 mm hergestellt. Aus langjähriger Erfahrung ist bekannt, dass die Standardabweichung bei 3 mm liegt. Zur Prüfung des Fertigungsprozesses werden im Stundentakt jeweils 4 Produkte aus der laufenden Produktion entnommen und geprüft. Die Stichproben der letzten 6 Stunden sind unten gegeben. Fertige eine $\bar{x}$ -Karte an und trage die 6 Stichproben in die Karte ein. Gab es Warnungen?

	1	2	3	4
Stichprobe 1	215	215	216	212
Stichprobe 2	211	223	212	217
Stichprobe 3	219	212	219	220
Stichprobe 4	220	210	210	216
Stichprobe 5	224	215	219	218
Stichprobe 6	217	223	220	221

3.2 s -Karte

Mittels einer s -Karte soll ein normalverteiltes Merkmal X mit Mittelwert μ und Varianz σ^2 überwacht werden. Hintergrund der s -Karte ist die Fragen, ob sich die Standardabweichung verändert oder bereits verändert hat.

Das Entwickeln und Führen der Karte ist im Folgenden dargestellt.

1. Bestimmen der grundlegenden Parameter μ und σ : Diese werden aus einem ungestörten Prozessvorlauf geschätzt (siehe hierzu Abschnitt 4) oder durch die Sollwerte vorgegeben.
2. Festlegung des Stichprobenumfangs n für die Prüfung im laufenden Prozess. Bspw. werden jeweils $n = 5$ Werkstücke entnommen und untersucht.
3. Vorbereitung der s -Karte:

- (a) Wert σ/c_n als Mittellinie einzeichnen. Die Faktoren c_n sind dabei die Korrekturfaktoren, die wir bei den Schätzern der Standardabweichung kennengelernt hatten (siehe Bemerkung 1.14, Kapitel IV).
- (b) Einzeichnen der Warngrenzen. Diese liegen bei:

$$\sigma \cdot \sqrt{\frac{\chi_{n-1;0.025}^2}{n-1}} \quad \text{bzw.} \quad \sigma \cdot \sqrt{\frac{\chi_{n-1;0.975}^2}{n-1}}$$

Innerhalb dieses Intervalls liegen die Standardabweichungen s_i (s. u.) mit Wahrscheinlichkeit 95 %.

- (c) Einzeichnen der Eingriffsgrenzen. Diese liegen bei:

$$\sigma \cdot \sqrt{\frac{\chi_{n-1;0.005}^2}{n-1}} \quad \text{bzw.} \quad \sigma \cdot \sqrt{\frac{\chi_{n-1;0.995}^2}{n-1}}$$

Innerhalb dieses Intervalls liegen die Standardabweichungen s_i (s. u.) mit Wahrscheinlichkeit 99 %.

4. Führen der s -Karte

- (a) Der laufenden Produktion werden zu festgelegten Zeitpunkten t_i jeweils n Teile entnommen und untersucht. Aus der Stichprobe wird die empirische Standardabweichung s_i gebildet.
- (b) Der empirische Standardabweichung s_i wird auf der Karte eingetragen.
- (c) Es wird geprüft, ob die Warn- oder Eingriffsgrenzen überschritten werden. Darüber hinaus erfolgt die Prüfung auf Trends und Runs. Bei der Prüfung auf Runs sollte man – da die χ^2 -Verteilung nicht symmetrisch ist – gegen den Median

$$\sigma \cdot \sqrt{\frac{\chi_{n-1;0.5}^2}{n-1}}$$

vergleichen und diesen hierzu ebenfalls in die s -Karte einzeichnen.

Bemerkung 3.4

Wird die untere Warn- bzw. Eingriffsgrenze unterschritten, ist dies ein gutes Zeichen, da die Schwankung (Standardabweichung) unseres Produktionsprozesses signifikant zurückgegangen ist. Dennoch sollte eruiert werden, was der Grund dafür ist, um möglichst auch zukünftig ähnliche Produktionsbedingungen herstellen zu können.

Aufgabe 3.5. (Fortsetzung)

Fertige für die in Aufgabe 3.3 dargestellte Situation eine s -Karte und fülle diese mit den 6 Stichproben. Gab es Warnungen?

4 Bestimmung von μ und σ

Sind die Parameter μ und σ nicht durch Sollvorgaben vorgegeben, müssen diese zuerst aus einem ungestörten Vorlauf geschätzt werden. Das Vorgehen hierzu ist im Folgenden dargestellt.

1. Erhebe k unabhängige Stichproben mit Umfang m aus dem Produktionsprozess. Wir erhalten folgende Stichproben:

Nr.	Stichprobe	Kenngößen
1	$x_{11}, x_{12}, \dots, x_{1m}$	$\bar{x}_1, s_1$
2	$x_{21}, x_{22}, \dots, x_{2m}$	$\bar{x}_2, s_2$
$\vdots$	$\vdots$	$\vdots$
k	$x_{k1}, x_{k2}, \dots, x_{km}$	$\bar{x}_k, s_k$

Hierbei ist $\bar{x}_i$ der übliche Stichprobenmittelwert und s_i die übliche empirische Standardabweichung, d.h.

$$\bar{x}_i = \frac{1}{m}(x_{i1} + \dots + x_{im}) \quad \text{bzw.} \quad s_i = \sqrt{\frac{1}{m-1} \sum_{j=1}^m (x_{ij} - \bar{x}_i)^2}$$

2. Wir ermitteln Schätzer für μ und σ nun wie folgt

$$\hat{\mu} = \frac{1}{k}(\bar{x}_1 + \dots + \bar{x}_k) \quad \text{bzw.} \quad \hat{\sigma} = c_m \cdot \frac{1}{k} \cdot (s_1 + \dots + s_k)$$

hierbei bezeichnet c_m die Korrekturfaktoren, die wir bei den Schätzern der Standardabweichung für normalverteilte Zufallsvariablen kennengelernt hatten (siehe auch Bemerkung 1.14, Kapitel IV).

Bemerkung 4.1

Die Werte für c_n mit $n = 2, \dots, 10$ sind im Folgenden nochmals tabelliert:

n	2	3	4	5	6	7	8	9	10
c_n	1.253	1.128	1.085	1.064	1.051	1.042	1.036	1.032	1.028

Aufgabe 4.2

Zur Feststellung von μ und σ eines Produktionsprozesses wurden an fünf Tagen jeweils 3 Werkstücke der laufenden Produktion entnommen und deren Längen bestimmt; die Ergebnisse sind unten angegeben. Schätze μ und σ aus den Stichproben.

	1	2	3
Tag 1	679	631	640
Tag 2	660	646	668
Tag 3	642	674	649
Tag 4	627	657	660
Tag 5	632	679	657

5 Ein Beispiel

Wir sollen für einen Kunden Nägel produzieren. Dieser möchte 100 Mio. Nägel bestellen, die zuverlässig zwischen 59.0 mm und 60.5 mm lang sind. Die einzelnen Schritte zur Vorbereitung und Durchführung des Auftrages sind im Folgenden dargestellt.

5.1 Analyse des Fertigungsprozesses – Schätzung von μ und σ

Zuerst müssen wir unseren Fertigungsprozess analysieren, um Schätzer für den Erwartungswert μ als auch die Standardabweichung σ unserer produzierten Nägel zu erlangen. Erst auf dieser Basis können wir entscheiden, ob wir die geforderten Toleranzen überhaupt einhalten können.

Wir entnehmen hierzu unserer Produktion an sieben aufeinander folgenden Tagen jeweils 5 Nägel. Die Ergebnisse der erhobenen Stichproben sind im Folgenden dargestellt:

	Tag 1	Tag 2	Tag 3	Tag 4	Tag 5	Tag 6	Tag 7
x_1	59.56	59.75	59.62	59.56	59.60	59.53	59.75
x_2	59.56	59.63	59.55	59.65	59.37	60.01	59.33
x_3	59.59	59.87	59.80	59.63	59.51	59.83	59.86
x_4	59.58	59.75	59.42	59.36	59.62	59.89	59.54
x_5	59.58	59.51	59.58	59.63	59.63	59.48	59.72
$\bar{x}_i$	59.574	59.702	59.594	59.566	59.546	59.748	59.640
s_i	0.013	0.137	0.137	0.120	0.109	0.232	0.208

Mithin erhalten wir als Schätzer (mit Anpassungsfaktor $c_5 = 1.064$):

$$\hat{\mu} = \frac{59.574 + 59.702 + 59.594 + 59.566 + 59.546 + 59.748 + 59.640}{7} = 59.624$$

$$\hat{\sigma} = 1.064 \cdot \frac{0.013 + 0.137 + 0.137 + 0.120 + 0.109 + 0.232 + 0.208}{7} = 0.1454$$

5.2 Prozessanalyse – Ermittlung von c_p und c_{pk}

Wir bestimmen nun die Prozesskennzahlen c_p und c_{pk} , um zu entscheiden, ob unser Prozess die nötigen Qualitätsanforderungen erfüllt und wir die Einhaltung der Toleranzgrenzen sicherstellen

können.

Es gilt

$$\begin{aligned}\text{OGW} &= 60.5 \\ \text{UGW} &= 59.0 \\ M &= 59.75 \\ \hat{\mu} &= 59.624 \\ \hat{\sigma} &= 0.1454\end{aligned}$$

und damit folgt:

$$c_p = \frac{1.5}{6 \cdot \sigma} = 1.7194 \quad \text{bzw.} \quad c_{pk} = \frac{59.624 - 59.0}{3 \cdot \sigma} = 1.4305$$

Da beide Prozesskennzahlen über $4/3$ – den gängigen Qualitätsanforderungen – liegen, liegt also Prozessfähigkeit vor.

Wir entschließen uns, auf dieser Basis die Produktion auf den Zielwert 59.7 mm neu zu justieren, um eine stabilere Einstellung zu erhalten. Die Standardabweichung σ können wir nicht beeinflussen.

5.3 Prozesskontrolle – Vorbereitung der Qualitätsregelkarten

Wir legen den Stichprobenumfang mit $n = 5$ fest. Wir entnehmen also pro Stunde 5 Nägel, messen deren Längen und berechnen den Mittelwert sowie die empirische Standardabweichung.


5.3.1 $\bar{x}$ -Karte

Für die $\bar{x}$ -Karte ergibt sich:

- obere Eingriffsgrenze: $59.7 + 2.576 \cdot \frac{0.1454}{\sqrt{5}} = 59.868$
- untere Eingriffsgrenze: $59.7 - 2.576 \cdot \frac{0.1454}{\sqrt{5}} = 59.532$
- obere Warngrenze: $59.7 + 1.96 \cdot \frac{0.1454}{\sqrt{5}} = 59.827$
- untere Warngrenze: $59.7 - 1.96 \cdot \frac{0.1454}{\sqrt{5}} = 59.573$

Die $\bar{x}$ -Karte hat damit folgende Gestalt:

$\bar{x}$ -Karte




5.3.2 s -Karte

Für die s -Karte ergibt sich:

- Mittellinie: $\frac{0.1454}{1.064} = 0.1367$
- obere Eingriffsgrenze: $0.1454 \cdot \sqrt{\frac{14.860}{4}} = 0.2802$
- obere Warngrenze: $0.1454 \cdot \sqrt{\frac{11.143}{4}} = 0.2427$
- untere Warngrenze: $0.1454 \cdot \sqrt{\frac{0.484}{4}} = 0.0506$
- untere Eingriffsgrenze: $0.1454 \cdot \sqrt{\frac{0.207}{4}} = 0.0331$

Die s -Karte hat damit folgende Gestalt:




5.4 Prozesskontrolle – Durchführung

Wir überwachen nun den Produktionsprozess mittels der im letzten Abschnitt entworfenen Qualitätsregelkarten. Wir entnehmen hierzu ab 7 Uhr stündlich jeweils 5 Nägel und berechnen Mittelwert und empirische Standardabweichung der Stichprobe. Bis 9 Uhr ergeben sich folgende Werte:

	7 Uhr	8 Uhr	9 Uhr
x_1	59.81	59.80	59.40
x_2	59.88	59.79	59.52
x_3	59.52	59.70	59.42
x_4	59.44	59.93	59.71
x_5	59.69	59.78	59.68
$\bar{x}$	59.67	59.80	59.55
s	0.19	0.08	0.14

Wir tragen diese Werte in die Qualitätsregelkarten ein. Um 9 Uhr sehen diese dann wie folgt aus:



Die Messung zum Mittelwert führte um 9 Uhr zu einer Warnung. Der Produktionsprozess wurde jedoch nicht gestoppt. Erst wenn die Eingriffsgrenzen überschritten werden, erfolgt ein Eingriff in die Produktion. Der Verlauf der s -Karte ist bis 9 Uhr unauffällig.

Teil VI

Anhang

TABELLE: Kumulierte Standard-Normalverteilung

$$\Phi(z) = \int_{-\infty}^z \varphi(x) dx = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$


z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.10	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.20	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.30	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.40	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.50	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.60	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.70	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.80	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.90	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.00	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.10	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.20	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.30	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.40	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.50	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.60	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.70	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.80	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.90	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.00	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.10	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.20	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.30	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.40	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.50	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.60	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.70	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.80	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.90	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.00	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.10	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.20	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.30	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.40	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Interpretation: Die Werte in der Tabelle geben die Wahrscheinlichkeit dafür an, dass eine standardnormalverteilte Zufallsgröße X kleiner oder gleich z ist.

Transformationsregel:

$$\Phi(-z) = 1 - \Phi(z)$$

Beispiel: $P(X \leq 1.83) = \Phi(1.83) = 0.9664$




Quantile z_α der Standardnormalverteilung $N(0, 1)$

Ablesebeispiel: $z_{0.95} = 1.6449$.

Erweiterung der Tafel: $z_{1-\alpha} = -z_\alpha$

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-z^2/2} dz \quad \text{Verteilungsfunktion}$$



α	z_α	α	z_α	α	z_α	α	z_α
0.9999	3.7190	0.9955	2.6121	0.975	1.9600	0.780	0.7722
0.9998	3.5401	0.9950	2.5758	0.970	1.8808	0.770	0.7388
0.9997	3.4316	0.9945	2.5427	0.965	1.8119	0.760	0.7063
0.9996	3.3528	0.9940	2.5121	0.960	1.7507	0.750	0.6745
0.9995	3.2905	0.9935	2.4838	0.955	1.6954	0.740	0.6433
0.9994	3.2389	0.9930	2.4573	0.950	1.6449	0.730	0.6128
0.9993	3.1946	0.9925	2.4324	0.945	1.5982	0.720	0.5828
0.9992	3.1559	0.9920	2.4089	0.940	1.5548	0.710	0.5534
0.9991	3.1214	0.9915	2.3867	0.935	1.5141	0.700	0.5244
0.9990	3.0902	0.9910	2.3656	0.930	1.4758	0.690	0.4959
0.9989	3.0618	0.9905	2.3455	0.925	1.4395	0.680	0.4677
0.9988	3.0357	0.9900	2.3263	0.920	1.4051	0.670	0.4399
0.9987	3.0115	0.9895	2.3080	0.915	1.3722	0.660	0.4125
0.9986	2.9889	0.9890	2.2904	0.910	1.3408	0.650	0.3853
0.9985	2.9677	0.9885	2.2734	0.905	1.3106	0.640	0.3585
0.9984	2.9478	0.9880	2.2571	0.900	1.2816	0.630	0.3319
0.9983	2.9290	0.9875	2.2414	0.895	1.2536	0.620	0.3055
0.9982	2.9112	0.9870	2.2262	0.890	1.2265	0.610	0.2793
0.9981	2.8943	0.9865	2.2115	0.885	1.2004	0.600	0.2533
0.9980	2.8782	0.9860	2.1973	0.880	1.1750	0.590	0.2275
0.9979	2.8627	0.9855	2.1835	0.875	1.1503	0.580	0.2019
0.9978	2.8480	0.9850	2.1701	0.870	1.1264	0.570	0.1764
0.9977	2.8338	0.9845	2.1571	0.865	1.1031	0.560	0.1510
0.9976	2.8202	0.9840	2.1444	0.860	1.0803	0.550	0.1257
0.9975	2.8070	0.9835	2.1321	0.855	1.0581	0.540	0.1004
0.9974	2.7944	0.9830	2.1201	0.850	1.0364	0.530	0.0753
0.9973	2.7821	0.9825	2.1084	0.845	1.0152	0.520	0.0502
0.9972	2.7703	0.9820	2.0969	0.840	0.9945	0.510	0.0251
0.9971	2.7589	0.9815	2.0858	0.835	0.9741	0.500	0.0000
0.9970	2.7478	0.9810	2.0749	0.830	0.9542		
0.9969	2.7370	0.9805	2.0642	0.825	0.9346		
0.9968	2.7266	0.9800	2.0537	0.820	0.9154		
0.9967	2.7164	0.9795	2.0435	0.815	0.8965		
0.9966	2.7065	0.9790	2.0335	0.810	0.8779		
0.9965	2.6968	0.9785	2.0237	0.805	0.8596		
0.9964	2.6874	0.9780	2.0141	0.800	0.8416		
0.9963	2.6783	0.9775	2.0047	0.795	0.8239		
0.9962	2.6693	0.9770	1.9954	0.790	0.8064		
0.9961	2.6606	0.9765	1.9863	0.785	0.7892		
0.9960	2.6521	0.9760	1.9774	0.780	0.7722		

TABELLE: Quantile der Student- t -Verteilung


$n \backslash \gamma$	0.9	0.95	0.975	0.99	0.995
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771
28	1.313	1.701	2.048	2.467	2.763
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
40	1.303	1.684	2.021	2.423	2.704
60	1.296	1.671	2.000	2.390	2.660
120	1.289	1.658	1.980	2.358	2.617
∞	1.282	1.645	1.960	2.327	2.576

Interpretation: Die Werte in der Tabelle geben das γ -Quantil $q_\gamma = t_{n,\gamma}$ einer t_n -verteilten Zufallsgröße X an, also

$$\mathbb{P}(X \leq q_\gamma) = \gamma.$$

Anwendung: α bezeichnet die Irrtumswahrscheinlichkeit und n die Anzahl der Freiheitsgrade einer t_n -verteilten Zufallsgröße X .

Beispiel: Bei einem einseitigen Test mit einer Irrtumswahrscheinlichkeit von $\alpha = 5\%$ (d.h. $\gamma = 1 - \alpha = 0.95$) und $n = 10$ Freiheitsgraden ist der kritische Wert $t_{n,1-\alpha} = 1.812$. Das heißt, $\mathbb{P}(X \leq 1.812) = 0.95$.



Für einen zweiseitigen Test mit $\alpha = 0.05$ und $n = 10$ ist der kritische Wert $t_{n,1-\frac{\alpha}{2}} = 2.228$.

TABELLE: Quantile der χ_n^2 -Verteilung

n						α				
	0.005	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99	0.995
1	0.000	0.000	0.001	0.004	0.016	2.706	3.841	5.024	6.635	7.879
2	0.010	0.020	0.051	0.103	0.211	4.605	5.991	7.378	9.210	10.597
3	0.072	0.115	0.216	0.352	0.584	6.251	7.815	9.348	11.345	12.838
4	0.207	0.297	0.484	0.711	1.064	7.779	9.488	11.143	13.277	14.860
5	0.412	0.554	0.831	1.145	1.610	9.236	11.070	12.833	15.086	16.750
6	0.676	0.872	1.237	1.635	2.204	10.645	12.592	14.449	16.812	18.548
7	0.989	1.239	1.690	2.167	2.833	12.017	14.067	16.013	18.475	20.278
8	1.344	1.646	2.180	2.733	3.490	13.362	15.507	17.535	20.090	21.955
9	1.735	2.088	2.700	3.325	4.168	14.684	16.919	19.023	21.666	23.589
10	2.156	2.558	3.247	3.940	4.865	15.987	18.307	20.483	23.209	25.188
11	2.603	3.053	3.816	4.575	5.578	17.275	19.675	21.920	24.725	26.757
12	3.074	3.571	4.404	5.226	6.304	18.549	21.026	23.337	26.217	28.300
13	3.565	4.107	5.009	5.892	7.042	19.812	22.362	24.736	27.688	29.819
14	4.075	4.660	5.629	6.571	7.790	21.064	23.685	26.119	29.141	31.319
15	4.601	5.229	6.262	7.261	8.547	22.307	24.996	27.488	30.578	32.801
16	5.142	5.812	6.908	7.962	9.312	23.542	26.296	28.845	32.000	34.267
17	5.697	6.408	7.564	8.672	10.085	24.769	27.587	30.191	33.409	35.718
18	6.265	7.015	8.231	9.390	10.865	25.989	28.869	31.526	34.805	37.156
19	6.844	7.633	8.907	10.117	11.651	27.204	30.144	32.852	36.191	38.582
20	7.434	8.260	9.591	10.851	12.443	28.412	31.410	34.170	37.566	39.997
21	8.034	8.897	10.283	11.591	13.240	29.615	32.671	35.479	38.932	41.401
22	8.643	9.542	10.982	12.338	14.041	30.813	33.924	36.781	40.289	42.796
23	9.260	10.196	11.689	13.091	14.848	32.007	35.172	38.076	41.638	44.181
24	9.886	10.856	12.401	13.848	15.659	33.196	36.415	39.364	42.980	45.559
25	10.520	11.524	13.120	14.611	16.473	34.382	37.652	40.646	44.314	46.928
26	11.160	12.198	13.844	15.379	17.292	35.563	38.885	41.923	45.642	48.290
27	11.808	12.879	14.573	16.151	18.114	36.741	40.113	43.195	46.963	49.645
28	12.461	13.565	15.308	16.928	18.939	37.916	41.337	44.461	48.278	50.993
29	13.121	14.256	16.047	17.708	19.768	39.087	42.557	45.722	49.588	52.336
30	13.787	14.953	16.791	18.493	20.599	40.256	43.773	46.979	50.892	53.672
40	20.707	22.164	24.433	26.509	29.051	51.805	55.758	59.342	63.691	66.766
50	27.991	29.707	32.357	34.764	37.689	63.167	67.505	71.420	76.154	79.490
60	35.534	37.485	40.482	43.188	46.459	74.397	79.082	83.298	88.379	91.952
70	43.275	45.442	48.758	51.739	55.329	85.527	90.531	95.023	100.425	104.215
80	51.172	53.540	57.153	60.391	64.278	96.578	101.879	106.629	112.329	116.321
90	59.196	61.754	65.647	69.126	73.291	107.565	113.145	118.136	124.116	128.299
100	67.328	70.065	74.222	77.929	82.358	118.498	124.342	129.561	135.807	140.169

Interpretation: α bezeichnet die Irrtumswahrscheinlichkeit und n die Anzahl der Freiheitsgrade einer χ_n^2 -verteilten Zufallsvariablen.

Beispiel: Bei einem zweiseitigen Test mit einer Irrtumswahrscheinlichkeit von 5% ($\alpha = 0.05$) und 10 Freiheitsgraden ($n = 10$) ergeben sich die kritischen Werte $\chi_{10, \frac{\alpha}{2}}^2 = 3.247$ und $\chi_{10, 1-\frac{\alpha}{2}}^2 = 20.483$. Das heißt, $P(3.247 < \chi_{10}^2 < 20.483) = 0.95$.

